



ระบบอ่านค่ามาตรน้ำอานาล็อกอัตโนมัติโดยใช้เทคนิคการประมวลผลภาพและการเรียนรู้เชิงลึก

Automatic Analog Water Meter Reading using Deep Learning
and Image Processing Techniques

ปิยะพร แสงพรหมขารี่

Piyaporn Sangpromcharee

วิทยานิพนธ์นี้สำหรับการศึกษิตามหลักสูตรปริญญา

วิศวกรรมศาสตรบัณฑิต สาขาวิศวกรรมคอมพิวเตอร์

มหาวิทยาลัยนครพนม

A Thesis Submitted in Fulfillment of the Requirements for the Degree of
Bachelor of Engineering in Computer Engineering

Nakhon Phanom University

2568

ลิขสิทธิ์ของมหาวิทยาลัยนครพนม



ระบบอ่านค่ามาตรน้ำอานาล็อกอัตโนมัติโดยใช้เทคนิคการประมวลผลภาพและการเรียนรู้เชิงลึก

Automatic Analog Water Meter Reading using Deep Learning
and Image Processing Techniques

ปิยะพร แสงพรหมขารี่

Piyaporn Sangpromcharee

วิทยานิพนธ์นี้สำหรับการศึกษิตามหลักสูตรปริญญา

วิศวกรรมศาสตรบัณฑิต สาขาวิศวกรรมคอมพิวเตอร์

มหาวิทยาลัยนครพนม

A Thesis Submitted in Fulfillment of the Requirements for the Degree of
Bachelor of Engineering in Computer Engineering

Nakhon Phanom University

2568

ลิขสิทธิ์ของมหาวิทยาลัยนครพนม

ชื่อวิทยานิพนธ์ ระบบอ่านค่ามาตรน้ำอเนกประสงค์อัตโนมัติโดยใช้เทคนิคการประมวลผลภาพ
และการเรียนรู้เชิงลึก

ชื่อผู้เขียน นางสาว ปิยะพร แสงพรหมขารี

สาขาวิชา วิศวกรรมคอมพิวเตอร์

อาจารย์ที่ปรึกษาวิทยานิพนธ์หลัก

คณะกรรมการสอบ

..... ประธานกรรมการ

(ผู้ช่วยศาสตราจารย์ ดร. คมกฤษณ์ ชูเรือง)

(ผู้ช่วยศาสตราจารย์ ดร.พัฒนพงษ์ วันจันทิก)

อาจารย์ที่ปรึกษาวิทยานิพนธ์รอง

.....

(.....)

..... กรรมการ

(ผู้ช่วยศาสตราจารย์ ดร.ทรงฤทธิ์ กิตติศรีวรพันธุ์)

..... กรรมการ

(ผู้ช่วยศาสตราจารย์ ดร.ชาญวิธ สุวรรณพงศ์)

..... กรรมการ

(รองศาสตราจารย์ สุทธิภัทร ศรีสุข)

คณะวิศวกรรมศาสตร์ มหาวิทยาลัยนครพนม อนุมัติให้บัณฑิตวิทยานิพนธ์ฉบับนี้ สำหรับการศึกษา ตาม
หลักสูตรปริญญาวิศวกรรมศาสตรบัณฑิต สาขาวิชาวิศวกรรมคอมพิวเตอร์

.....

(ผู้ช่วยศาสตราจารย์ ดร.บัณฑิต บุญขาว)

คณบดีคณะวิศวกรรมศาสตร์

ขอรับรองว่าโครงการนี้มาจากการศึกษาของนักศึกษาเอง และได้แสดงความขอบคุณต่อบุคคลที่มีส่วน
ช่วยเหลือแล้ว

ลงชื่อ.....

(ผู้ช่วยศาสตราจารย์ ดร. คมกฤษณ์ ชูเรือง)

อาจารย์ที่ปรึกษาวิทยานิพนธ์หลัก

ลงชื่อ.....

(นางสาว ปิยะพร แสงพรหมขารี)

นักศึกษา

ข้าพเจ้าขอรับรองว่าโครงการนี้ไม่เคยเป็นส่วนหนึ่งในการอนุมัติปริญญาในระดับใดมาก่อน และไม่ได้ถูกใช้
ในการยื่นขออนุมัติปริญญาในขณะนี้

ลงชื่อ.....

(นางสาว ปิยะพร แสงพรหมชาลี)

นักศึกษา

ชื่อเรื่อง	ระบบอ่านค่ามาตรน้ำอเนกประสงค์อัตโนมัติโดยใช้เทคนิคการประมวลผลภาพ
	และการเรียนรู้เชิงลึก
ผู้วิจัย	ปิยะพร แสงพรหมขารี
ปริญญา	วิศวกรรมศาสตรบัณฑิต
ปีการศึกษา	2568
อาจารย์ที่ปรึกษา	ผู้ช่วยศาสตราจารย์ ดร. คมกฤษณ์ ชูเรือง

บทคัดย่อ

โครงงานนี้มุ่งพัฒนาระบบอ่านค่าเกจนาฬิกาของมิเตอร์น้ำ โดยประยุกต์ใช้กรอบสถาปัตยกรรมเชิงลำดับชั้น (Layered AI-based Meter Reading Framework) เพื่อแปลงค่าการอ่านจากหน้าปัดมิเตอร์ให้อยู่ในรูปแบบข้อมูลดิจิทัล ระบบถูกออกแบบภายใต้เฟรมเวิร์กหลักเพียงหนึ่งเดียว ซึ่งประกอบด้วย 4 โมดูลหลัก ได้แก่ Data Acquisition Module สำหรับรับภาพจากกล้องและเตรียมข้อมูลเข้าสู่กระบวนการประมวลผล Detection Module ซึ่งใช้โมเดล YOLOv8 ภายใต้แนวคิด Object Detection เพื่อตรวจจับตำแหน่งของดิจิทัลสตริปและหน้าปัดเข็ม Recognition Module ที่ประกอบด้วยโมเดล Convolutional Neural Network (CNN) สำหรับจำแนกตัวเลขดิจิทัล และโมเดล Angle-based Regression สำหรับคำนวณตำแหน่งเข็มโดยอาศัยหลักการทางตรีโกณมิติ และ Post-processing Module สำหรับการประมวลผลภาพเพิ่มเติม เช่น การแปลงภาพเป็นระดับสีเทา การปรับความคมชัดของภาพ และการคำนวณค่ามุมเพื่อแปลงตำแหน่งเข็มให้เป็นค่าปริมาณการใช้น้ำในรูปแบบตัวเลข

ระบบถูกพัฒนาในรูปแบบ Web Application โดยใช้เฟรมเวิร์ก Django ภายใต้แนวคิด Thin Client Architecture ซึ่งรองรับการสื่อสารผ่าน REST API และสามารถบูรณาการทำงานร่วมกับระบบ Smart Home หรือ Internet of Things (IoT) ได้ โดยไม่จำเป็นต้องมีการเปลี่ยนแปลงอุปกรณ์มิเตอร์น้ำเดิม

ผลการทดลองแสดงให้เห็นว่าโมเดลจำแนกตัวเลขมีความแม่นยำเฉลี่ยประมาณ 94.7–95% โมเดล Transition มีค่า Validation Accuracy เท่ากับ 94.65% และโมเดลทำนายมุมของเข็มมีความแม่นยำ 96% ภายในช่วงความคลาดเคลื่อน ± 5 องศา ขณะที่ระบบโดยรวมแบบ End-to-End มีอัตราความสำเร็จมากกว่า 82% ผลลัพธ์ดังกล่าวสะท้อนให้เห็นว่าระบบที่พัฒนาขึ้นสามารถช่วยลดข้อผิดพลาดจากการอ่านค่าด้วยมนุษย์ เพิ่มประสิทธิภาพในการจัดเก็บและจัดการข้อมูล และมีศักยภาพในการนำไปประยุกต์ใช้งานจริงในระบบบริหารจัดการน้ำอัจฉริยะ รวมถึงระบบ Internet of Things (IoT) ในอนาคต

คำสำคัญ : การประมวลผลภาพ, ปัญญาประดิษฐ์, การตรวจจับวัตถุ, YOLO, มิเตอร์น้ำ, Smart Home

Title	Automatic Analog Water Meter Reading using Deep Learning and Image Processing Techniques
Author	Piyaporn Sangpromcharee
Degree	Bachelor of Engineering
Academic Year	2025
Thesis Advisor	Assistant Professor Dr. Komkrit Chooruang

ABSTRACT

This project aims to develop an automated system for reading analog water meter gauges by applying a Layered AI-based Meter Reading Framework to convert meter dial readings into digital data. The objective is to reduce human reading errors and enable efficient digital monitoring of water consumption.

The proposed system is designed as a single framework consisting of four main modules. The Data Acquisition Module captures images from a camera and prepares the data for further processing. The Detection Module, based on the YOLOv8 object detection model, identifies the locations of the digital strip and pointer dial on the meter face.

The Recognition Module employs a Convolutional Neural Network (CNN) to classify digital numbers and an angle-based regression model to estimate the pointer position using trigonometric principles. In addition, a Post-processing Module performs further image processing operations such as grayscale conversion, contrast enhancement, and angle calculation to transform the detected pointer position into numerical water consumption values.

The system is implemented as a web application using Django under a Thin Client Architecture, supporting communication via REST API. This architecture enables seamless integration with Smart Home and Internet of Things (IoT) systems without requiring modifications to existing water meters.

Experimental results show that the digit classification model achieves an average accuracy of 94.7–95%, the transition model reaches a validation accuracy of 94.65%, and the pointer angle prediction model achieves 96% accuracy within ± 5 degrees. The overall end-to-end system achieves a success rate of over 82%.

These results demonstrate that the proposed system can effectively reduce human reading errors, improve data collection efficiency, and provide a practical solution for automated water meter monitoring in smart infrastructure environments.

Keywords: Image Processing, Artificial Intelligence, Object Detection, YOLO, Water Meter, Smart Home

กิตติกรรมประกาศ

โครงการนี้สำเร็จลุล่วงด้วยความกรุณาจาก ผู้ช่วยศาสตราจารย์ ดร. คมกฤษณ์ ชูเรือง
อาจารย์ที่ปรึกษา ซึ่งได้ให้คำแนะนำอย่างต่อเนื่อง รวมถึงสนับสนุนความรู้ทางวิชาการและข้อมูลที่สำคัญ
ต่อการดำเนินงานตลอดระยะเวลาโครงการ

ขอขอบพระคุณ คณะกรรมการสอบโครงการ ที่ได้ให้คำแนะนำและข้อเสนอแนะอันเป็นประโยชน์
อย่างยิ่งต่อการปรับปรุงและพัฒนาผลงานให้มีความสมบูรณ์ยิ่งขึ้น

ปิยะพร แสงพรหมขารี

สารบัญ

เรื่อง	หน้า
บทคัดย่อ	ก
ABSTRACT	ข
กิตติกรรมประกาศ	ง
สารบัญ	จ
สารบัญรูปภาพ	ช
สารบัญตาราง	ญ
บทที่ 1	1
บทนำ	1
1.1 ที่มาและความสำคัญของปัญหา	2
1.2 วัตถุประสงค์ของโครงการ	2
1.3 ขอบเขตของโครงการ	2
1.4 ประโยชน์ที่คาดว่าจะได้รับ	2
บทที่ 2	4
ทฤษฎีและงานวิจัยที่เกี่ยวข้อง	4
2.1 ทฤษฎีที่เกี่ยวข้อง	3
2.1.1 ระบบอ่านค่ามาตรน้ำ	3
2.1.2 เทคโนโลยีปัญญาประดิษฐ์และการประมวลผลภาพ	6
2.1.3 Artificial Intelligence (AI) และ Deep Learning	12
2.1.4 การตรวจจับวัตถุด้วย YOLO (You Only Look Once)	15
2.1.5 Web Application, Mobile WebView และ IoT Integration	24
2.1.6 การเทรนโมเดล (Model Training)	25
2.1.7 การประเมินผลโมเดล (Model Evaluation)	15
2.2 งานวิจัยที่เกี่ยวข้อง	17

บทที่ 3.....	25
วิธีการดำเนินการ	25
3.1 ภาพรวมการทำงาน	25
3.2 แนวทางการพัฒนาโครงการวิจัย	26
3.2.1 การวางแผนลำดับการดำเนินงาน.....	26
3.2.2 การกำหนดปัญหา.....	26
3.2.3 การวิเคราะห์ปัญหา	26
3.2.4 การศึกษาข้อมูลและเลือกเครื่องมือในการพัฒนา	26
3.2.5 การออกแบบโครงการ.....	28
บทที่ 4	55
4.1 ผลการทำงานของระบบ (System Results)	55
4.2 ผลการดำเนินงานของโมดูลปัญญาประดิษฐ์ (AI Module Results).....	55
4.2.1 การตรวจจับหน้าปัดเข็ม.....	55
4.2.2 การตรวจจับช่องตัวเลขดิจิทัล	59
4.2.3 โมเดลทำนายมุมเข็ม	62
4.2.4 ผลการฝึกโมเดล CNN จำแนกตัวเลข.....	64
4.2.5 ผลการฝึกโมเดล Transition.....	67
บทที่ 5	79
บรรณานุกรม.....	94
ภาคผนวก	95
ภาคผนวก ก ตัวอย่างผลการตรวจจับมิเตอร์น้ำจากระบบ AquaRead	96
ภาคผนวก ข โค้ดใช้งานระบบ (Deployment / Application)	90

สารบัญรูปภาพ

รูป	หน้า
รูปภาพที่ 1 ภาพจริงของเจ้าหน้าที่จดคำมิตอร์	3
รูปภาพที่ 2 ขั้นตอนการประมวลผลภาพเบื้องต้น.....	4
รูปภาพที่ 3 ตัวอย่างการตรวจจับและจับคู่จุดลักษณะ (Feature Matching)	5
รูปภาพที่ 4 แสดงโครงสร้างพื้นฐานของโครงข่ายประสาทเทียมแบบคอนโวลูชัน.....	6
รูปภาพที่ 5 ตัวอย่างการทำงานของชั้น Convolution โดยใช้ฟิลเตอร์ (Filter) ขนาด 3x3.....	6
รูปภาพที่ 6 การใช้ Filter 3x3 ในการตรวจจับขอบแนวตั้ง.....	7
รูปภาพที่ 7 แสดงการทำงานของ Stride และ Feature Map.....	7
รูปภาพที่ 8 แสดงตัวอย่างการใช้ Zero-Padding รอบภาพอินพุต	8
รูปภาพที่ 9 แสดงตัวอย่างการทำ Max Pooling	8
รูปภาพที่ 10 ตัวอย่างโครงสร้างการดำเนินงานของข้อมูลจากมิตอร์นำสู่คลาวด์และผู้ใช้.....	14
รูปภาพที่ 11 ขั้นตอนการทำงานของระบบอ่านมิตอร์ ที่ติดตั้งบน ESP32	18
รูปภาพที่ 12 Web Interface ของ AI-on-the-edge-device แสดงผลการอ่านคำมิตอร์.....	18
รูปภาพที่ 13 มิตอร์น้ำแบบนาฬิกา มีทั้งกล่องตัวเลข (Digit Box) และหน้าปัดเข็ม (Pointer Meter)	19
รูปภาพที่ 14 แผนผังการทำงานของโมเดล (Pipeline Diagram).....	19
รูปภาพที่ 15 ตัวอย่างความหลากหลายของสภาวะภาพถ่ายมิตอร์ไฟฟ้า	20
รูปภาพที่ 16 ผลลัพธ์การตรวจจับตัวเลขด้วย YOLOV3.....	20
รูปภาพที่ 17 ขั้นตอนการทำงานของอัลกอริทึมอ่านมาตรวัด.....	21
รูปภาพที่ 18 โครงสร้างวิธีการอ่านค่ามาตรเข็มอัตโนมัติที่ประกอบด้วย YOLOX-DC	22
รูปภาพที่ 19 แสดงสถาปัตยกรรมของระบบอ่านค่ามาตรวัด.....	23
รูปภาพที่ 20 ตัวอย่างภาพมาตรวัดที่ใช้ในการทดสอบระบบในสภาพแวดล้อมจริง.....	34
รูปภาพที่ 21 แผนผังภาพรวมการทำงาน	25
รูปภาพที่ 22 ภาพรวมการทำงานของระบบ.....	29
รูปภาพที่ 23 แผนผังการเตรียมชุดข้อมูลในการฝึกโมเดล	30
รูปภาพที่ 24 ตัวอย่างไฟล์ข้อความ Label (.txt) ของ YOLO.....	31
รูปภาพที่ 25 ภาพตัวอย่างการ Annotate หน้าปัดเข็มทั้ง 3 ช่อง	32
รูปภาพที่ 26 ตัวอย่างผลลัพธ์ชุดข้อมูลภาพ(.jpg) และไฟล์ Label (.txt).....	33
รูปภาพที่ 27 ภาพตัวอย่างการ Annotate บริเวณช่องตัวเลขดิจิทัลทั้ง 5 หลัก	34
รูปภาพที่ 28 ตัวอย่างไฟล์ข้อความ Label (.txt) ของ YOLO สำหรับคลาส digital.....	34
รูปภาพที่ 29 ตัวอย่างภาพหน้าปัดมาตรวัดแบบเข็มที่ถูกครอบและปรับขนาด	35
รูปภาพที่ 30 ตัวอย่างการกำหนดจุดสำคัญ (Keypoint Annotation) บนภาพหน้าปัด.....	35
รูปภาพที่ 31 แสดงโครงสร้างของโมเดล CNN Pointer Regression ซึ่งใช้ Convolution	37
รูปภาพที่ 32 ตัวอย่างภาพตัวเลขดิจิทัลที่ถูกครอบและปรับขนาดก่อนใช้ในการฝึกโมเดล	39

รูปภาพที่ 33 ตัวอย่างโครงสร้างโพลเดอร์ของชุดข้อมูลตัวเลขหลัก (0–9 และ NaN).....	39
รูปภาพที่ 34 สถาปัตยกรรมของโมเดล Convolutional Neural Network (CNN).....	40
รูปภาพที่ 35 ตัวอย่างโค้ดที่ใช้สร้างสถาปัตยกรรมและคอมไพล์โมเดล Convolutional Neural Network (CNN).....	41
รูปภาพที่ 36 ตัวอย่างโค้ดที่ใช้สำหรับการฝึกโมเดล Convolutional Neural Network (CNN).....	42
รูปภาพที่ 37 ตัวอย่างคำสั่งในโปรแกรม FFmpeg สำหรับแยกเฟรมภาพจากวิดีโอ	43
รูปภาพที่ 38 ตัวอย่างโค้ดภาษา Python สำหรับครอบเฉพาะบริเวณช่องตัวเลขของมิเตอร์น้ำ	44
รูปภาพที่ 39 ตัวอย่างภาพตัวเลขในช่วงเปลี่ยนหลัก 9→0 ที่ใช้ในการฝึกโมเดล Transition	44
รูปภาพที่ 40 ตัวอย่างโครงสร้างโพลเดอร์ของชุดข้อมูลที่กำลังเลื่อน (Transition Dataset)	45
รูปภาพที่ 41 แสดงโครงสร้างโมเดล CNN Pair / Transition Model ที่ใช้ในการจำแนกการเปลี่ยนผ่านของตัวเลข	45
รูปภาพที่ 42 ตัวอย่างโค้ดการฝึกโมเดล CNN Transition / Pair Model.....	46
รูปภาพที่ 43 ตัวอย่างโค้ดสำหรับการประเมินความแม่นยำของโมเดลบนชุดข้อมูลฝึก.....	47
รูปภาพที่ 44 สถาปัตยกรรมการออกแบบ Web Application.....	49
รูปภาพที่ 45 ตัวอย่างหน้าจอหลัก (Home Screen) ของระบบ AquaRead.....	62
รูปภาพที่ 46 ตัวอย่างผลการตรวจจับภาพมิเตอร์น้ำจากชุดข้อมูลฝึก (Training Batch).....	58
รูปภาพที่ 47 ตัวอย่างผลการตรวจจับภาพมิเตอร์น้ำจากชุดข้อมูลตรวจสอบ	58
รูปภาพที่ 48 กราฟผลการฝึกโมเดล YOLOv8 สำหรับการตรวจจับช่องตัวเลขดิจิทัล.....	70
รูปภาพที่ 49 ตัวอย่างผลการตรวจจับช่องตัวเลขดิจิทัลจากชุดข้อมูลฝึก	61
รูปภาพที่ 50 ตัวอย่างผลการตรวจจับช่องตัวเลขดิจิทัลจากชุดข้อมูลตรวจสอบ.....	61
รูปภาพที่ 51 กราฟเปรียบเทียบค่าการทำนายมุมของเข็ม กับค่าจริง	74
รูปภาพที่ 52 (ก) กราฟแสดงค่าการสูญเสีย (Loss) ของชุดข้อมูลฝึกและชุดตรวจสอบ.....	76
รูปภาพที่ 53 (ก) กราฟความแม่นยำของโมเดลระหว่างการฝึกและการตรวจสอบ	67
รูปภาพที่ 54 Confusion Matrix ของผลการจำแนกภาพในชุดข้อมูลตรวจสอบ	68
รูปภาพที่ 55 การทำนายค่าตัวเลขก่อนการใช้ Transition-State Handling	69
รูปภาพที่ 56 ความต่อเนื่องของค่าตัวเลขก่อนและหลังการใช้ Transition-State Handling.....	71
รูปภาพที่ 57 หน้าจอเริ่มต้น (Splash Screen) และหน้าจอเข้าสู่ระบบ.....	72
รูปภาพที่ 58 หน้าหลักของระบบ AquaRead	73
รูปภาพที่ 59 หน้าจอเมนูบริการของระบบ AquaRead.....	73
รูปภาพที่ 60 หน้าจอการอัปโหลดหรือถ่ายภาพมิเตอร์น้ำ	74
รูปภาพที่ 61 หน้าจอแสดงผลการตรวจจับมิเตอร์น้ำและผลการคำนวณปริมาณการใช้น้ำ	74
รูปภาพที่ 62 หน้าจอแสดงผลรายละเอียดการอ่านค่ามิเตอร์น้ำ.....	75
รูปภาพที่ 63 หน้าจอประวัติการอ่านค่าและการแจ้งเตือนล่าสุด.....	76
รูปภาพที่ 64 หน้าจอโปรไฟล์และการตั้งค่าของผู้ใช้งาน	76
รูปภาพที่ 65 หน้าเว็บหลักของระบบ AquaRead แสดงส่วนต้อนรับผู้ใช้และปุ่มเข้าสู่ระบบ/สมัครสมาชิก	66
รูปภาพที่ 66 หน้าเข้าสู่ระบบ (Login Page) ของผู้ใช้งานภายในระบบ.....	66
รูปภาพที่ 67 หน้าอัปโหลดภาพมิเตอร์ (AI Detection Page) ซึ่งผู้ใช้สามารถเลือกแหล่งข้อมูลได้ทั้งจาก	67

รูปภาพที่ 68	หน้าเว็บแสดงผลการอ่านค่ามาตรวัดน้ำจริงจากระบบ AquaRead.....	67
รูปภาพที่ 69	หน้ารายละเอียดผลลัพธ์ (Results Page).....	67
รูปภาพที่ 70	หน้าจอประวัติการอ่านค่าและการแจ้งเตือนล่าสุด.....	69
รูปภาพที่ 71	หน้าจอโปรไฟล์และการตั้งค่าของผู้ใช้งาน	69
รูปภาพที่ 72	ผลการตรวจจับมิเตอร์ที่มีโครงสร้างต่างจากโมเดลที่ฝึก.....	73
รูปภาพที่ 1	การทำนายค่าตัวเลขก่อนการใช้ Transition-State.....	80
รูปภาพที่ 74	ความต่อเนื่องของค่าตัวเลขหลังการใช้ Transition-State.....	80
รูปภาพที่ 75	หน้าจอเริ่มต้น	82
รูปภาพที่ 76	หน้าหลักระบบ.....	83
รูปภาพที่ 77	หน้าจอเมนูบริการของระบบ.....	83
รูปภาพที่ 78	หน้าจออัปโหลดหรือถ่ายภาพ	84
รูปภาพที่ 79	หน้าเว็บแสดงผลการตรวจจับมิเตอร์น้ำ	84
รูปภาพที่ 80	หน้าจอแสดงผลรายละเอียด	85
รูปภาพที่ 81	หน้าจอประวัติการอ่านค่า.....	86
รูปภาพที่ 82	หน้าจอโปรไฟล์	86
รูปภาพที่ 83	ตัวอย่างกรณีที่คุณภาพของภาพส่งผลต่อความแม่นยำของระบบ	90
รูปภาพที่ 84	ผลการตรวจจับมิเตอร์น้ำที่หน้าปัดแตกต่างจากข้อมูลที่ใช้ฝึก.....	91

สารบัญตาราง

ตาราง	หน้า
ตารางที่ 1 พัฒนาการของอัลกอริทึม YOLO (You Only Look Once).....	10
ตารางที่ 2 สรุปประสิทธิภาพรวมของระบบ AquaRead	61

บทที่ 1

บทนำ

1.1 ที่มาและความสำคัญของปัญหา

ในปัจจุบัน มิเตอร์น้ำที่ใช้กันทั่วไปตามบ้านเรือน หน่วยงานรัฐ และสถานประกอบการส่วนใหญ่ยังเป็นแบบอนาล็อกที่แสดงผลด้วยหน้าปัดเข็มและตัวเลขกลไกแบบหมุน (rolling digits) การอ่านค่าจึงทำโดยมนุษย์เป็นหลัก การอ่านค่าจากหลักพันถึงหลักหน่วยบนช่องตัวเลข และพิจารณาทศนิยมจากสเกลหรือเข็มสีแดงแล้วจดบันทึกหรือถ่ายภาพประกอบ แม้บางพื้นที่เริ่มใช้มิเตอร์อิเล็กทรอนิกส์/อัลตราโซนิก หรือระบบ AMR/AMI ที่ส่งข้อมูลอัตโนมัติผ่านเครือข่าย แต่การใช้งานยังมีสัดส่วนไม่มากด้วยข้อจำกัดด้านต้นทุนอุปกรณ์ การติดตั้ง และโครงสร้างพื้นฐานการสื่อสาร

อย่างไรก็ดี วิธีอ่านแบบเดิมมีข้อจำกัดสำคัญ ได้แก่ ความเสี่ยงต่อความคลาดเคลื่อนจากมนุษย์ (Human Error) เช่น อ่านสลับหลัก ตัดสินใจผิดเมื่อเลขใกล้เปลี่ยนรอบ (9→0) หรือเมื่อเข็มอยู่กึ่งกลางสเกล ตลอดจนสภาพหน้างานที่ไม่เอื้อ เช่น แสงย้อน เงา ฝุ่น คราบน้ำ กระดาษฟุ้ง และมุมมองเอียง ซึ่งลดทัศนวิสัยในการอ่าน นอกจากนี้ กระบวนการบันทึกค่าลงแบบฟอร์มหรือระบบภายหลังยังสร้างความล่าช้าและโอกาสผิดพลาด ทำให้ข้อมูลไม่พร้อมต่อการวิเคราะห์แบบใกล้เคียงเรียลไทม์ ส่งผลให้การตรวจจับความผิดปกติ การรั่วไหล การควบคุมค่าใช้จ่าย และการวางแผนทรัพยากรทำได้ไม่ทันทั่วถึง

ดังนั้น โครงการนี้จึงมุ่งเสนอแนวทางที่ทำงานร่วมกับมิเตอร์อนาล็อกเดิมโดยตรง ด้วยเทคโนโลยีประมวลผลภาพ (Image Processing) ผสานปัญญาประดิษฐ์ (AI) เพื่ออ่านค่ามิเตอร์อัตโนมัติอย่างแม่นยำและตรวจสอบได้ โดยระบบจะตรวจจับกรอบตัวเลข/เข็ม แยกส่วนประกอบภาพ จำแนกตัวเลขรวมถึงกรณีที่ตัวเลขกำลังเปลี่ยน (transition) คำนวณค่าจากเข็มเชิงมุม จากนั้นประมวลผลเพื่อตรวจสอบความสอดคล้องระหว่างตัวเลขกับเข็ม พร้อมจัดเก็บหลักฐานภาพทุกครั้ง แนวทางนี้ช่วยลดภาระและข้อผิดพลาดของมนุษย์ ทำให้ข้อมูลเข้าสู่ระบบได้ใกล้เคียงเรียลไทม์ รองรับการใช้วิเคราะห์ประวัติและการแจ้งเตือนความผิดปกติ และพร้อมเชื่อมต่อสู่ระบบ Smart Home/IoT โดยยังยึดหลัก “ติดตั้งทับของเดิม ไม่ต้องเปลี่ยนมิเตอร์” เพื่อลดต้นทุนและเพิ่มโอกาสการยอมรับใช้งานในทางปฏิบัติ

1.2 วัตถุประสงค์ของโครงการ

- 1) เพื่อพัฒนาระบบที่สามารถอ่านค่ามิเตอร์น้ำแบบอนาล็อกได้โดยอัตโนมัติ
- 2) เพื่อใช้เทคนิค Image Processing และ AI ในการตรวจจับตำแหน่งเข็มของมิเตอร์
- 3) เพื่อแปลงข้อมูลจากการอ่านค่าเข็มให้เป็นตัวเลขดิจิทัลที่สามารถนำไปใช้งานต่อได้
- 4) เพื่อออกแบบระบบที่สามารถเชื่อมต่อกับ Web Application หรือระบบ IoT ได้อย่างสะดวก

1.3 ขอบเขตของโครงการ

- 1) ใช้กล้องถ่ายภาพหน้าปัดของมิเตอร์น้ำอนาล็อกจากมาตรฐาน เช่น SPP MGS 15 m³
- 2) ระบบสามารถตรวจจับเข็มหมุนในหน้าปัดย่อยทั้ง 3 วง และแปลงมุมเข็มเป็นตัวเลข
- 3) ใช้โมเดล YOLOv8 ในการตรวจจับเข็มของมิเตอร์
- 4) พัฒนาระบบต้นแบบ (Prototype) สำหรับอ่านค่าและแสดงผลผ่าน Web Application
- 5) ไม่ครอบคลุมมิเตอร์แบบดิจิทัลเต็มรูปแบบหรือมิเตอร์ประเภทอื่น เช่น มิเตอร์ไฟฟ้า

1.4 ประโยชน์ที่คาดว่าจะได้รับ

- 1) ลดข้อผิดพลาดจากการอ่านค่าด้วยมนุษย์
- 2) เพิ่มความสะดวกในการจัดเก็บและวิเคราะห์ข้อมูลการใช้น้ำ
- 3) สามารถนำไปใช้งานร่วมกับระบบ Smart Home หรือ IoT ได้ทันที
- 4) ประยุกต์ใช้งานกับมิเตอร์น้ำอนาล็อกเดิมได้โดยไม่ต้องเปลี่ยนอุปกรณ์

บทที่ 2

ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

ในบทนี้จะกล่าวถึงงานวิจัยและองค์ความรู้ที่เกี่ยวข้องกับโครงการระบบอ่านค่ามาตรน้ำโดยใช้เทคโนโลยี Image Processing และปัญญาประดิษฐ์ (AI) ซึ่งครอบคลุมตั้งแต่แนวคิดการอ่านค่ามาตรน้ำแบบเดิม การประยุกต์ใช้ Image Processing และ Deep Learning การตรวจนับวัตถุด้วย YOLO แนวทางการพัฒนา Web Application และ IoT รวมถึงรายละเอียดเชิงลึกในกระบวนการฝึกสอนโมเดล (Model Training) และการประเมินผล (Evaluation) เพื่อให้โครงการมีความสมบูรณ์และสามารถใช้งานได้จริง

2.1 ทฤษฎีที่เกี่ยวข้อง

2.1.1 ระบบอ่านค่ามาตรน้ำ

2.1.1.1 การอ่านค่าด้วยแรงงานคน (Manual Reading)

การอ่านค่ามาตรน้ำโดยใช้แรงงานคนเป็นวิธีดั้งเดิมที่ใช้กันมานาน เจ้าหน้าที่ต้องเดินตรวจตามบ้านหรืออาคารและจดบันทึกค่าจากมาตรน้ำลงสมุดหรืออุปกรณ์พกพา แม้วิธีนี้จะมีต้นทุนการลงทุนต่ำแต่ก็มีข้อเสียคือ ใช้แรงงานจำนวนมากเสี่ยงต่อความผิดพลาดจากมนุษย์ เช่น อ่านตัวเลขผิด หรือเขียนบันทึกผิด ไม่สามารถตรวจสอบย้อนหลังได้อย่างสะดวก หากเกิดข้อโต้แย้งต้องย้อนกลับไปดูเอกสารหรือรูปถ่าย (ถ้ามี) และมีข้อจำกัดในการเก็บและจัดการข้อมูล เพราะข้อมูลอยู่ในรูปแบบกระดาษหรือไฟล์แยกทำให้การรวมผลหรือสรุปผลทำได้ยาก ไม่เหมาะกับพื้นที่ขนาดใหญ่หรือมีจำนวนมิเตอร์มาก เช่น หมู่บ้านจัดสรรหรืออาคารชุดหลายหลัง เพราะใช้เวลานาน เสี่ยงต่อการสูญหายของข้อมูลหรือการบันทึกซ้ำซ้อน เมื่อมีพนักงานหลายคนทำงานพร้อมกันในพื้นที่ต่าง ๆ และสุดท้ายคือ ไม่มีระบบตรวจนับหรือแจ้งเตือนความผิดปกติอัตโนมัติ เช่น การใช้น้ำผิดปกติหรือมิเตอร์ชำรุด



รูปภาพที่ 2 ลักษณะการจดมิเตอร์แบบmanual

2.1.1.2 การอ่านค่าแบบกึ่งอัตโนมัติ (Semi-Automatic Reading)

วิธีนี้ใช้เทคโนโลยีเข้ามาช่วย เช่น ให้ผู้ใช้งานถ่ายรูปมาตรน้ำแล้วส่งไปให้เจ้าหน้าที่ตรวจสอบหรือใช้กล้องติดตั้งถาวรแล้วส่งข้อมูลภาพมายังศูนย์กลาง แม้จะลดงานของเจ้าหน้าที่ลง แต่ยังคงพึ่งพามนุษย์ในการตีความและบันทึกค่า


2.1.1.3 การอ่านค่าแบบอัตโนมัติ (Automatic Meter Reading: AMR)

AMR ใช้เทคโนโลยีเซนเซอร์หรือ IoT ทำให้สามารถอ่านค่าได้โดยอัตโนมัติ และส่งข้อมูลเข้าสู่ระบบกลางทันที ช่วยให้ได้ข้อมูลแบบเรียลไทม์ ลดแรงงาน และเพิ่มความถูกต้อง อย่างไรก็ตาม มาตรน้ำแบบอิเล็กทรอนิกส์ (Smart Meter) ยังมีราคาสูง ไม่แพร่หลาย โดยเฉพาะในครัวเรือนทั่วไป จึงเกิดแนวทางใหม่คือการนำ AI มาประมวลผลภาพจากมาตรน้ำกลไก (Analog/Digital Hybrid Meter) เพื่อแปลงเป็นค่าดิจิทัลแทน [1]

2.1.2 เทคโนโลยีปัญญาประดิษฐ์และการประมวลผลภาพ

2.1.2.1 การประมวลผลภาพ (Image Processing)

การประมวลผลภาพดิจิทัล (Image Processing) มีบทบาทสำคัญในขั้นตอนเตรียมข้อมูลก่อนส่งให้โมเดล AI ตัวอย่างเทคนิคที่เกี่ยวข้อง ได้แก่ การแปลงภาพสีเป็นภาพขาวดำ (Grayscale) การทำ Threshold เพื่อแยกวัตถุออกจากพื้นหลัง การตรวจจับขอบ (Edge Detection) เช่น Canny Edge การปรับความสว่าง คอนทราสต์ และการลดสัญญาณรบกวน (Noise Reduction) การจัดแนวภาพ (Image Alignment) คือการทำให้ภาพอินพุตที่ถ่ายใหม่ตรงกับภาพอ้างอิง (Reference Image) โดยใช้เทคนิคการจับคู่คุณลักษณะ (Feature Matching) เช่น SIFT หรือ ORB เพื่อตรวจหาจุดเด่น แล้วนำมาคำนวณ Homography Transformation เพื่อปรับตำแหน่ง/หมุน/ยืดให้ตรงกับแม่แบบ ข้อดีคือทำให้ ROI (Region of Interest) เช่น ตัวเลขและเข็ม อยู่ในตำแหน่งที่แน่นอนในทุกภาพ ลดความผิดพลาดจากมุมมองหรือการเอียง ช่วยให้โมเดล AI ตรวจจับได้เสถียรมากขึ้นเทคนิคเหล่านี้ช่วยให้โมเดล AI สามารถโฟกัสที่ตัวเลขและเข็มได้ง่ายขึ้นลดผลกระทบจากสภาพแวดล้อม เช่น แสงจ้า เงา หรือฝุ่น




รูปภาพที่ 3 ขั้นตอนการประมวลผลภาพเบื้องต้น (a) ภาพต้นฉบับ (b) แปลงเป็นโทนขาวดำ (c) ทำ Threshold ด้วยวิธี CLAHE + Otsu เพื่อเน้นบริเวณตัวเลข/เข็มให้เด่นชัดก่อนเข้าสู่โมเดล AI

2.1.2.2 การจับคู่คุณลักษณะและการจัดแนวภาพ (Feature Matching & Homography Alignment)

การจับคู่คุณลักษณะ (Feature Matching) เป็นกระบวนการค้นหาจุดเด่น (keypoints) ที่สอดคล้องกันระหว่างภาพอินพุตและภาพอ้างอิง โดยใช้ตัวบรรยายลักษณะ (descriptors) เช่น SIFT, SURF หรือ ORB จากนั้นนำคู่จุดที่ตรงกันไปประเมินความน่าเชื่อถือด้วยวิธี RANSAC เพื่อคัดกรองจุดผิดพลาด และคำนวณเมทริกซ์การแปลงเชิงฉายภาพ (Homography, 3×3) เพื่อปรับมุมมองของภาพอินพุตให้ตรงกับภาพอ้างอิง (warp/rotate/scale) [2]

วิธีนี้ทำให้บริเวณสนใจ (ROI) เช่น กล้องตัวเลขและหน้าปัดเข็ม อยู่ในตำแหน่งคงที่ ลดผลกระทบจากมุมกล้อง การเอียง และความแปรปรวนของสเกล ซึ่งเอื้อต่อการตรวจจับด้วย YOLO และการจำแนกด้วย CNN ให้มีความเสถียรและแม่นยำมากขึ้น




รูปภาพที่ 4 ตัวอย่างการตรวจจับและจับคู่จุดลักษณะ (Feature Matching) ระหว่างภาพต้นฉบับและภาพเป้าหมาย เส้นสีแดงแสดงคู่จุดที่มีความคล้ายคลึงกันซึ่งใช้ในการคำนวณ Homography เพื่อจัดแนวภาพ

2.1.3 Artificial Intelligence (AI) และ Deep Learning

AI โดยเฉพาะ Deep Learning ได้เข้ามามีบทบาทสำคัญในงานด้าน Computer Vision โดยโมเดลที่นิยมใช้คือ Convolutional Neural Network (CNN) ซึ่งมีโครงสร้างคล้ายสมองมนุษย์ สามารถเรียนรู้คุณลักษณะ (Features) จากภาพในหลายระดับ เช่น เส้น ขอบ รูปทรง ไปจนถึงรูปแบบซับซ้อนอย่างตัวเลขหรือสัญลักษณ์

2.1.3.1 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) เป็นโครงข่ายประสาทเทียมเชิงลึก (Deep Neural Network) ที่ถูกออกแบบมาโดยเฉพาะสำหรับประมวลผลข้อมูลเชิงภาพ (Image Data) ซึ่งมีโครงสร้างเลียนแบบกระบวนการมองเห็นของสมองมนุษย์ (Visual Cortex) CNN สามารถเรียนรู้คุณลักษณะของภาพ (Features) โดยอัตโนมัติผ่านการคำนวณแบบการคอนโวลูชัน (Convolution Operation) แทนการป้อนค่าพิกเซลทั้งหมดเหมือนโครงข่ายทั่วไป ทำให้สามารถลดจำนวนพารามิเตอร์และเพิ่มประสิทธิภาพได้มากกว่า




รูปภาพที่ 5 แสดงโครงสร้างพื้นฐานของโครงข่ายประสาทเทียมแบบคอนโวลูชัน (Convolutional Neural Network)

โครงสร้างพื้นฐานของ CNN ประกอบด้วยเลเยอร์หลักดังนี้

1) Convolutional Layer

เป็นชั้นหลักที่ใช้ Kernel หรือ Filter ขนาดเล็ก (เช่น 3×3 หรือ 5×5) ทำหน้าที่เลื่อนผ่านภาพอินพุตเพื่อคำนวณผลการคอนโวลูชันในแต่ละตำแหน่ง ผลลัพธ์ที่ได้จะเป็น Feature Map ซึ่งแสดงลักษณะสำคัญของภาพ เช่น ขอบ (Edge), เส้น (Line) หรือรูปร่าง (Shape)



รูปภาพที่ 6 ตัวอย่างการทำงานของชั้น Convolution โดยใช้ฟิลเตอร์ (Filter) ขนาด 3×3 เลื่อนผ่านภาพอินพุตเพื่อเน้นลักษณะขอบของภาพ และได้ผลลัพธ์เป็น Feature Map ที่แสดงบริเวณที่มีการเปลี่ยนแปลงของค่าเข้มภาพอย่างชัดเจน

1.1) ตัวอย่างของ Filter


ในภาพตัวอย่าง แสดงให้เห็นว่าการนำ Filter ที่มีค่า +1 และ -1 วางคร่อมภาพ จะช่วยเน้นขอบแนวตั้งหรือแนวนอน ซึ่งเป็นกระบวนการดึงลักษณะพื้นฐานของภาพออกมาเพื่อให้โมเดลเรียนรู้ต่อไป

1	-1	-1
-1	1	-1
-1	-1	1

รูปภาพที่ 7 การใช้ Filter 3x3 ในการตรวจจับขอบแนวตั้ง โดยค่าบวก (1) และค่าลบ (-1) ใช้แยกความแตกต่างของความเข้มระหว่างพื้นที่สองฝั่ง ทำให้ Feature Map ที่ได้มีค่าสูงในบริเวณที่เป็นขอบภาพ


1.2) Stride และ Padding

- Stride คือจำนวนพิกเซลที่ฟิลเตอร์เลื่อนไปในแต่ละครั้ง หากตั้งค่า stride = 1 หมายถึงฟิลเตอร์เลื่อนทีละ 1 พิกเซล ทำให้ได้ Feature Map ขนาดใหญ่ ส่วน stride = 2 จะทำให้ขนาดลดลงแต่ประมวลผลเร็วขึ้น



รูปภาพที่ 8 แสดงการทำงานของ Stride และ Feature Map เมื่อ Stride = 1 โดยฟิลเตอร์เลื่อนทีละ 1 พิกเซล ผลลัพธ์คือ Feature Map ที่มีขนาดใกล้เคียงกับภาพต้นฉบับและสามารถตรวจจับรายละเอียดได้ครบถ้วน


- Padding คือการขยายขอบของภาพอินพุตด้วยศูนย์ (Zero-Padding) เพื่อคงขนาดของ Feature Map ให้เท่ากับภาพต้นฉบับและป้องกันการสูญเสียข้อมูลบริเวณขอบภาพ



รูปภาพที่ 9 แสดงตัวอย่างการใช้ Zero-Padding รอบภาพอินพุต เพื่อให้ฟิลเตอร์สามารถครอบคลุมบริเวณขอบภาพได้ครบ ผลลัพธ์ที่ได้คือ Feature Map ที่ยังคงขนาดใกล้เคียงกับภาพต้นฉบับ พร้อมรักษาข้อมูลบริเวณขอบภาพไว้ครบถ้วน

1.3) Max Pooling

Max Pooling เป็นกระบวนการลดขนาด (Downsampling) ของ Feature Map โดยเลือกค่าพิกเซลที่มีค่าสูงสุดในแต่ละบริเวณย่อย (window) เพื่อคงเฉพาะลักษณะที่เด่นที่สุดของภาพไว้ กระบวนการนี้ช่วยลดจำนวนพารามิเตอร์ ลดการซ้ำซ้อนของข้อมูล และทำให้โมเดลทนทานต่อการเลื่อนหรือหมุนของภาพมากขึ้น



รูปภาพที่ 10 แสดงตัวอย่างการทำ Max Pooling ด้วยขนาดหน้าต่าง 2x2 และค่าStride = 2 โดยเลือกค่ามากที่สุดแต่ละช่องย่อย (เช่น 8, 7, 6, 4) เพื่อสร้าง Feature Map ที่ขนาดเล็กลงแต่ยังคงลักษณะสำคัญของภาพ

2) Activation Function (ReLU)

ใช้ฟังก์ชันไม่เชิงเส้น (Non-linearity) เช่น Rectified Linear Unit (ReLU) ให้กับโครงข่าย โดยนิยามใช้ฟังก์ชัน Rectified Linear Unit (ReLU) ซึ่งมีสมการ $f(x) = \max(0, x)$

ทำหน้าที่กรองค่าลบออกจาก Feature Map ช่วยให้โมเดลเรียนรู้ได้รวดเร็วขึ้นและเพื่อเพิ่มความสามารถในการเรียนรู้ลักษณะที่ซับซ้อน ลดปัญหาการเกิดค่าลบ และช่วยให้โครงข่ายลู่เข้าได้เร็วขึ้น

3) Pooling Layer

หลังจากผ่าน Convolution และ ReLU แล้ว ข้อมูลจะเข้าสู่ Pooling Layer เพื่อย่อขนาดของ feature map โดยเลือกค่าสูงสุดในแต่ละบริเวณ (Max Pooling) หรือค่าเฉลี่ย (Average Pooling) เพื่อลดจำนวนพารามิเตอร์ ลดการซ้ำซ้อนของข้อมูล และเพิ่มความทนทานต่อการเลื่อนตำแหน่งของวัตถุในภาพ

4) Fully Connected Layer (FC Layer)

หลังจากผ่านการดึงลักษณะจากหลายชั้นของ Convolution และ Pooling แล้ว ผลลัพธ์จะถูกแปลงให้อยู่ในรูปเวกเตอร์และป้อนเข้าสู่ชั้น Fully Connected เพื่อทำการจำแนก (Classification) หรือทำนายค่า (Regression)

5) Output Layer


ชั้นสุดท้ายของ CNN ใช้ฟังก์ชัน Activation ที่เหมาะสม เช่น Softmax (สำหรับงานจำแนกหลายคลาส) หรือ Sigmoid (สำหรับงานจำแนกสองคลาส) เพื่อให้ผลลัพธ์เป็นค่าความน่าจะเป็นของแต่ละคลาส ในขั้นตอนการเรียนรู้ CNN จะทำการปรับค่าน้ำหนักของ filter ผ่านกระบวนการ Backpropagation โดยใช้ตัววัดความผิดพลาด (Loss Function) เช่น Categorical Cross-Entropy และตัวปรับพารามิเตอร์ (Optimizer) เช่น Adam หรือ SGD เพื่อให้ผลลัพธ์การทำนายมีความแม่นยำสูงสุด

จุดเด่นของ CNN คือความสามารถในการ “เรียนรู้คุณลักษณะเชิงลำดับชั้น (Hierarchical Feature Learning)” โดยชั้นแรก ๆ จะเรียนรู้ลักษณะพื้นฐาน เช่น ขอบและมุม ขณะที่ชั้นลึก ๆ จะเรียนรู้ลักษณะระดับสูง เช่น รูปแบบของวัตถุหรือตัวเลข ซึ่งเหมาะสมอย่างยิ่งสำหรับงานด้าน การจดจำภาพ (Image Recognition) และ การรู้จำตัวเลขดิจิทัล (Digit Recognition) [3]

2.1.4 การตรวจจับวัตถุด้วย YOLO (You Only Look Once)

YOLO (You Only Look Once) เป็นอัลกอริทึมการตรวจจับวัตถุ (Object Detection) ที่ได้รับความนิยมสูง เนื่องจากสามารถประมวลผลได้รวดเร็วและแม่นยำ โดยใช้หลักการแบ่งภาพออกเป็นกริด (Grid) แล้วทำนาย Bounding Box และคลาสของวัตถุทั้งหมดในขั้นตอนเดียว ทำให้แตกต่างจากอัลกอริทึมรุ่นก่อน ๆ ที่มักต้องใช้หลายขั้นตอน เช่น Region Proposal และ Classification แยกกัน

จุดเด่นของ YOLO คือสามารถตรวจจับวัตถุหลายชนิดในภาพเดียวได้แบบเรียลไทม์ (Real-time Detection) จึงถูกนำไปใช้ในงานหลากหลาย ตั้งแต่การตรวจจับคน รถยนต์ ไปจนถึงการประยุกต์ในงานอุตสาหกรรมและ IoT [4]




รูปภาพที่ 11 การเปรียบเทียบกระบวนการตรวจจับวัตถุแบบ Two-Stage (Faster R-CNN) และ One-Stage (YOLO)

จะเห็นได้ว่า Two-Stage Detector มีขั้นตอน Region Proposal ก่อนการจำแนกประเภท ในขณะที่ YOLO ทำการตรวจจับและจำแนกภายในโครงข่ายเดียว ส่งผลให้มีความเร็วสูงกว่าและเหมาะสำหรับงานแบบ Real-Time

2.1.4.1 หลักการแบ่งภาพแบบ Grid System

YOLO แบ่งภาพอินพุตออกเป็นตาราง $S \times S$ Grid โดยแต่ละช่องของกริดจะรับผิดชอบในการทำนาย Bounding Box, Confidence Score และ Class Probability สำหรับวัตถุที่มีจุดศูนย์กลางอยู่ในช่องนั้น วิธีการนี้ช่วยให้โมเดลสามารถตรวจจับวัตถุหลายตำแหน่งได้พร้อมกัน



รูปภาพที่ 12 การแบ่งภาพอินพุตเป็นตาราง $S \times S$ ในโมเดล YOLO โดยแต่ละ Grid Cell ทำหน้าที่พยากรณ์ค่า (x, y, w, h) ค่าความเชื่อมั่น และประเภทของวัตถุ

2.1.4.2 สถาปัตยกรรมของ YOLOv8 (YOLOv8 Architecture)

YOLOv8 เป็นโมเดลตรวจจับวัตถุแบบ One-Stage Detector ที่พัฒนาภายใต้แนวคิดการประมวลผลภาพแบบ End-to-End โดยมีโครงสร้างหลักแบ่งออกเป็น 3 ส่วน ได้แก่ Backbone, Neck และ Detection Head ซึ่งทำงานร่วมกันเพื่อสกัดคุณลักษณะของภาพและพยากรณ์ตำแหน่งวัตถุอย่างมีประสิทธิภาพ

1) Backbone

Backbone ทำหน้าที่สกัดคุณลักษณะ (Feature Extraction) จากภาพอินพุต โดยใช้ชั้น Convolutional Neural Network หลายระดับเพื่อเรียนรู้ลักษณะเชิงพื้นที่ เช่น ขอบ (edges), รูปร่าง (shapes) และลวดลาย (patterns) ของวัตถุในภาพ

กระบวนการ Downsampling จะลดขนาดเชิงพื้นที่ของภาพลงในแต่ละระดับ ขณะเดียวกันเพิ่มจำนวน Feature Maps เพื่อให้โมเดลสามารถเรียนรู้คุณลักษณะเชิงลึกได้มากขึ้น ซึ่งช่วยเพิ่มความแม่นยำในการตรวจจับวัตถุที่มีลักษณะซับซ้อน

2) Neck

Neck มีหน้าที่รวมคุณลักษณะจากหลายระดับความลึก (Multi-scale Feature Aggregation) โดยใช้โครงสร้าง เช่น Feature Pyramid Network (FPN) และ Path Aggregation Network (PAN) เพื่อผสานข้อมูลจากชั้นล่างและชั้นบนของโมเดล

การรวมคุณลักษณะหลายสเกลช่วยให้ระบบสามารถตรวจจับวัตถุที่มีขนาดแตกต่างกันได้อย่างมีประสิทธิภาพ ซึ่งมีความสำคัญต่อการตรวจจับองค์ประกอบของมิเตอร์น้ำที่มีทั้งส่วนดิจิทัลขนาดเล็ก และหน้าปัดเข็มที่มีขนาดใหญ่กว่า

3) Detection Head

Detection Head เป็นส่วนที่ทำหน้าที่พยากรณ์ผลลัพธ์ขั้นสุดท้าย โดยจะคำนวณค่าพารามิเตอร์ของกรอบวัตถุ ได้แก่ ตำแหน่งจุดศูนย์กลาง (x, y) ความกว้างและความสูง (w, h) ค่าความเชื่อมั่นของการมีวัตถุ (Objectness Confidence) และ ค่าความน่าจะเป็นของประเภทวัตถุ (Class Probability)

YOLOv8 ใช้แนวคิด Anchor-Free Detection ซึ่งลดความซับซ้อนของการกำหนด Anchor Boxes และเพิ่มความยืดหยุ่นในการพยากรณ์ตำแหน่งวัตถุ

2.1.4.3 ฟังก์ชันความสูญเสีย (Loss Function)

ในการฝึกโมเดล YOLOv8 ระบบจะทำการปรับค่าพารามิเตอร์ของโครงข่ายประสาทเทียม โดยอาศัยฟังก์ชันความสูญเสีย (Loss Function) ซึ่งมีหน้าที่วัดความแตกต่างระหว่างค่าที่โมเดลพยากรณ์กับค่าความจริง (Ground Truth) การลดค่าความสูญเสียให้ต่ำที่สุดจะทำให้โมเดลมีความแม่นยำมากขึ้น

องค์ประกอบของ Loss Function ฟังก์ชันความสูญเสียของ YOLO ประกอบด้วย องค์ประกอบหลัก 3 ส่วน ได้แก่

1) Localization Loss ใช้วัดความคลาดเคลื่อนของตำแหน่งกรอบวัตถุ (Bounding Box Regression) โดยพิจารณาค่าพิกัด (x, y) ความกว้าง (w) และความสูง (h) ใน YOLOv8 นิยมใช้แนวคิด IoU-based Loss เช่น Complete IoU (CIoU) ซึ่งคำนึงถึง พื้นที่ซ้อนทับระหว่างกรอบพยากรณ์กับกรอบจริง ระยะห่างระหว่างจุดศูนย์กลาง และอัตราส่วนกว้างต่อสูงของกรอบ ค่า IoU (Intersection over Union) คำนวณได้จาก $\text{IoU} = (\text{พื้นที่ซ้อนทับ}) / (\text{พื้นที่รวม})$ ยิ่งค่า IoU ใกล้ 1 แสดงว่าการพยากรณ์มีความแม่นยำสูง

2) Objectness (Confidence) Loss ใช้วัดความถูกต้องของค่าความเชื่อมั่นว่าในกรอบนั้นมีวัตถุอยู่จริงหรือไม่ หากโมเดลพยากรณ์ว่ามีวัตถุในตำแหน่งที่ไม่มีวัตถุจริง ค่า Loss จะเพิ่มขึ้น เพื่อบังคับให้โมเดลเรียนรู้การแยกแยะพื้นหลัง (Background) ออกจากวัตถุเป้าหมาย

3) Classification Loss ใช้วัดความถูกต้องของการจำแนกประเภทวัตถุ โดยเปรียบเทียบค่าความน่าจะเป็นที่โมเดลพยากรณ์กับค่าจริงของคลาส โดยทั่วไปใช้ Binary Cross-Entropy (BCE) หรือ Cross-Entropy Loss ในการคำนวณ

2.1.4.4 พัฒนาการของ YOLO

เวอร์ชัน	ปี	คุณลักษณะสำคัญ	ข้อเด่น	ข้อจำกัด
YOLOv1	2016	ตรวจจับวัตถุแบบ single-pass ครั้งแรก	เร็วกว่าอัลกอริทึมก่อนหน้า	ความแม่นยำต่ำ โดยเฉพาะวัตถุขนาดเล็ก
YOLOv2-v3	2018	ปรับปรุง Backbone, ใช้ Anchor Boxes, รองรับ Multi-scale	แม่นยำขึ้น ตรวจจับหลายสเกล	ยังมีปัญหากับวัตถุที่ซ้อนกัน (Overlapping objects)
YOLOv4	2020	เพิ่ม Mosaic Data Augmentation, Cross Stage Partial (CSP)	สมดุลระหว่างความเร็วและความแม่นยำ เหมาะกับ Edge/Embedded	การเทรนซับซ้อน ต้องใช้ GPU ประสิทธิภาพสูง

YOLOv5	2020	พัฒนาโดย Ultralytics, ใช้งานง่าย หลายขนาด (Nano-XL)	เทรน Custom Dataset ได้สะดวก มี Community ใหญ่	ไม่ใช่เวอร์ชันทางการ (Official) จากผู้คิดค้น YOLO ดั้งเดิม
YOLOv6-v7	2022	สถาปัตยกรรมใหม่ รองรับ งาน Pose Estimation และ Segmentation	ประสิทธิภาพสูง ความยืดหยุ่น มาก ขึ้น	โค้ดยังซับซ้อน เอกสาร/คู่มือ ใช้งานไม่มากเท่า YOLOv5
YOLOv8	2023	Anchor-free Head, รองรับ Detection/Segmentation/Classification/Pose	แม่นยำสูง ใช้งาน เอกสารและชุมชน ผู้ใช้มาก	ขนาดโมเดลใหญ่กว่า YOLOv5 ต้องใช้ทรัพยากร เพิ่ม
YOLOv9	2024	ปรับปรุง Backbone และ Training Strategy	แม่นยำขึ้น โดยเฉพาะ Dataset ขนาดใหญ่	ยังใหม่ เอกสารและการใช้งาน จริงน้อย
YOLOv10	2024	ออกแบบสำหรับ Edge Devices โดยใช้ทรัพยากร น้อย	ประสิทธิภาพสูงแม้ บนอุปกรณ์จำกัด	ความแม่นยำอาจดีกว่า YOLOv8/YOLOv9 ในงาน บางประเภท
YOLOv11	2025	ยกระดับความเร็ว ความ แม่นยำ และความยืดหยุ่น	รองรับการใช้งาน หลากหลาย แพลตฟอร์ม	ยังใหม่มาก งานอ้างอิงและ กรณีศึกษาในภาคสนามน้อย
YOLO26	2025	เพิ่ม mAP อย่างมี นัยสำคัญ	Accuracy สูงมาก	ขนาดโมเดลและ latency สูงขึ้น

ตารางที่ 1 แสดงพัฒนาการของอัลกอริทึม YOLO (You Only Look Once)

2.1.5 Web Application, Mobile WebView และ IoT Integration

เมื่อได้ค่าที่อ่านจากมาตรน้ำแล้ว ขั้นตอนต่อมาคือการจัดเก็บ ประมวลผล และนำเสนอข้อมูลให้ ผู้ใช้งานสามารถเข้าถึงได้อย่างสะดวกและปลอดภัย การพัฒนา Web Application ร่วมกับการเชื่อมต่อ Internet of Things (IoT) และการรองรับการใช้งานผ่าน Mobile WebView จึงมีบทบาทสำคัญในการทำให้ ระบบอ่านค่ามาตรน้ำอัตโนมัติสามารถใช้งานได้จริงในสภาพแวดล้อมหลากหลาย ทั้งในครัวเรือน หน่วยงานรัฐ และองค์กรธุรกิจ

2.1.5.1 โครงสร้างสถาปัตยกรรมระบบ

ระบบอ่านค่ามิเตอร์น้ำที่ใช้ Web Application และ IoT มีองค์ประกอบหลัก 4 ส่วน ได้แก่

1) Image Sensor Node

ใช้กล้องหรือโมดูล เช่น ESP32-CAM หรือกล้องจากสมาร์ทโฟนในการถ่ายภาพหน้าปัดมิเตอร์น้ำ จากนั้นส่งภาพเข้าสู่ระบบผ่านเครือข่ายอินเทอร์เน็ต

2) Server หรือ Cloud


ทำหน้าที่รับข้อมูลจาก Edge Device และดำเนินการประมวลผลเพิ่มเติม เช่น การตรวจจับวัตถุด้วยโมเดล YOLO การจำแนกตัวเลขด้วย CNN การทำนายมุมเข็ม และการตรวจสอบความถูกต้องของข้อมูล

3) Database

ใช้สำหรับจัดเก็บข้อมูลค่ามิเตอร์น้ำที่อ่านได้ รวมถึงภาพต้นฉบับและข้อมูลผลลัพธ์ โดยอาจเลือกใช้ฐานข้อมูลเชิงสัมพันธ์ เช่น MySQL หรือ PostgreSQL หรือฐานข้อมูลแบบ Time-Series ตามลักษณะการใช้งาน

4) User Interface (Web Application และ Mobile WebView)

จัดทำในรูปแบบ Web Application เพื่อแสดงผลข้อมูลการอ่านค่ามิเตอร์น้ำย้อนหลัง รายงานสรุป และกราฟการใช้น้ำ โดยรองรับการเข้าถึงทั้งผ่าน Web Browser บนคอมพิวเตอร์ และผ่าน Mobile Application ที่ใช้งาน WebView บนอุปกรณ์พกพา



รูปภาพที่ 13 ตัวอย่างโครงสร้างการดำเนินงานของข้อมูลจากมิเตอร์น้ำสู่คลาวด์และผู้ใช้

2.1.5.2 User Interface ผ่าน Web Application และ Mobile WebView

Web Application ของระบบ AquaRead ถูกออกแบบให้เป็นศูนย์กลางในการแสดงผลและจัดการข้อมูล โดยรองรับการใช้งานผ่าน Web Browser และ Mobile WebView บนอุปกรณ์พกพา โดย Mobile WebView ทำหน้าที่เป็นตัวแสดงผลหน้า Web Application ภายใน Mobile Application โดยไม่ต้องพัฒนา Mobile Application แบบ Native แยกต่างหาก

แนวทางนี้ช่วยให้สามารถใช้โค้ดฐานเดียวกัน (Single Codebase) สำหรับการแสดงผลบนหลายแพลตฟอร์ม และเหมาะสมกับระบบที่มีการประมวลผลหลักอยู่บนฝั่งเซิร์ฟเวอร์ เช่น ระบบอ่านค่ามิเตอร์น้ำด้วยปัญญาประดิษฐ์ นอกจากนี้ยังช่วยลดความซ้ำซ้อนในการพัฒนาและเพิ่มความสะดวกในการบำรุงรักษาระบบ

2.1.5.3 ความปลอดภัยและการจัดการสิทธิ์ (Security & Privacy)

เนื่องจากข้อมูลการใช้น้ำถือเป็นข้อมูลสำคัญ จำเป็นต้องมีมาตรการด้านความปลอดภัย เช่น

- 1) การเข้ารหัสข้อมูลด้วย TLS/SSL เพื่อป้องกันการดักฟัง
- 2) การยืนยันตัวตน (Authentication) และการกำหนดสิทธิ์การใช้งาน (Authorization) เช่น การใช้ JWT Token หรือ OAuth
- 3) การจัดการสิทธิ์ผู้ใช้ (User Role) แบ่งเป็น ผู้ใช้งานทั่วไป ผู้ดูแลระบบ และผู้ตรวจสอบ

2.1.6 การเทรนโมเดล (Model Training)

2.1.6.1 การเตรียมชุดข้อมูล (Dataset Preparation)

ข้อมูลเป็นหัวใจสำคัญของการฝึกโมเดล ภาพมาตรน้ำจะถูกถ่ายจากหลายสภาพแวดล้อม เช่น แสงกลางวัน แสงน้อย ภาพเบลอ และมุมเอียง เพื่อจำลองสภาวะที่เกิดขึ้นจริง จากนั้นทำการ Label เช่น กำหนด Bounding Box รอบตัวเลขและเข็ม เพื่อเพิ่มความหลากหลาย มีการทำ Data Augmentation ได้แก่ การหมุน (Rotation) $\pm 15^\circ$ การปรับความสว่างและคอนทราสต์ การเบลอแบบ Gaussian Blur และ การเพิ่ม Noise

สิ่งเหล่านี้ช่วยให้โมเดลมีความทนทาน (Robustness) และลดการ Overfitting โดยทั่วไปชุดข้อมูล ถูกแบ่งออกเป็น 3 ส่วน ได้แก่ Training set (70–80%), Validation set (10–15%) และ Test set (10–15%)

2.1.7 การประเมินผลโมเดล (Model Evaluation)

การประเมินผลโมเดลเป็นขั้นตอนสำคัญเพื่อวัดความสามารถของระบบว่า สามารถตรวจจับและจำแนกค่าจากมาตรน้ำได้อย่างถูกต้องและเสถียรหรือไม่ โดยทั่วไปการประเมินผลแบ่งออกเป็น 2 ประเภท คือ เกณฑ์มาตรฐานที่ใช้ในงานวิชาการด้าน Computer Vision และ เกณฑ์เฉพาะที่ออกแบบมาเพื่อตรวจสอบความถูกต้องในการอ่านค่ามาตรน้ำ

2.1.7.1 เกณฑ์มาตรฐาน (Standard Metrics)

1) **Accuracy (ความถูกต้องโดยรวม)** คือสัดส่วนของจำนวนผลลัพธ์ที่โมเดลทำนายถูกต้องต่อจำนวนทั้งหมด นิยมใช้กับงานที่ต้องการจำแนกประเภทชัดเจน เช่น การจำแนกตัวเลขดิจิทัล 0–9

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

2) **Precision (ความแม่นยำ)** คือ วัดสัดส่วนของค่าที่ทำนายว่า “ถูก” แล้วถูกจริง ๆ
เหมาะสำหรับตรวจสอบว่าระบบไม่ทำนายเกิน (False Positive) มากเกินไป

$$\text{Precision} = \frac{TP}{TP+FP}$$

3) **Recall (ความครอบคลุม)** วัดสัดส่วนของค่าที่ถูกจริง ๆ ที่โมเดลสามารถตรวจพบได้
เหมาะกับงานที่ไม่อยากให้พลาดเป้าหมาย (False Negative)

$$\text{Recall} = \frac{TP}{TP+FN}$$

4) **F1-Score** เป็นค่าเฉลี่ยเชิงฮาร์โมนิกของ Precision และ Recall
เพื่อให้เห็นสมดุลทั้งสองด้าน

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

5) **mAP (mean Average Precision)** ใช้กันอย่างแพร่หลายในงาน Object Detection
เช่น YOLO โดยคำนวณค่า Area Under Curve (AUC) ของ Precision-Recall Curve สำหรับแต่ละคลาส
แล้วหาค่าเฉลี่ย (AP) ของทุกคลาสอีกครั้งหนึ่ง โมเดลที่มีค่า mAP สูงหมายถึงสามารถตรวจจับวัตถุได้ทั้ง
แม่นยำและครอบคลุม

2.1.7.2 เกณฑ์เฉพาะสำหรับการอ่านค่ามาตรน้ำ (Domain-Specific Metrics)

นอกจากเกณฑ์มาตรฐานแล้ว โครงการนี้ยังต้องประเมินผลลัพธ์โดยใช้เกณฑ์ที่ออกแบบมา
เฉพาะสำหรับการอ่านค่ามาตรน้ำ เพื่อสะท้อนความถูกต้องในเชิงปฏิบัติการ ได้แก่

1) Per-Digit Accuracy

ตรวจสอบความถูกต้องของการจำแนกตัวเลขแต่ละหลัก (เช่น หลักพัน หลักร้อย หลักสิบ)
โดยนับจำนวนหลักที่อ่านถูกต้องต่อจำนวนหลักทั้งหมดใน Test Set

2) Pair Confidence และ Transition Accuracy

สำหรับกรณีตัวเลขที่อยู่ในช่วง Transition (เช่น 9 → 0) จะใช้ค่าความเชื่อมั่น
(Confidence) ของโมเดลร่วมกับ Pair Model เพื่อวัดว่าโมเดลสามารถตัดสินใจได้ถูกต้องหรือไม่
โดยประเมินทั้งทิศทางการเปลี่ยนและความถูกต้องหลังการ Carry

3) Consistency Check

ตรวจสอบว่าค่าที่อ่านได้จากมิเตอร์ต้องมีความต่อเนื่อง ไม่สามารถลดลงได้ (เช่น จาก 125
→ 124 ถือว่าผิดปกติ) การประเมินนี้มีความสำคัญมากเพราะช่วยกรองผลลัพธ์ที่แม้โมเดลจะทำนายถูกเป็น
บางหลัก แต่ผิดพลาดด้านตรรกะการใช้งาน

4) Angle Error (สำหรับเข็มอนาล็อก)

ใช้ค่าวัดความคลาดเคลื่อนของการทำนายมุมเข็มเมื่อเทียบกับค่าจริง โดยคำนวณ

เป็นค่าเฉลี่ยความต่างขององศา (Mean Absolute Error: MAE) หรือ Root Mean Squared Error (RMSE) เพื่อวัดความแม่นยำของ Needle Regression Model

5) End-to-End Reading Accuracy

เป็นเกณฑ์ที่วัดจากผลลัพธ์สุดท้ายที่ระบบอ่านออกมาเทียบกับ Ground Truth โดยตรง (ไม่แยกเป็น per-digit หรือ per-needle) เพื่อดูว่า “ค่าที่รายงานเป็นตัวเลขการใช้น้ำ” ถูกต้องหรือไม่

2.1.7.3 ความสำคัญของการประเมินหลายมิติ


การใช้เกณฑ์เพียงค่าเดียว เช่น Accuracy อาจไม่สะท้อนคุณภาพโมเดลที่แท้จริง ดังนั้นจึงต้องใช้หลายเกณฑ์ควบคู่กัน เช่น Precision–Recall สำหรับการตรวจจับเข็ม, Per-Digit Accuracy สำหรับตัวเลข, และ Consistency Check เพื่อให้มั่นใจว่าระบบสามารถนำไปใช้งานจริงได้โดยไม่ทำให้เกิดค่าผิดพลาดสะสม

2.2 งานวิจัยที่เกี่ยวข้อง

มีงานวิจัยจำนวนมากที่เกี่ยวข้องกับการอ่านค่ามาตรทั้งแบบอนาล็อกและดิจิทัล โดยใช้เทคโนโลยีปัญญาประดิษฐ์และการประมวลผลภาพ ซึ่งสามารถสรุปได้ดังนี้

Jomjol (2021) ได้พัฒนาโปรเจกต์ AI-on-the-edge-device ซึ่งเป็นระบบอ่านค่ามิเตอร์น้ำและมิเตอร์ไฟฟ้าโดยใช้ไมโครคอนโทรลเลอร์ ESP32-CAM ร่วมกับ TensorFlow Lite โมเดล CNN ขนาดเล็กถูกฝังลงในอุปกรณ์เพื่อประมวลผลภาพที่ได้จากกล้องโดยตรง ทำให้สามารถอ่านค่าทั้งแบบดิจิทัล (rolling digit) และเข็มอนาล็อกได้อัตโนมัติ โดยระบบมีการประยุกต์ใช้เทคนิค Correction Algorithm เช่น การทำ Carry-over และ Consistency Check เพื่อแก้ไขค่าที่ผิดพลาดจากการอ่าน ผลการทดสอบแสดงให้เห็นว่าระบบสามารถทำงานได้จริงบนอุปกรณ์ Edge ที่มีข้อจำกัดด้านทรัพยากร แต่ยังคงให้ความแม่นยำในระดับที่ใช้งานจริงได้ อีกทั้งยังรองรับการเชื่อมต่อ IoT ผ่าน MQTT และ Home Assistant จึงสามารถนำข้อมูลไปใช้กับระบบ Smart Home หรือ Smart City ได้ทันที จุดเด่นของงานนี้คือการพิสูจน์ว่า AI สามารถรันบน Edge Device ราคาต่ำได้โดยไม่ต้องพึ่งเซิร์ฟเวอร์ ขณะที่ข้อจำกัดหลักอยู่ที่ความเสถียรของภาพจาก ESP32-CAM ซึ่งอาจได้รับผลกระทบจากสภาพแสงและการติดตั้ง รวมถึงไม่สามารถใช้โมเดลที่ซับซ้อนมากได้ [5]

ตัวอย่างระบบอ่านค่ามิเตอร์ด้วย Edge AI



รูปภาพที่ 14 ขั้นตอนการทำงานของระบบอ่านมิเตอร์ ที่ติดตั้งบน ESP32


Digitizer - AI on the edge

An ESP32 all inclusive neural network recognition system for meter digitalization


Overview	Configuration	Recognition	File Server	System									
													
<table border="1"> <tr> <td>Raw Value:</td> </tr> <tr> <td>038.5975</td> </tr> <tr> <td>Corrected Value:</td> </tr> <tr> <td>38.5975</td> </tr> <tr> <td>Checked Value:</td> </tr> <tr> <td>38.5975</td> </tr> <tr> <td>Start Time:</td> </tr> <tr> <td>20201118-075416</td> </tr> <tr> <td>Last Page Refresh 06:57:39</td> </tr> </table>					Raw Value:	038.5975	Corrected Value:	38.5975	Checked Value:	38.5975	Start Time:	20201118-075416	Last Page Refresh 06:57:39
Raw Value:													
038.5975													
Corrected Value:													
38.5975													
Checked Value:													
38.5975													
Start Time:													
20201118-075416													
Last Page Refresh 06:57:39													

รูปภาพที่ 15 Web Interface ของ AI-on-the-edge-device แสดงผลการอ่านค่ามิเตอร์

Dasgupta et al. (2019) นำเสนอระบบการอ่านค่ามาตรน้ำแบบอัตโนมัติ โดยผสมผสาน YOLOv2 เข้ากับ Convolutional Neural Network (CNN) เพื่อจัดการกับทั้งสององค์ประกอบของมาตรน้ำ ได้แก่ กล่องตัวเลข (Digit Box) และหน้าปัดเข็ม (Pointer Meter) ดังรูปตัวอย่างที่ 13



รูปภาพที่ 16 มิเตอร์น้ำแบบอนาล็อก มีทั้งกล่องตัวเลข (Digit Box) และหน้าปัดเข็ม (Pointer Meter)




รูปภาพที่ 17 แผนผังการทำงานของโมเดล (Pipeline Diagram)

ผลการทดลองแสดงให้เห็นว่า วิธีการผสมผสาน Object Detection (YOLOv2) กับ CNN Regression สามารถอ่านค่ามาตรน้ำได้อย่างมีประสิทธิภาพ แม้จะมีสภาพแวดล้อมที่ซับซ้อน เช่น ภาพเบลอ เงา หรือการเอียงของกล้อง โดยมีความแม่นยำสูงกว่าวิธี OCR แบบดั้งเดิม


จุดเด่นของงานนี้ คือการแสดงให้เห็นว่าการอ่านค่ามาตรน้ำสามารถทำได้ด้วยแนวทาง Hybrid Model (Detection + Regression) ซึ่งเป็นรากฐานสำคัญให้กับงานวิจัยในอนาคต

รวมถึงโครงการปัจจุบันที่พัฒนาต่อยอดด้วยการใช้ YOLOv8 และ Correction Logic เพื่อเพิ่มความแม่นยำในการจัดการกับ Transition Digit และ Carry-over [6]

Imran et al. (2023) ได้พัฒนา ระบบอ่านค่ามิเตอร์ไฟฟ้าดิจิทัลและอนาล็อกจากภาพถ่าย โดยมุ่งเน้น การตรวจจับและจำแนกตัวเลข (Digit Recognition) บนจอของมิเตอร์ไฟฟ้าแบบดิจิทัล ระบบใช้ YOLOv3 เปรียบเทียบกับวิธี Handcrafted Features บนชุดข้อมูลกว่า 12,000 ภาพ ของมิเตอร์หลายชนิดในสภาวะ แวดล้อมที่แตกต่างกัน ซึ่งประกอบด้วยปัญหาหลัก ได้แก่ การหมุนและสเกลที่ไม่คงที่ เงาและแสงที่ไม่ สม่ำเสมอ การบดบังบางส่วน รวมถึงชนิดของมิเตอร์ที่หลากหลาย



รูปภาพที่ 18 ตัวอย่างความหลากหลายของสภาวะภาพถ่ายมิเตอร์ไฟฟ้า



รูปภาพที่ 19 ผลลัพธ์การตรวจจับตัวเลขด้วย YOLOv3

ผลการทดลองแสดงว่า YOLOv3 ให้ค่าความแม่นยำสูงกว่า 98% และมีความ Robust ต่อ สภาพแวดล้อมจริง เช่น ภาพเบลอ เงา หรือการเอียงของกล้อง แม้ว่าจะยังพบความผิดพลาดเล็กน้อยในบาง กรณี (เช่น การอ่านเลข 3, 5 ที่ใกล้เคียง) แต่โดยรวมแล้ว outperform วิธีแบบดั้งเดิมอย่างชัดเจน งานวิจัยนี้ ยืนยันว่าเทคนิค Object Detection สมัยใหม่อย่าง YOLO สามารถช่วยลดความผิดพลาดจากการอ่านมิเตอร์ ด้วยแรงงานคนได้ และยังสามารถเชื่อมต่อเพื่อใช้งานในระบบ IoT และ Billing System ได้จริง [7]

งานวิจัย Li et al. (2021) นี้นำเสนอกล้องอัจฉริยะสำหรับการอ่านค่าความดันจากระบบเข็มวัดในสถานีไฟฟ้าย่อย โดยมุ่งแก้ไขปัญหที่พบในสภาพการทำงานจริง เช่น แสงที่ไม่สม่ำเสมอ ฉากหลังที่ซับซ้อน และการมี damping fluid บนหน้าปัดซึ่งทำให้การตรวจจับเข็มทำได้ยากขึ้น วิธีการของ Li และคณะ ประกอบด้วยการพัฒนาอัลกอริทึมสำหรับตรวจจับวงกลมหน้าปัดโดยอาศัยการตรวจจับเส้นขอบแบบหลายขั้นตอน (multi-step edge detection) ผสมผสานกับ Hough Transform และอัลกอริทึมปรับค่า threshold นอกจากนี้ยังใช้เวลาเฉลี่ยเพียงประมาณ 143 ms ต่อการอ่านค่าซึ่งเร็วกว่าวิธี Hough Circle Detection ที่ใช้กันมาก่อนหน้านี้

จุดเด่นประการหนึ่งคือความทนทานต่อค่าความสว่างและแสงเงาที่ซับซ้อน ทำให้วิธีนี้มีความเหมาะสมต่อการใช้งานในสภาพจริง โดยผลการทดลองให้ความถูกต้อง (accuracy) โดยมีอัตราความคลาดเคลื่อนเฉลี่ยเพียง 0.994% ของการอ่านค่ามาตรวัดอยู่ในระดับที่สามารถใช้งานได้จริงในระบบเรือไฟฟ้า [8]



(a) original image




(b) enhanced image



(c) the result of circle detection



(d) the result of pointer extraction




(e) the result of pointer position



(f) the coordinate of the zero and end scale


รูปภาพที่ 20 ขั้นตอนการทำงานของอัลกอริทึมอ่านมาตรวัด

งานวิจัยของ Li et al., 2025 นี้ นำเสนอวิธีการอ่านค่ามาตรเข็ม (Pointer Meter Reading Recognition, PMRR) ที่มีความทนทานต่อสภาพอุตสาหกรรมจริง เช่น ภาพเบลอ แสงไม่สม่ำเสมอ ฉากหลังซับซ้อน และการเอียงของกล้อง โดยใช้ YOLOX-DC ซึ่งปรับปรุงจาก YOLOX ด้วยกลไก Decoupled Circle Head สำหรับการตรวจจับหน้าปัด, โมเดล PM-SwinUnet (ผสาน U-Net และ Swin Transformer) สำหรับการแบ่งส่วน pointer และสเกล พร้อมด้วย Scale and Pointer Fitting Module เพื่อระบุตำแหน่งอย่างแม่นยำ และการอ่านค่าด้วย Improved Angle Method ที่ลดความผิดพลาดและภาระคำนวณ ผลการทดลองแสดงว่า YOLOX-DC ให้ Precision/Recall สูงถึง 99.6%/99.7% ขณะที่ PM-SwinUnet ทำได้ mIoU 94.1% และ mPA 97.6% ค่าคลาดเคลื่อนเฉลี่ยของการอ่านอยู่เพียง 0.92% (δ) และ 0.26% (γ) ใช้เวลาเฉลี่ย ~0.6 วินาทีต่อการอ่าน เร็วกว่าวิธีเดิมเกือบสองเท่า อีกทั้งยังทนทานต่อสภาวะภาพที่ยากลำบาก ทำให้ระบบ End-to-End ที่พัฒนาขึ้นนี้เหมาะสมต่อการประยุกต์ใช้งานจริงในการผลิตและการเปลี่ยนผ่านสู่การผลิตดิจิทัล (Manufacturing Digital Transformation) [9]



รูปภาพที่ 21 โครงสร้างวิธีการอ่านค่ามาตรเข็มอัตโนมัติที่ประกอบด้วย YOLOX-DC สำหรับตรวจจับหน้าปัด, PM-SwinUnet สำหรับการแบ่งส่วน pointer และสเกล และ Improved Angle Method สำหรับคำนวณค่าการอ่าน

งานวิจัยของ Wu et al., 2021 นำเสนอเรื่อง A High-Precision Automatic Pointer Meter Reading System in Low-Light Environment นำเสนอระบบอ่านค่ามาตรวัดแบบเข็มโดยอัตโนมัติที่สามารถทำงานได้อย่างแม่นยำในสภาพแสงน้อย ซึ่งเป็นปัญหาที่ระบบอ่านค่าด้วยกล้องมักประสบอยู่ในสภาพแวดล้อมจริง เช่น โรงไฟฟ้า หรือสถานีย่อยสถานีวิทยุได้พัฒนา สถาปัตยกรรมแบบหลายโมดูล (Multi-Module System) ซึ่งประกอบด้วยสามขั้นตอนหลัก คือ




รูปภาพที่ 22 แสดงสถาปัตยกรรมของระบบอ่านค่ามาตรวัด โดยใช้ ResNet50–FPN ร่วมกับ Region Proposal Network (RPN) และ Multi-Scale PrRoI Pooling เพื่อสร้าง Binary Mask ของหน้าปัด ก่อนเข้าสู่ขั้นตอนการแก้ภาพเอียงและการอ่านค่า

1) การปรับภาพให้ตรง (Skew Correction) โดยใช้ Mask-RCNN ที่ปรับปรุงด้วยกลไก Attention และ PrRoI Pooling เพื่อสร้าง Binary Mask ของหน้าปัดและทำ Ellipse Fitting พร้อม Perspective Transformation สำหรับการแก้ภาพเอียง เทคนิคนี้เพิ่มความแม่นยำในการจัดแนวภาพได้ดีกว่าวิธีตรวจจุด Key Points แบบเดิม

2) การปรับแสงและลดสัญญาณรบกวน (Illumination Enhancement) โดยเสนออัลกอริทึม RBF Fusion ซึ่งผสมผสาน Retinex แบบ Fractional Order เข้ากับ Fast Adaptive Bilateral Filtering ทำให้สามารถเพิ่มความสว่างในบริเวณแสงน้อยได้โดยไม่เกิด over-exposure และยังคงรักษารายละเอียดของพื้นผิวหน้าปัดไว้ได้ดี

3) การอ่านค่าเข็ม (Reading Recognition) ด้วยเครือข่ายประสาทเทียมเชิงลึก ResNet101 ที่ปรับปรุงใหม่ ซึ่งใช้วิธี Needle Direction Regression ในการถดถอยทิศทางของเข็มแบบ End-to-End โดยไม่ต้องระบุจุดปลายเข็มหรือจุดศูนย์กลางเหมือนวิธีดั้งเดิม ช่วยลดความผิดพลาดจากการระบุตำแหน่งจุดไม่แม่นยำ

ผลการทดลองใช้ข้อมูลจริง 1672 ภาพจากสถานีไฟฟ้าแสดงให้เห็นว่า การเพิ่ม Transfer Learning และ PrRoI Pooling ทำให้ mAP₅₀ ของการตรวจจับวัตถุสูงถึง 0.892–0.938 อัลกอริทึม RBF ให้คะแนน LOE = 428 (ต่ำที่สุด) และ FSIM = 0.943 (สูงที่สุด) เหนือกว่าวิธี CLAHE, MSRCR และ Dark Channel Defogging ค่าความคลาดเคลื่อนเฉลี่ยของการอ่าน (Mean Relative Error) เพียง 2.217 % และ Mean Reference Error เพียง 0.208 % มีอัตราความสำเร็จในการแก้ภาพเอียงมากกว่า 98.8 % และใช้เวลาอ่านต่อภาพน้อยกว่า 1 วินาที



รูปภาพที่ 23 ตัวอย่างภาพมาตรวัดที่ใช้ในการทดสอบระบบในสภาพแวดล้อมจริง ซึ่งมีการเปลี่ยนมุมกล้องและระดับแสงที่แตกต่างกัน เพื่อจำลองสถานการณ์ในโรงงานหรือสถานีอุตสาหกรรม


จุดเด่นของงานนี้คือ การรวมเทคนิค Computer Vision และ Deep Learning เข้าด้วยกันอย่างเป็นระบบ ครอบคลุมทั้งการแก้ภาพเอียง การเพิ่มแสง และการอ่านค่าแบบอัตโนมัติ ทำให้สามารถทำงานได้อย่างเสถียรแม้ในสภาพแสงน้อยหรือภาพเอียง ซึ่งเป็นกรณีที่เกิดขึ้นจริงในภาคสนาม [10]

บทที่ 3

วิธีการดำเนินการ

3.1 ภาพรวมการทำงาน

ในบทนี้จะอธิบายขั้นตอนการดำเนินงานของโครงการ ตั้งแต่การเก็บข้อมูล การเตรียมชุดข้อมูล การพัฒนาโมเดล AI การออกแบบระบบประมวลผล รวมถึงการพัฒนา Web Application และการเชื่อมต่อกับ IoT เพื่อให้สามารถอ่านค่ามาตรน้ำแบบอนาล็อกและแปลงเป็นข้อมูลดิจิทัลได้อย่างมีประสิทธิภาพ



รูปภาพที่ 24 แผนผังภาพรวมการทำงาน

3.2 แนวทางการพัฒนาโครงการวิจัย

3.2.1 การวางแผนลำดับการดำเนินงาน

ผู้วิจัยได้กำหนดขั้นตอนการพัฒนาโครงการอ่านค่ามิเตอร์น้ำอัตโนมัติ โดยใช้แนวทางการประมวลผลภาพและปัญญาประดิษฐ์ เพื่อให้สามารถอ่านค่ามิเตอร์น้ำจากภาพได้อย่างถูกต้องและมีประสิทธิภาพสูงสุด โดยแบ่งการดำเนินงานออกเป็นขั้นตอนหลัก ได้แก่ การกำหนดปัญหา การวิเคราะห์ปัญหา การศึกษาข้อมูล การออกแบบและพัฒนาระบบ และการทดสอบประเมินผล ทั้งนี้การวางแผนลำดับงานดังกล่าวช่วยให้โครงการมีทิศทางที่ชัดเจน และสามารถติดตามความก้าวหน้าได้อย่างเป็นระบบ

3.2.2 การกำหนดปัญหา

ในปัจจุบันการอ่านค่ามิเตอร์น้ำยังคงต้องอาศัยแรงงานมนุษย์ ไม่ว่าจะเป็นเจ้าหน้าที่หรือผู้ใช้น้ำเอง วิธีการดังกล่าวมีข้อจำกัดหลายประการ เช่น ความผิดพลาดจากการอ่านค่า ความไม่สะดวกในการเก็บข้อมูล รวมถึง ไม่สามารถนำข้อมูลไปใช้ในการวิเคราะห์แบบเรียลไทม์ได้ ปัญหาเหล่านี้ก่อให้เกิดความล่าช้าในการจัดการทรัพยากรน้ำและอาจสร้างภาระค่าใช้จ่ายที่เพิ่มขึ้น โครงการจึงกำหนดปัญหาว่าจะต้องพัฒนาระบบที่สามารถอ่านค่ามิเตอร์น้ำได้อัตโนมัติจากภาพถ่าย ซึ่งช่วยลดความผิดพลาดของมนุษย์ เพิ่มความแม่นยำ และทำให้สามารถนำข้อมูลไปใช้ประโยชน์ได้ทันที

3.2.3 การวิเคราะห์ปัญหา

จากการวิเคราะห์ลักษณะของมิเตอร์น้ำแบบหน้าปัด พบว่าการอ่านค่ามิเตอร์จากภาพถ่ายมีความซับซ้อน เนื่องจากมิเตอร์ประกอบด้วยองค์ประกอบหลายประเภท ได้แก่ ตัวเลขดิจิทัลและหน้าปัดเข็ม ซึ่งต้องใช้วิธีการประมวลผลที่แตกต่างกันในการตีความค่า นอกจากนี้การอ่านค่ามิเตอร์ด้วยแรงคน เสี่ยงต่อการอ่านผิดพลาด ส่งผลให้การอ่านค่ามิเตอร์มีโอกาสเกิดความคลาดเคลื่อนได้ ดังนั้นแนวทางแก้ไขคือการประยุกต์ใช้โมเดล YOLOv8 สำหรับการตรวจจับวัตถุ (Object Detection) เพื่อระบุตำแหน่งช่องตัวเลขและหน้าปัดเข็ม จากนั้นใช้โมเดล Convolutional Neural Network (CNN) สำหรับการจำแนกตัวเลขแต่ละหลัก (Digit Classification) ขณะเดียวกันการอ่านค่าหน้าปัดเข็มใช้วิธี Angle Estimation เพื่อคำนวณมุมของเข็มและแปลงเป็นค่าตัวเลข พร้อมทั้งใช้ Rule-based Correction เพื่อตรวจสอบความสอดคล้องของผลลัพธ์และจัดการกรณีตัวเลขกำลังเปลี่ยนผ่าน (Digit Transition) เพื่อเพิ่มความถูกต้องและความน่าเชื่อถือของค่าที่ระบบอ่านได้

3.2.4 การศึกษาข้อมูลและเลือกเครื่องมือในการพัฒนา

ผู้วิจัยได้ทำการศึกษาข้อมูลจากเอกสารทางวิชาการ งานวิจัยที่เกี่ยวข้อง และตัวอย่างระบบอ่านค่ามิเตอร์น้ำอัตโนมัติที่มีการเผยแพร่ รวมถึงการสืบค้นข้อมูลจากแหล่งออนไลน์ เช่น Google Scholar, YouTube, Roboflow, Ultralytics และ GitHub เพื่อนำเทคนิคที่ได้มาประยุกต์ใช้กับการพัฒนาระบบ โดยเน้นการเลือกเครื่องมือ และโมเดลที่เหมาะสมกับการตรวจจับและจำแนกตัวเลข รวมถึงการจัดเตรียมชุดข้อมูลภาพมิเตอร์ในสภาพแวดล้อมจริงเพื่อใช้ในการฝึกและทดสอบโมเดลทั้งนี้เพื่อให้ระบบที่พัฒนาขึ้นสามารถใช้งานได้จริงและความแม่นยำสูง

3.2.4.1 เครื่องมือที่ใช้ในการพัฒนา

ในการพัฒนาโครงงานวิจัยนี้ ผู้วิจัยได้เลือกใช้เครื่องมือทั้งด้านฮาร์ดแวร์และซอฟต์แวร์ที่เหมาะสมกับการพัฒนาระบบอ่านค่ามาตรน้ำอัตโนมัติด้วยเทคนิคปัญญาประดิษฐ์ โดยมีรายละเอียดดังต่อไปนี้

1) ฮาร์ดแวร์ (Hardware)

กล้องถ่ายภาพมาตรน้ำ ใช้สำหรับเก็บภาพหน้าปัดมาตรน้ำ ซึ่งประกอบด้วยตัวเลขหมุน (Digital Rollers) และหน้าปัดเข็ม (Analog Dials) โดยภาพที่ได้จะถูกใช้เป็นข้อมูลนำเข้าสำหรับกระบวนการประมวลผลภาพและการตรวจจับวัตถุ ความละเอียดของกล้องมีผลต่อความคมชัดของภาพ และช่วยลดความคลาดเคลื่อนในการอ่านค่า

เครื่องคอมพิวเตอร์ประสิทธิภาพสูง (CPU และ GPU) ใช้สำหรับการพัฒนาและฝึกโมเดลปัญญาประดิษฐ์ เช่น Convolutional Neural Network (CNN) และ YOLO โดยเฉพาะขั้นตอนการฝึกโมเดลเชิงลึก (Deep Learning) ซึ่งต้องใช้พลังการประมวลผลสูง การ์ดจอที่รองรับเทคโนโลยี NVIDIA CUDA ช่วยเร่งความเร็วในการคำนวณ ทำให้ระยะเวลาในการฝึกโมเดลลดลงอย่างมีนัยสำคัญ

โทรศัพท์มือถือระบบ Android ใช้สำหรับทดสอบการทำงานของระบบผ่าน Mobile WebView โดยทำหน้าที่จำลองการใช้งานจริงของผู้ใช้ปลายทาง อุปกรณ์ดังกล่าวใช้ในการตรวจสอบความถูกต้องของการแสดงผล (Responsive Design) ความเร็วในการตอบสนองของระบบ และความสามารถในการเข้าถึง Web Application ผ่านเครือข่ายอินเทอร์เน็ต

2) ซอฟต์แวร์ (Software)

Python ใช้เป็นภาษาหลักในการพัฒนา เนื่องจากมีไลบรารีสนับสนุนด้าน Computer Vision และ Machine Learning จำนวนมาก และมีความเหมาะสมต่อการพัฒนาระบบต้นแบบ (Prototype)

OpenCV ใช้ในกระบวนการประมวลผลภาพเบื้องต้น (Preprocessing) เช่น การปรับค่าความสว่างและความคมชัด การแปลงภาพเป็นระดับสีเทา (Grayscale) การทำ Threshold การตรวจจับขอบภาพ (Edge Detection) และการจัดแนวภาพ (Image Alignment)

TensorFlow และ Keras ใช้สำหรับพัฒนาและฝึกโมเดล CNN เพื่อจำแนกตัวเลขดิจิทัล (0-9 และ Transition Digit) รวมถึงการสร้าง Pair Model เพื่อช่วยตรวจสอบความถูกต้องของลำดับตัวเลข

PyTorch และ Ultralytics YOLOv8 ใช้สำหรับงานตรวจจับวัตถุ (Object Detection) โดยเฉพาะการระบุตำแหน่งกรอบของตัวเลขหมุนและเข็มบนหน้าปัดมิเตอร์น้ำ โมเดล YOLOv8 มีคุณสมบัติด้านความเร็วในการประมวลผล และรองรับการใช้งานกับชุดข้อมูลเฉพาะ (Custom Dataset) ได้อย่างมีประสิทธิภาพ

Django Framework ใช้สำหรับพัฒนา Web Application เพื่อให้ผู้ใช้สามารถอัปโหลดภาพ แสดงผลการประมวลผลย้อนหลัง และดูข้อมูลสถิติการใช้น้ำผ่านระบบเว็บ

WebView Component ใช้สำหรับแสดงผล Web Application ภายใน Mobile Application โดยทำหน้าที่เป็นตัวกลางในการเรียกใช้งานระบบผ่าน URL เดียวกันกับ Web Browser ช่วยลดความซ้ำซ้อนในการพัฒนาแอปพลิเคชันแบบ Native

HTML5, CSS3 และ JavaScript ใช้สำหรับพัฒนาส่วนติดต่อผู้ใช้ (User Interface) ของ Web Application โดยรองรับการแสดงผลแบบ Responsive Design เพื่อให้สามารถใช้งานได้ทั้งบนคอมพิวเตอร์และอุปกรณ์พกพา

3) เครื่องมือสนับสนุน (Supporting Tools)

GitHub ใช้สำหรับควบคุมเวอร์ชันของซอร์สโค้ดและจัดเก็บโครงการออนไลน์

Visual Studio Code / PyCharm ใช้เป็นเครื่องมือพัฒนา (IDE) สำหรับเขียนทดสอบ และแก้ไขโค้ด

Google Colab ใช้สำหรับทดลองและฝึกโมเดลเบื้องต้นบนระบบคลาวด์ที่รองรับ GPU ก่อนนำไปพัฒนาต่อบนเครื่องหลัก

Web Browser ใช้สำหรับทดสอบและตรวจสอบการทำงานของ Web Application รวมถึงการจำลองการแสดงผลผ่าน Mobile WebView


3.2.5 การออกแบบโครงงาน

ในการออกแบบโครงงานวิจัยนี้ ผู้วิจัยมุ่งเน้นไปที่การออกแบบระบบซอฟต์แวร์เป็นหลัก เนื่องจากในระยะปัจจุบันของโครงการยังไม่ได้มีการพัฒนาและติดตั้งฮาร์ดแวร์ภาคสนาม เช่น กล้องถ่ายภาพหรือไมโครคอนโทรลเลอร์โดยตรง การออกแบบระบบจึงแบ่งออกเป็นสองส่วนหลัก ได้แก่ การออกแบบสถาปัตยกรรมซอฟต์แวร์ และการออกแบบการทำงานของระบบ Web Application ซึ่งถูกนำไปใช้งานผ่าน Mobile WebView บนอุปกรณ์พกพา

การออกแบบดังกล่าวให้ความสำคัญกับกระบวนการจัดการข้อมูลภาพมิเตอร์น้ำ การประมวลผลด้วยโมเดลปัญญาประดิษฐ์ (AI) และการเชื่อมโยงผลลัพธ์ที่ได้กับฐานข้อมูลผู้ใช้งาน โดยระบบ Web Application ทำหน้าที่เป็นศูนย์กลางในการรับข้อมูล แสดงผล และจัดเก็บข้อมูล ทั้งในการใช้งานผ่าน Web Browser บนคอมพิวเตอร์ และในการใช้งานผ่าน Mobile Application ที่แสดงผลด้วย WebView เพื่อรองรับการใช้งานในภาคสนามได้อย่างสะดวกและสอดคล้องกับสถาปัตยกรรมของระบบโดยรวม


3.2.5.1 การออกแบบสถาปัตยกรรมซอฟต์แวร์

สถาปัตยกรรมระบบถูกออกแบบให้มีขั้นตอนการทำงานเป็นลำดับชัดเจน เริ่มจาก (1) การอัปโหลดหรือ รับภาพจากกล้องที่เชื่อมต่อเข้าระบบ, (2)การตรวจจับตำแหน่งดิจิทัลสตริปและหน้าปัดเข็มด้วยโมเดลตรวจจับวัตถุ (YOLO), (3) การครอบและปรับแต่งภาพ (padding/clip) เพื่อความชัดเจน, (4) การจำแนกตัวเลขด้วยโมเดล CNN และการอ่านค่าเข็มด้วยวิธีเชิงมุม (Angle-based Method), และ (5) การประมวลผลหลังบ้าน (Post-processing) เช่น การตรวจสอบความสอดคล้องระหว่างตัวเลขกับเข็ม และผลลัพธ์ทั้งหมดจะถูกจัดเก็บในฐานข้อมูล พร้อมหลักฐานภาพเพื่อความโปร่งใส



รูปภาพที่ 25 ภาพรวมการทำงานของระบบ

3.2.5.2 การเตรียมชุดข้อมูลในการฝึกโมเดล



รูปภาพที่ 26 แผนผังการเตรียมชุดข้อมูลในการฝึกโมเดล

ในการสร้างชุดข้อมูลเพื่อใช้ในการฝึกโมเดล AI ผู้วิจัยได้ทำการ คัดลอก (Crop) และกำหนด Label (Annotation) จากภาพมาตรฐานจริง เพื่อระบุตำแหน่งบริเวณที่สนใจ (Region of Interest: ROI) ทั้งส่วนหน้าปัดเข็ม และ ช่องตัวเลขดิจิทัล

โดยขั้นตอนการเตรียมข้อมูลแบ่งออกเป็น 2 ขั้นตอนหลัก ได้แก่ การ Crop และกำหนด Label จากภาพมิเตอร์น้ำมัน เพื่อเตรียมข้อมูลสำหรับการตรวจจับวัตถุด้วย YOLO และการ Crop ภาพเฉพาะส่วนของหน้าปัดเข็มและตัวเลขดิจิทัล เพื่อสร้างชุดข้อมูลเฉพาะทางสำหรับฝึกโมเดล CNN และ Regression

1) Crop และกำหนด Label จากภาพมิเตอร์น้ำมัน


ในขั้นตอนแรก ผู้วิจัยนำภาพรวมของมิเตอร์น้ำมันมาทำการ Crop และ Annotate (Label) เพื่อระบุบริเวณที่สนใจ (Region of Interest: ROI) ได้แก่

1.1) หน้าปัดเข็ม ผู้วิจัยได้ทำการ Crop ภาพจากมิเตอร์น้ำมันจริงและกำหนดกรอบกำกับ (Bounding Box) สำหรับบริเวณเข็มทั้ง 3 ช่องของหน้าปัด โดยแบ่งออกเป็น 3 คลาส ตามตำแหน่งทศนิยมของค่าที่อ่านได้ เพื่อให้โมเดลสามารถตรวจจับและแยกช่องหน้าปัดได้อย่างถูกต้องตามลำดับหลัก ได้แก่ Class 1 (x001) : ทศนิยมตำแหน่งที่ 2 , Class 2 (x0001) : ทศนิยมตำแหน่งที่ 3 และ Class 3 (x00001) : ทศนิยมตำแหน่งที่ 4

กระบวนการ Annotate ใช้วิธีวาดกรอบสี่เหลี่ยมรอบบริเวณวงกลมของหน้าปัด แต่ละช่อง โดยไม่กินขอบรอบนอก เพื่อให้ได้ ROI ที่แม่นยำในการตรวจจับ จากนั้นบันทึกค่าพิกัดในรูปแบบ YOLO ได้แก่ <class_id> <x_center> <y_center> <width> <height> ซึ่งค่าพิกัดทั้งหมดถูกปรับให้อยู่ในช่วง [0,1] เพื่อให้เหมาะสมกับการฝึกโมเดล

```
1 0.706522 0.625786 0.239130 0.245283
2 0.485507 0.710692 0.246377 0.251572
3 0.250000 0.616352 0.239130 0.251572
```

รูปภาพที่ 27 ตัวอย่างไฟล์ข้อความ Label (.txt) ของ YOLO ซึ่งประกอบด้วยข้อมูลคลาสและพิกัดของกรอบ Bounding Box ทั้ง 3 คลาสในภาพเดียวกัน




รูปภาพที่ 28 ภาพตัวอย่างการ Annotate หน้าปัดเข็มทั้ง 3 ช่อง โดยใช้คลาส x001, x0001, และ x00001 ซึ่งแทนตำแหน่งทศนิยมลำดับที่ 2-4 ของมิเตอร์น้ำ

ผลลัพธ์ที่ได้คือ ชุดข้อมูลภาพและไฟล์ Label ในแต่ละไฟล์จะถูกตั้งชื่อเดียว กับภาพต้นฉบับ (เช่น img16.jpg → img16.txt) และจัดเก็บตามโครงสร้างชุดข้อมูล YOLO ที่แบ่งเป็นโฟลเดอร์

```
dataset /
├─ images/
│   ├── train/
│   └─ val/
├─ labels/
│   ├── train/
│   └─ val/
└─ data.yaml
```

สำหรับฝึกโมเดล YOLO แบบ Multi-Class Object Detection ซึ่งสามารถระบุแต่ละหน้าปัดเข็มได้แยกจากกัน จากนั้นนำข้อมูลดังกล่าวไปฝึกเป็นโมเดล YOLO multi-class สำหรับตรวจจับวัตถุทั้ง 3 คลาสในภาพเดียว



รูปภาพที่ 29 ตัวอย่างผลลัพธ์ชุดข้อมูลภาพ(.jpg) และไฟล์ Label (.txt)

1.2) ตัวเลขดิจิทัล (Digital Strip Area)

ในส่วนของช่องตัวเลขดิจิทัล ผู้วิจัยได้ทำการครอบภาพจากมิเตอร์น้ำจริง แล้วกำหนดกรอบกำกับ (Bounding Box) เฉพาะบริเวณแถบตัวเลขเลื่อนทั้งหมด 5 หลัก เพื่อระบุตำแหน่งที่ใช้ในการอ่านค่าตัวเลข โดยกำหนดให้เป็น คลาสเดียว (Single-class) ชื่อ digital

ขั้นตอนนี้มุ่งเน้นการตรวจจับบริเวณที่เป็นหน้าตาตัวเลขเท่านั้น โดยไม่สนใจรายละเอียดของตัวเลขแต่ละหลักในภาพ เพื่อให้โมเดลสามารถแยกส่วนที่เป็น “พื้นที่อ่านค่า” ออกจากส่วนอื่นของมิเตอร์ได้อย่างแม่นยำ

การ Annotate ใช้วิธีการวาดกรอบสี่เหลี่ยมรอบช่องตัวเลขทั้งหมดในหนึ่งภาพ จากนั้นบันทึกไฟล์ฉลาก (.txt) ที่มีรูปแบบตามมาตรฐาน YOLO ได้แก่ <class_id> <x_center> <y_center> <width> <height> โดยในที่นี้ class_id ถูกกำหนดเป็น 0 สำหรับทุกภาพ เพราะมีเพียงคลาสเดียว ซึ่งค่าทั้งหมดเป็นค่าพิกัด normalized ให้อยู่ในช่วง [0,1] เพื่อให้โมเดลสามารถเรียนรู้ได้โดยไม่ขึ้นกับขนาดภาพจริง โดยโครงสร้างของชุดข้อมูลจะถูกจัดในรูปแบบเดียวกับ YOLO multi-class ได้แก่

```
dataset _digital/
├─ images/
│   └─ train/
│       └─ val/
├─ labels/
│   └─ train/
│       └─ val/
└─ data.yaml
```



รูปภาพที่ 30 ภาพตัวอย่างการ Annotate บริเวณช่องตัวเลขดิจิทัลทั้ง 5 หลัก โดยกำหนดเป็นคลาสเดียว digital ซึ่งใช้ในการฝึกโมเดล YOLO single-class เพื่อให้ระบบสามารถตรวจจับขอบเขตของช่องตัวเลขได้อย่างแม่นยำ

```
0 0.630015 0.363443 0.041138 0.078640
0 0.558405 0.363443 0.041138 0.083953
0 0.486034 0.362646 0.040630 0.079171
0 0.412138 0.363443 0.040122 0.083953
0 0.336211 0.364506 0.039614 0.081828
```

รูปภาพที่ 31 ตัวอย่างไฟล์ข้อความ Label (.txt) ของ YOLO สำหรับคลาส digital ที่ประกอบด้วยหมายเลขคลาส (0) และค่าพิกัดของกรอบ Bounding Box ในรูปแบบ normalized

ผลลัพธ์จากการฝึกโมเดล YOLO single-class จะได้โมเดล Model YOLO Single-class Digital ซึ่งสามารถตรวจจับบริเวณตัวเลขดิจิทัลในภาพมาตรฐานได้โดยอัตโนมัติ และจะถูกส่งต่อให้โมเดล CNN Digit Recognition ในขั้นตอนถัดไปสำหรับจำแนกค่าตัวเลขจริง (0-9) ต่อไป

2) กรอบภาพเฉพาะส่วนของหน้าปัดเข็มและตัวเลขดิจิทัล

หลังจากที่โมเดล YOLO สามารถตรวจจับและกรอบบริเวณที่ต้องการได้แล้ว ผู้วิจัยภาพที่ได้มาใช้สร้างชุดข้อมูลย่อยเพิ่มเติม เพื่อฝึกโมเดลเฉพาะทางในแต่ละประเภทการอ่านค่า ดังนี้


2.1) ชุดข้อมูลหน้าปัดเข็ม (Pointer Dataset) และการฝึก Pointer Regression

ในส่วนของหน้าปัดเข็ม ผู้วิจัยได้ทำการกรอบภาพเฉพาะบริเวณของหน้าปัดแต่ละช่องจากผลลัพธ์ของโมเดล YOLO จากนั้นปรับขนาดและจัดแนวภาพให้อยู่ในรูปสี่เหลี่ยมจัตุรัส เช่น 96×96 พิกเซล เพื่อเตรียมสำหรับการฝึกโมเดล CNN แบบ Regression



รูปภาพที่ 32 ตัวอย่างภาพหน้าปัดมาตรวัดแบบเข็มที่ถูกกรอบและปรับขนาดให้มีความละเอียด 96×96 พิกเซล เพื่อใช้เป็นข้อมูลนำเข้าของโมเดล CNN สำหรับการประมาณค่ามุมของเข็ม

2.1.1) การกำกับฉลาก (Labeling) ทำการกำหนด จุดสำคัญ (Keypoint) บนภาพแต่ละภาพ จำนวน 2 จุด คือ จุดศูนย์กลางของหน้าปัด (Center: C) และ จุดปลายเข็ม (Tip: T)



รูปภาพที่ 33 ตัวอย่างการกำหนดจุดสำคัญ (Keypoint Annotation) บนภาพหน้าปัด ประกอบด้วยจุดศูนย์กลางของหน้าปัด (Center: C) และจุดปลายเข็ม (Tip: T) ซึ่งใช้ในการคำนวณมุมการหมุนของเข็มในขั้นตอนการเทรนโมเดล

จากนั้นคำนวณมุมการหมุนของเข็ม (θ) โดยอ้างอิงจากแนวแกน 12 นาฬิกา เป็นศูนย์องศา และหมุนตามทิศทางคงที่ของเข็มนาฬิกา เพื่อให้การเรียนรู้ของโมเดลเป็นเชิงเส้นและต่อเนื่อง ผู้วิจัยได้ทำการแปลงค่ามุมให้อยู่ในรูปของ ค่า sine และ cosine ดังนี้

$$\text{target} = (\sin \theta, \cos \theta)$$

ผลลัพธ์ที่ได้คือไฟล์ฉลาก (Label file) ที่ประกอบด้วยพิกัดจุด C, T และค่าของ $\sin \theta, \cos \theta$ สำหรับใช้ในการฝึกโมเดล

2.1.2) การเตรียมข้อมูล

ทำการ Normalize ค่า Pixel ให้อยู่ในช่วง $[0,1]$ เพื่อให้โมเดลเรียนรู้ได้อย่างมีประสิทธิภาพและ เพิ่มความหลากหลายของข้อมูลด้วย Data Augmentation เช่น ปรับความสว่าง (brightness), ความคมชัด (contrast), เบลอ (blur), การเลื่อน (shift), และการซูม (zoom) หากมีการใช้การหมุนภาพ (rotation augmentation) จะต้อง อัปเดตค่า θ และ $(\sin \theta, \cos \theta)$ ให้สอดคล้องกับมุมใหม่ทุกครั้ง เพื่อให้ข้อมูลและ label ตรงกัน จากนั้นทำการสุ่มแบ่งชุดข้อมูลเป็น Training, Validation และ Testing ตามสัดส่วนที่เหมาะสม โดยอ้างอิงหลักการเดียวกับในโครงการ jomjol ซึ่งป้องกันไม่ให้ภาพจาก “มิเตอร์เดียวกัน” ปรากฏซ้ำในชุดข้อมูลต่างกัน เพื่อลดปัญหา data leakage ที่อาจทำให้การประเมินโมเดลคลาดเคลื่อน

2.1.3) สถาปัตยกรรมของโมเดล (CNN Pointer Regression)

โมเดลนี้ใช้โครงสร้างแบบ Convolutional Neural Network (CNN) เพื่อให้คอมพิวเตอร์สามารถ “เรียนรู้” รูปร่างและมุมของเข็มในหน้าปัดนี้ได้ โดยแทนค่ามุมของเข็มออกมาเป็นตัวเลข $\sin \theta, \cos \theta$ ซึ่งสามารถนำไปคำนวณกลับเป็นองศาจริงได้ภายหลัง

โครงสร้างของโมเดลประกอบด้วยขั้นตอนหลัก ๆ ดังนี้

(1) รับภาพอินพุต (Input Image)

โมเดลรับภาพหน้าปัดเข็มที่ถูกครอบและปรับขนาดให้เท่ากัน (เช่น 32×32 พิกเซล) ภาพแต่ละภาพจะมี 3 ช่องสี (RGB)

(2) การสกัดคุณลักษณะ (Feature Extraction)

โมเดลใช้ ชุดตัวกรอง หรือ Convolution Layer (Conv2D) เพื่อมองหา รูปร่างและลวดลายของเข็ม เช่น เส้นตรงของเข็มหรือขอบหน้าปัด แต่ละชั้นของ Conv จะมีการทำ Batch Normalization (BN) เพื่อให้การเรียนรู้เสถียร และใช้ฟังก์ชันกระตุ้น ReLU เพื่อให้โมเดลเข้าใจลักษณะเชิงซับซ้อนได้ดีขึ้น หลังจากนั้น มี MaxPooling เพื่อลดขนาดภาพ แต่ยังคงเก็บเฉพาะลักษณะที่สำคัญที่สุดไว้


(3) การรวมข้อมูล (Flatten + Dense Layers)

ข้อมูลภาพที่ผ่านการสกัดลักษณะแล้วจะถูกแปลงเป็น เวกเตอร์ตัวเลขผ่าน Flatten Layer จากนั้นส่งต่อไปยัง Dense Layer ที่มี 128 หน่วยประมวลผล เพื่อรวมข้อมูลทั้งหมดเข้าด้วยกันและเรียนรู้ความสัมพันธ์ระหว่างลักษณะของภาพกับมุมเข็ม

(4) การทำนายผลลัพธ์ (Output Layer)

ชั้นสุดท้ายมี 2 ช่องผลลัพธ์ (Linear Output) ซึ่งใช้สำหรับทำนายค่า $(\sin \theta, \cos \theta)$ ของมุมเข็ม เมื่อได้ผลลัพธ์แล้ว สามารถคำนวณมุมจริงได้จากสมการ

$$\hat{\theta} = \text{atan2}(\sin \theta, \cos \theta)$$



รูปภาพที่ 34 แสดงโครงสร้างของโมเดล CNN Pointer Regression ซึ่งใช้ Convolution หลายชั้นในการสกัดคุณลักษณะของภาพหน้าปัดเข็ม ก่อนผ่านชั้น Dense เพื่อทำนายค่า $(\sin \theta, \cos \theta)$ แทนมุมของเข็ม

โดยโมเดลนี้ทำหน้าที่ แปลงภาพหน้าปัดเข็ม $\rightarrow$ เป็นมุมการหมุนของเข็มเพื่อใช้คำนวณค่าปริมาณน้ำที่อ่านได้อย่างแม่นยำ

2.1.4) ขั้นตอนการฝึก (Model Training)

(1) **Loss Function:** Mean Squared Error (MSE) เพื่อวัดความแตกต่างระหว่างค่าจริงและค่าที่โมเดลทำนายได้ในแกน $\sin, \cos$

(2) **Optimizer:** ใช้ตัวปรับค่า Adam Optimizer โดยกำหนดอัตรา การเรียนรู้เริ่มต้น (learning rate = 1×10^{-3}) และใช้เทคนิค ReduceLROnPlateau เพื่อลดค่า Learning Rate เมื่อการเรียนรู้ไม่ดีขึ้น

(3) **Batch Size:** 32 ภาพต่อการอัปเดตน้ำหนัก

(4) **Epochs:** ฝึกทั้งหมด 50–100 รอบ พร้อมเทคนิค EarlyStopping เพื่อหยุดการฝึกอัตโนมัติเมื่อค่า loss ของชุด validation ไม่ลดลง และ ModelCheckpoint เพื่อบันทึกโมเดลที่มีประสิทธิภาพดีที่สุด

2.1.5) การคำนวณผลลัพธ์หลังการฝึก (Angle Reconstruction)

เมื่อโมเดลผ่านการฝึกแล้ว จะสามารถทำนายค่าคู่ $(\hat{s}, \hat{c})$ ซึ่งแทนค่า $\sin$ และ $\cos$ ของมุมเข็มได้ จากนั้นทำการแปลงค่าดังกล่าวกลับเป็นมุมจริงด้วยสมการ

$$\hat{\theta} = \text{atan2}(\hat{s}, \hat{c})$$

โดยมุม $\hat{\theta}$ ที่ได้คือค่ามุมการหมุนของเข็มจากตำแหน่งศูนย์ (อ้างอิงจากทิศ 12 นาฬิกา) ซึ่งเป็นผลลัพธ์สุดท้ายที่ใช้ในการอ่านค่าหน้าปัด

2.1.6) การประเมินผล (Model Evaluation) หลังจากการฝึกแล้ว จะทำการประเมินความแม่นยำของโมเดลด้วยเกณฑ์ต่อไปนี้

(1) **MAE (Mean Absolute Error):** ค่าความคลาดเคลื่อนเฉลี่ยของมุมระหว่างค่าจริงและค่าที่โมเดลทำนาย (หน่วยเป็นองศา)

(2) **RMSE (Root Mean Square Error):** วัดความแม่นยำโดยรวมของโมเดล โดยให้ความสำคัญกับความคลาดเคลื่อนที่มีค่าสูง

(3) **Accuracy ($\pm 5^\circ$):** ร้อยละของภาพที่มุมที่โมเดลทำนายมีความคลาดเคลื่อนไม่เกิน 5 องศาจากค่าจริง

ผลการฝึกและการประเมินทั้งหมดจะถูกบันทึกไว้ในไฟล์โมเดลซึ่งสามารถนำไปใช้งานในการอ่านค่าหน้าปัดเข็มจริงได้ในขั้นตอนถัดไป

2.2) ชุดข้อมูลตัวเลขดิจิทัล (Digital Dataset)

ในการเตรียมข้อมูลสำหรับฝึกโมเดลอ่านค่าตัวเลขดิจิทัล ผู้วิจัยได้ดำเนินการสร้างชุดข้อมูลจากบริเวณแถบตัวเลขของมิเตอร์น้ำ โดยเริ่มจากการครอบ (Crop) บริเวณตัวเลขดิจิทัลที่ตรวจจับได้จากโมเดล YOLO single-class จากนั้นนำภาพที่ได้มาจัดระเบียบและแบ่งออกเป็นชุดย่อย เพื่อใช้ในการฝึกโมเดล Convolutional Neural Network (CNN) สองรูปแบบ ได้แก่ ชุดข้อมูลตัวเลขหลัก (Digit Dataset) สำหรับจำแนกค่าตัวเลข 0–9 และ NaN และชุดข้อมูลเลขที่กำลังเลื่อน (Transition Dataset) สำหรับจำแนกเลขที่อยู่ในช่วงเปลี่ยนผ่าน เช่น $9 \rightarrow 0$, $2 \rightarrow 3$ เป็นต้น


2.2.1) ชุดข้อมูลตัวเลขหลัก (Digit Dataset)

(1) การเตรียมข้อมูล (Data Preparation)

ภาพแถบตัวเลขที่ได้จากการครอบด้วยโมเดล YOLO จะถูกแบ่งย่อยเป็นภาพของตัวเลขแต่ละหลัก จากนั้นปรับขนาดภาพให้คงที่ เช่น 32×20 พิกเซล เพื่อให้ตรงกับขนาดอินพุตของโมเดล CNN ภาพทั้งหมดถูกปรับค่า Pixel ให้อยู่ในช่วง $[0, 1]$ และทำ Data Augmentation เพื่อเพิ่มความหลากหลายของข้อมูล เช่น การปรับความสว่าง (Brightness) การปรับความคมชัด (Contrast) การเบลอภาพ (Blur) การเลื่อน (Shift) การซูม (Zoom) และการหมุนเล็กน้อย (Rotation)

ในการแบ่งชุดข้อมูล ผู้วิจัยได้ทำการ สุ่มแบ่งข้อมูลออกเป็นสองส่วนหลัก ได้แก่ ชุดข้อมูลฝึก (Training Set) ประมาณ 90% ของข้อมูลทั้งหมด เพื่อใช้ในการเรียนรู้ลักษณะของตัวเลขแต่ละคลาส และชุดข้อมูลทดสอบ (Testing Set) ประมาณ 10% ของข้อมูลทั้งหมด สำหรับประเมินประสิทธิภาพของโมเดลหลังการฝึก


การแบ่งข้อมูลใช้ฟังก์ชัน `train_test_split()` จากไลบรารี `scikit-learn` ซึ่งช่วยให้ข้อมูลของแต่ละคลาสถูกกระจายอย่างสมดุลทั้งในชุดฝึกและชุดทดสอบ ทั้งนี้ ในระหว่างการฝึกยังมีการใช้กลไก Validation Data ภายใน `ImageDataGenerator` เพื่อประเมินค่าความสูญเสีย (Loss) ของโมเดลในแต่ละรอบการเรียนรู้ (Epoch) ซึ่งช่วยให้สามารถปรับปรุงสมดุลของโมเดลได้อย่างเหมาะสม และลดความเสี่ยงของการเรียนจำข้อมูลเดิม (Overfitting)



รูปภาพที่ 35 ตัวอย่างภาพตัวเลขดิจิทัลที่ถูกครอบและปรับขนาดก่อนใช้ในการฝึกโมเดล

(2) การกำหนดฉลากข้อมูล (Label Definition)

ชุดข้อมูลตัวเลขหลักถูกจัดเก็บแยกตามโฟลเดอร์ของตัวเลขแต่ละค่า ได้แก่ 0–9 และ NaN (Not a Number) รวมทั้ง 11 คลาส โดยคลาส NaN ใช้แทนกรณีที่ตัวเลขเบลอหรืออยู่ในช่วงเปลี่ยนผ่านซึ่งไม่สามารถระบุค่าได้แน่ชัด




รูปภาพที่ 36 ตัวอย่างโครงสร้างโฟลเดอร์ของชุดข้อมูลตัวเลขหลัก (0–9 และ NaN)

(3) สถาปัตยกรรมของโมเดล (CNN Architecture)

โมเดล CNN ที่ใช้ในส่วนนี้ออกแบบมาสำหรับการจำแนกตัวเลขขนาดเล็กโดย

มีโครงสร้างดังนี้



รูปภาพที่ 37 สถาปัตยกรรมของโมเดล Convolutional Neural Network (CNN) สำหรับการจำแนกตัวเลข
ที่มา: ดัดแปลงจาก jomjol (2021)

รายละเอียดขั้นตอนการทำงาน

- **Input Layer** ($32 \times 20 \times 3$) อินพุตคือภาพขนาด 32 พิกเซล $\times$ 20 พิกเซล 3 ช่องสี (RGB) ทำหน้าที่รับภาพของตัวเลขที่ถูกครอบ (crop) มาจากส่วนดิจิทัลของมิเตอร์น้ำ

- **Batch Normalization** ปรับค่าสเกลของพิกเซลให้อยู่ในช่วงที่เหมาะสมก่อนเข้าสู่ชั้นคอนโวลูชัน ลดปัญหา internal covariate shift ทำให้โมเดลเรียนรู้ได้เร็วและเสถียรมากกว่าเดิม

- **Convolutional Layer 1** — Conv2D ($3 \times 3 \times 32$) + ReLU ใช้ฟิลเตอร์ 3×3 จำนวน 32 ตัว เพื่อสกัดคุณลักษณะพื้นฐาน เช่น เส้นขอบ หรือ รูปร่างของตัวเลข ReLU (Rectified Linear Unit) ทำหน้าที่ตัดค่าลบออก $\rightarrow$ ช่วยให้โมเดลเรียนรู้ลักษณะเชิงบวกที่มีความสำคัญ และขนาดผลลัพธ์ คือ $32 \times 20 \times 32$

- **MaxPooling** (2×2) ลดขนาดภาพลงครึ่งหนึ่ง (เลือกค่าพิกเซลที่มากที่สุดในแต่ละบล็อก 2×2) ช่วยลดจำนวนพารามิเตอร์และเพิ่มความทนทานต่อการเลื่อนหรือเอียงของภาพ และขนาดผลลัพธ์คือ $16 \times 10 \times 32$

- **Convolutional Layer 2** — Conv2D ($3 \times 3 \times 64$) + ReLU เพิ่มจำนวนฟิลเตอร์เป็น 64 เพื่อสกัดคุณลักษณะระดับสูงขึ้น เช่น ส่วนโค้ง หรือ ลักษณะเฉพาะของแต่ละตัวเลข และขนาดผลลัพธ์คือ $16 \times 10 \times 64$

- **MaxPooling** (2×2) ลดขนาดภาพลงอีกครั้งหนึ่งให้ขนาดผลลัพธ์คือ $8 \times 5 \times 64$

- **Convolutional Layer 3** — Conv2D (3×3×64) + ReLU ชั้นนี้ช่วยรวมลดลายเชิงลึกจากหลายจุดของภาพ เพื่อให้เข้าใจรูปร่างโดยรวมของตัวเลข และขนาดผลลัพธ์คือ 8×5×64
- **MaxPooling** (2×2) ลดขนาดข้อมูลลงเหลือเพียงจุดสำคัญที่สุด
ขนาดผลลัพธ์คือ 4×2×64
- **Flatten Layer** แปลงข้อมูลสามมิติ (4×2×64 = 512 หน่วย) ให้เป็นเวกเตอร์ 1 มิติ เพื่อเตรียมส่งเข้าสู่ชั้นเชื่อมต่อต่อเติม (Fully Connected Layer)
- **Fully Connected Layer** (512 หน่วย + ReLU) ทำหน้าที่รวมคุณลักษณะทั้งหมดเข้าด้วยกัน เพื่อเรียนรู้ความสัมพันธ์ระหว่างลักษณะของตัวเลข ใช้ ReLU อีกครั้งเพื่อเพิ่มความไม่เชิงเส้น
- **Output Layer** (11 หน่วย + Softmax) เอาต์พุต 11 หน่วย แทนค่าความน่าจะเป็นของแต่ละคลาส (0–9 + NaN) Softmax ทำให้ค่าผลลัพธ์รวมกันได้ = 1 โดยเลือกคลาสที่มีค่าสูงสุดเป็นคำตอบสุดท้าย

```

55 # ==== MODEL ====
56 model = Sequential()
57 model.add(BatchNormalization(input_shape=(32,20,3)))
58 model.add(Conv2D(32, (3, 3), padding='same', activation="relu"))
59 model.add(MaxPool2D(pool_size=(2,2)))
60 model.add(Conv2D(64, (3, 3), padding='same', activation="relu"))
61 model.add(MaxPool2D(pool_size=(2,2)))
62 model.add(Conv2D(64, (3, 3), padding='same', activation="relu"))
63 model.add(MaxPool2D(pool_size=(2,2)))
64 model.add(Flatten())
65 model.add(Dense(512,activation="relu"))
66 model.add(Dense(11, activation = "softmax"))
67 model.summary()
68
69 model.compile(
70     loss=tf.keras.losses.categorical_crossentropy,
71     optimizer=tf.keras.optimizers.Adadelta(learning_rate=1.0, rho=0.95),
72     metrics=["accuracy"]
73 )

```

รูปภาพที่ 38 ตัวอย่างโค้ดที่ใช้สร้างสถาปัตยกรรมและคอมไพล์โมเดล Convolutional Neural Network (CNN) โดยใช้ TensorFlow/Keras สำหรับจำแนกภาพตัวเลขดิจิทัล (0–9 และ NaN)

(3.1) การฝึกโมเดล (Model Training)

หลังจากออกแบบสถาปัตยกรรมของโมเดลแล้ว ผู้วิจัยได้ทำการฝึก (Training) โมเดลด้วยชุดข้อมูลตัวเลขที่ผ่านการเตรียมและกำหนดฉลากเรียบร้อยแล้ว โดยมีการตั้งค่าพารามิเตอร์การฝึกดังนี้

```
history = model.fit(train_iterator, validation_data=validation_iterator, epochs=Epoch_Anz)

loss_ges = np.append(loss_ges, history.history['loss'])
val_loss_ges = np.append(val_loss_ges, history.history['val_loss'])
plt.semilogy(history.history['loss'])
plt.semilogy(history.history['val_loss'])
plt.title('model loss')
plt.ylabel('loss')
plt.xlabel('epoch')
plt.legend(['train', 'eval'], loc='upper left')
plt.show()
```

รูปภาพที่ 39 ตัวอย่างโค้ดที่ใช้สำหรับการฝึกโมเดล Convolutional Neural Network (CNN) พร้อมการแสดงผลกราฟค่าการสูญเสีย (Loss) ของชุดข้อมูลฝึกและชุดตรวจสอบในแต่ละรอบการเรียนรู้ (Epoch)

- **Loss Function:** ใช้ Categorical Cross-Entropy สำหรับการจำแนกหลายคลาส (multi-class classification)
- **Optimizer:** ใช้ Adam Optimizer โดยกำหนด learning rate = 1×10^{-3} เพื่อปรับค่าน้ำหนักของโมเดลให้เหมาะสมในแต่ละรอบการเรียนรู้
- **Batch Size:** 4 ภาพต่อรอบการอัปเดตน้ำหนัก
- **Epochs:** 80–100 รอบ หรือจนกว่าค่าการสูญเสีย (Loss) จะคงที่
- **Augmentation:** ใช้ข้อมูลจาก ImageDataGenerator ซึ่งมีการปรับสว่าง (Brightness), ขยาย (Zoom), หมุน (Rotation) และเลื่อนตำแหน่ง (Shift) แบบสุ่ม เพื่อเพิ่มความหลากหลายของข้อมูลและลดการเกิด overfitting
- **Validation:** ระหว่างการฝึกมีการใช้ชุด Validation เพื่อประเมินประสิทธิภาพของโมเดลในแต่ละ Epoch

นอกจากนี้ ยังมีการใช้เทคนิค EarlyStopping เพื่อหยุดการฝึกอัตโนมัติเมื่อค่าความสูญเสียของชุด Validation ไม่ลดลง และ ModelCheckpoint เพื่อบันทึกโมเดลที่ให้ผลลัพธ์ดีที่สุดไว้ใช้งาน

(4) การประเมินผล (Model Evaluation)

หลังจากทำการฝึกโมเดลเสร็จสิ้น ผู้วิจัยทำการประเมินประสิทธิภาพของโมเดล ด้วยชุดข้อมูลทดสอบ โดยใช้เกณฑ์การวัดผลต่าง ๆ ได้แก่

- Accuracy (%): ความแม่นยำในการจำแนกตัวเลขทั้งหมด
- Precision /Recall / F1-Score: ประสิทธิภาพการทำนายแต่ละคลาส
- Confusion Matrix: ใช้ตรวจสอบข้อผิดพลาดระหว่างคลาสต่าง ๆ

2.2.2) ชุดข้อมูลเลขที่กำลังเลื่อน (Transition Dataset)

ชุดข้อมูลเลขที่กำลังเลื่อน (Transition Dataset) ถูกจัดเตรียมขึ้นเพื่อแก้ปัญห การอ่านค่าที่คลาดเคลื่อนในช่วงที่ตัวเลขบนมิเตอร์น้ำกำลัง “เปลี่ยนค่า” ระหว่างหลัก เช่น 9→0, 1→2 หรือ mAP ซึ่งเป็นช่วงที่เส้นขอบระหว่างตัวเลขสองหลักปรากฏพร้อมกันในภาพ ทำให้โมเดล จำแนกตัวเลข (Digit Recognition Model) ปกติไม่สามารถระบุค่าได้แน่ชัด ผู้วิจัยจึงพัฒนาโมเดลเสริมที่ เรียกว่า Transition Model หรือ Pair Model เพื่อให้ระบบสามารถแยกแยะภาพในช่วงเปลี่ยนผ่านนี้ได้ อย่างถูกต้องมากขึ้น และใช้ผลลัพธ์ร่วมกับโมเดลหลักในการตัดสินใจที่อ่านได้สุดท้าย

(1) การเตรียมข้อมูล (Data Preparation)

ชุดข้อมูล Transition ถูกสร้างจากวิดีโอของมาตรวัดช่วงที่ตัวเลข “กำลังเลื่อน เปลี่ยนหลัก” (เช่น 1→2, 9→0) โดยมีขั้นตอนดังนี้

ขั้นที่ 1 แยกเฟรมจากวิดีโอ (FFmpeg) เลือกช่วงเวลาที่มีการเปลี่ยนเลข (เช่น 01:10-01:14) แล้วแตกวิดีโอเป็นภาพนิ่งทุก 1 วินาที ผลลัพธ์ที่ได้จะเป็นไฟล์ภาพต่อเนื่อง out_0000001.png, out_0000002.png, ... ครอบคลุมช่วงที่หน้าปัดกำลังเลื่อน

```
s\ffmpeg>
s\ffmpeg>cd bin
s\ffmpeg\bin>ffmpeg -ss 01:10:24 -to 01:14:39 -i ../IMG_4113.mov -vf "transpose=1,fps=1" ../pcic/output_%07d.png_
```

รูปภาพที่ 40 ตัวอย่างคำสั่งในโปรแกรม FFmpeg สำหรับแยกเฟรมภาพจากวิดีโอในช่วงเวลาที่ตัวเลขบน หน้าปัดมิเตอร์กำลังเปลี่ยนค่า โดยตั้งค่าให้ดึงภาพออกมาทุก 1 วินาที

ขั้นที่ 2 คัดลอกเฉพาะตำแหน่งตัวเลข + ปรับขนาด (Python) คัดลอกเฉพาะ
ช่องตัวเลขที่สนใจ แล้ว resize เป็น 32×20 พิกเซล (ให้ตรงกับอินพุตของโมเดล CNN) ผลลัพธ์ที่ได้จะ
เป็นภาพขนาด 32×20 พิกเซล พร้อมสำหรับจัดลงโฟลเดอร์ตามคลาสตัวเลข (0→1, ..., 9→0)

```
# loop ทุกไฟล์ในโฟลเดอร์
for filename in sorted(os.listdir(input_folder)):
    if filename.lower().endswith(".png"): # เอาเฉพาะไฟล์ PNG
        input_path = os.path.join(input_folder, filename)
        output_path = os.path.join(output_folder, filename)

        # เปิดรูป
        img = Image.open(input_path)

        # crop
        cropped = img.crop(crop_box)


        # resize
        resized = cropped.resize((20, 32), Image.Resampling.LANCZOS)

        # บันทึก
        resized.save(output_path)

        print(f"Saved: {output_path}")

print("เสร็จสิ้นการคัด + resize ภาพทั้งหมด")
```


รูปภาพที่ 41 ตัวอย่างโค้ดภาษา Python สำหรับคัดลอกเฉพาะบริเวณช่องตัวเลขของมิเตอร์น้ำและปรับขนาด
ภาพเป็น 32×20 พิกเซล เพื่อเตรียมข้อมูลสำหรับการฝึกโมเดล CNN ในขั้นตอนถัดไป



รูปภาพที่ 42 ตัวอย่างภาพตัวเลขในช่วงเปลี่ยนหลัก 9→0 ที่ใช้ในการฝึกโมเดล Transition

(2) การกำหนดฉลากข้อมูล (Label Definition)

หลังจากได้ภาพในช่วงที่ตัวเลขกำลังเลื่อนจากขั้นตอนก่อนหน้าแล้ว ข้อมูลทั้งหมดจะถูกจัดหมวดหมู่เป็นคลาส (Class) ตามลักษณะของ “คู่ตัวเลขที่กำลังเปลี่ยนผ่าน” โดยผู้วิจัยกำหนดให้มีทั้งหมด 10 คลาส แทนคู่การเปลี่ยนเลข ซึ่งแต่ละคลาสจะเก็บอยู่ในโฟลเดอร์ย่อยแยกกัน เพื่อให้โมเดลสามารถเรียนรู้ลักษณะเฉพาะของการเปลี่ยนเลขแต่ละคู่ได้อย่างถูกต้อง ตัวอย่างเช่น โฟลเดอร์ 1to2 เก็บภาพในช่วงที่ตัวเลขจาก 1 กำลังเปลี่ยนเป็น 2



รูปภาพที่ 43 ตัวอย่างโครงสร้างโฟลเดอร์ของชุดข้อมูลเลขที่กำลังเลื่อน (Transition Dataset) ซึ่งแบ่งตามคลาสของคู่ตัวเลขตั้งแต่ 0→1 จนถึง 9→0

(3) สถาปัตยกรรมของโมเดล (CNN Architecture)

โมเดลที่ใช้สำหรับการจำแนกช่วงการเปลี่ยนเลขนี้ออกแบบโดยอิงจากโครงสร้างพื้นฐานของ Convolutional Neural Network (CNN) ซึ่งใกล้เคียงกับโมเดลที่ใช้ในชุด Digit Dataset แต่ปรับจำนวนหน่วยในชั้น Fully Connected และ Output ให้เหมาะสมกับจำนวนคลาส 10 คลาส

```
model = Sequential(name="PairAB_Keras")
model.add(BatchNormalization(input_shape=(IMG_H, IMG_W, CHANNELS)))
model.add(Conv2D(32, (3,3), padding="same", activation="relu"))
model.add(MaxPool2D((2,2)))
model.add(Conv2D(64, (3,3), padding="same", activation="relu"))
model.add(MaxPool2D((2,2)))
model.add(Conv2D(64, (3,3), padding="same", activation="relu"))
model.add(MaxPool2D((2,2)))
model.add(Flatten())
model.add(Dense(512, activation="relu"))
model.add(Dropout(0.1))
model.add(Dense(10, activation="softmax")) # 10 คลาส (pair id=a)
model.summary()
```

รูปภาพที่ 44 แสดงโครงสร้างโมเดล CNN Pair / Transition Model ที่ใช้ในการจำแนกการเปลี่ยนผ่านของตัวเลข

รายละเอียดโครงสร้างของโมเดลมีดังนี้

- **Input Layer:** ขนาดอินพุต 32×20 พิกเซล (RGB)
- **Conv2D Layer:** จำนวน 3 ชั้น ใช้ฟิลเตอร์ขนาด 3×3 พร้อมฟังก์ชันกระตุ้น ReLU และมี Batch Normalization เพื่อปรับสมดุลข้อมูลก่อนเข้าสู่แต่ละชั้น
- **MaxPooling Layer:** จำนวน 3 ชั้น เพื่อลดขนาด Feature Map และลดจำนวนพารามิเตอร์
- **Flatten Layer:** แปลงข้อมูลจาก 3 มิติให้เป็นเวกเตอร์ 1 มิติ
- **Dense Layer:** 256 หน่วย พร้อม ReLU สำหรับรวมคุณลักษณะและเรียนรู้ความสัมพันธ์เชิงลึกของข้อมูล
- **Output Layer:** 10 หน่วย พร้อม Softmax Activation เพื่อจำแนกผลลัพธ์ออกเป็น 10 คลาสของคู่ตัวเลข

(3.1) การฝึกโมเดล (Model Training)

หลังจากออกแบบสถาปัตยกรรมของโมเดลแล้ว ผู้วิจัยได้ทำการฝึก (Training) โมเดลด้วยชุดข้อมูลภาพของตัวเลขที่ผ่านการปรับขนาดเป็น 32×20 พิกเซลและจัดหมวดหมู่เรียบร้อยแล้ว โดยใช้ฟังก์ชันสูญเสียแบบ Categorical Cross-Entropy และ Optimizer แบบ Adam (learning rate = 1×10^{-3}) การฝึกโมเดลกำหนดจำนวนรอบการเรียนรู้สูงสุดที่ 80 Epochs โดยใช้ Batch Size = 16 ภาพต่อรอบ พร้อมทั้งใช้เทคนิคการสุ่มลำดับข้อมูล (Shuffle) เพื่อป้องกันไม่ให้โมเดลจดจำลำดับของข้อมูลและช่วยให้การเรียนรู้มีความทั่วไประหว่างการฝึก

นอกจากนี้ยังได้กำหนดการแบ่งชุดข้อมูลแบบ Sequence-wise Split โดยใช้สัดส่วน Training : Validation = 8 : 2 เพื่อใช้ประเมินประสิทธิภาพของโมเดลระหว่างการฝึก โดยมีการใช้กลไก Early Stopping เพื่อหยุดการฝึกเมื่อประสิทธิภาพของโมเดลไม่ดีขึ้นเพิ่มเติม และเลือกโมเดลที่ให้ผลดีที่สุดจากช่วงการฝึก

```
os.makedirs(os.path.dirname(MODEL_SAVE_PATH), exist_ok=True)
os.makedirs(OUT_DIR, exist_ok=True)

# ===== CONFIG =====
IMG_H, IMG_W = 32, 20
CHANNELS = 1
VAL_RATIO = 0.2
SEED = 42
EPOCHS = 80
BATCH = 16
LR = 1e-3
AUG_LIGHT = True
```

รูปภาพที่ 45 ตัวอย่างโค้ดการฝึกโมเดล CNN Transition / Pair Model

(4) การประเมินผล (Model Evaluation)

ในขั้นตอนการประเมินผล ผู้วิจัยจะทำการทดสอบความแม่นยำของโมเดลที่ผ่านการฝึกแล้ว ทั้งบนชุดข้อมูลฝึก (Training Set) และชุดข้อมูลตรวจสอบ (Validation Set) เพื่อยืนยันว่าโมเดลสามารถเรียนรู้ลักษณะของข้อมูลได้จริงและสามารถจำแนกภาพที่ไม่เคยเห็นมาก่อนได้อย่างถูกต้อง โดยใช้โค้ดสำหรับคำนวณค่าความแม่นยำ (Accuracy) ดังแสดงในภาพที่ 45

```
# ===== Evaluate on TRAIN (memorization check) =====
print("\n=== Evaluate on TRAIN set (memorization check) ===")
pred_train = model.predict(X_train, batch_size=64, verbose=0)
pred_lbl = np.argmax(pred_train, axis=1)
true_lbl = np.argmax(y_train, axis=1)
acc_train = (pred_lbl == true_lbl).mean()
print(f"Train accuracy = {acc_train*100:.2f}% ({pred_lbl.size} samples)")

# ===== Evaluate on VAL =====
if X_val is not None:
    print("\n=== Evaluate on VALIDATION set ===")
    pred_val = model.predict(X_val, batch_size=64, verbose=0)
    pred_lbl_v = np.argmax(pred_val, axis=1)
    true_lbl_v = np.argmax(y_val, axis=1)
    acc_val = (pred_lbl_v == true_lbl_v).mean()
    print(f"Val accuracy = {acc_val*100:.2f}% ({pred_lbl_v.size} samples)")
```

รูปภาพที่ 46 ตัวอย่างโค้ดสำหรับการประเมินความแม่นยำของโมเดลบนชุดข้อมูลฝึก (Training Set) และชุดข้อมูลตรวจสอบ (Validation Set) เพื่อทดสอบความสามารถของโมเดลในการจดจำและจำแนกภาพช่วงการเปลี่ยนผ่านของตัวเลขได้อย่างถูกต้อง

3.2.5.3 การประเมินผลโมเดล (Model Evaluation)

ในการประเมินประสิทธิภาพของโมเดล ได้ใช้ตัวชี้วัดมาตรฐาน (Standard Metrics) ได้แก่ Accuracy, Precision, Recall, F1-Score และค่า mAP (Mean Average Precision) เพื่อสะท้อนความสามารถของโมเดลในการตรวจจับและจำแนกวัตถุ นอกจากนี้ยังได้ใช้ตัวชี้วัดเชิงโดเมน (Domain-specific Metrics) ได้แก่ Per-digit Accuracy, Pair Confidence, Consistency Check, Angle Error และ End-to-End Accuracy เพื่อให้ได้การประเมินที่ครอบคลุมบริบทของการอ่านค่ามาตรน้ำจริง การประเมินผลดำเนินการโดยใช้ชุดข้อมูล Test Set และทดสอบเพิ่มเติมกับภาพถ่ายจากกล้องสมาร์ทโฟน เพื่อยืนยันความสามารถในการใช้งานจริง

3.2.5.4 การรวมผลลัพธ์ (Fusion of Digital and Analog Readings)


ผลการอ่านค่ามาตรน้ำถูกแบ่งออกเป็นสองส่วน ได้แก่ Digital Reading ซึ่งได้ค่าจำนวนเต็ม (Integer) จากแถบดิจิทัล และ Analog Reading ซึ่งได้ค่าทศนิยมจากหน้าปัดเข็มย่อย โดยค่าทศนิยมนี้ยังมีบทบาทสำคัญในการช่วยตรวจสอบการ Carry-over ของหลักดิจิทัล กระบวนการ Fusion จะทำให้ค่าที่ได้มีความสอดคล้องและความแม่นยำสูงขึ้น สามารถสะท้อนปริมาณการใช้น้ำได้ใกล้เคียงความเป็นจริงมากกว่าอ่านจากเพียงช่องทางใดช่องทางหนึ่ง

3.2.5.5 การออกแบบ Web Application ให้ใช้งานผ่าน Mobile WebView

เพื่อรองรับการใช้งานระบบอ่านคำมีเตอร์น้ำอัตโนมัติในภาคสนาม โครงการนี้ได้ออกแบบ Web Application ของระบบ AquaRead ให้สามารถใช้งานผ่าน Mobile WebView บนอุปกรณ์พกพา โดยนำ Web Application ที่พัฒนาด้วย Django Framework มาแสดงผลภายใน Mobile Application โดยไม่มีการพัฒนา Mobile Application แบบ Native แยกต่างหาก

แนวทางดังกล่าวช่วยให้ระบบสามารถใช้โค้ดฐานเดียวกันสำหรับการใช้งานทั้งบน Web Browser และ Mobile WebView โดยการประมวลผลทั้งหมด เช่น การตรวจจับวัตถุด้วยโมเดล YOLOv8 การจำแนกตัวเลขด้วยโมเดล CNN และการจัดเก็บข้อมูล ยังคงดำเนินการบนฝั่งเซิร์ฟเวอร์เช่นเดียวกัน ส่งผลให้ลดความซับซ้อนและต้นทุนในการพัฒนาระบบ

การออกแบบส่วนติดต่อผู้ใช้ของ Web Application ได้คำนึงถึงข้อจำกัดของอุปกรณ์พกพา โดยมีการปรับการแสดงผลให้รองรับ Responsive Design และการโต้ตอบผ่านหน้าจอสัมผัส เพื่อให้เหมาะสมกับการใช้งานจริงในภาคสนาม ทั้งนี้แนวทางดังกล่าวเหมาะสมกับโครงการในระดับต้นแบบและสามารถนำไปต่อยอดในอนาคตได้




รูปภาพที่ 47 สถาปัตยกรรมการออกแบบ Web Application ให้ใช้งานผ่าน Mobile WebView ของระบบ AquaRead โดย Mobile Application ทำหน้าที่เป็น WebView Container สำหรับแสดงผล Web Application ขณะที่การรับ-ส่งข้อมูลและการประมวลผลด้วยปัญญาประดิษฐ์ดำเนินการบน Backend Server ผ่าน REST API

3.2.5.6 การออกแบบส่วนติดต่อผู้ใช้ (User Interface Design)


การออกแบบส่วนติดต่อผู้ใช้ (User Interface: UI) ของระบบ AquaRead มุ่งเน้นให้ผู้ใช้สามารถใช้งานระบบได้สะดวกผ่านอุปกรณ์พกพา โดยโครงสร้างหน้าจอถูกออกแบบให้สอดคล้องกับลำดับการทำงานของระบบ และรองรับการแสดงผลผ่าน Mobile WebView โดย UI ของระบบประกอบด้วยหน้าจอหลักดังนี้

(1) หน้า Home / สถานะระบบ




รูปภาพที่ 48 ตัวอย่างหน้าจอหลัก (Home Screen) ของระบบ AquaRead แสดงสถานะการใช้น้ำโดยรวม และเมนูนำทางหลักของระบบ ซึ่งออกแบบให้เหมาะสมกับการใช้งานผ่าน Mobile WebView

(2) หน้าเมนูบริการ (Service)




รูปภาพที่ 49 หน้าจอเมนูบริการ (Service Screen) สำหรับเลือกการทำงานของระบบ เช่น การบันทึกค่า มิเตอร์ การตรวจสอบค่าที่ผิดปกติ และการดูรายการห้อง

(3) หน้า Upload / ตรวจสอบ



รูปภาพที่ 50 หน้าจอสำหรับอัปโหลดหรือบันทึกภาพมิเตอร์น้ำผ่านกล้องหรือไฟล์ภาพ เพื่อส่งข้อมูลเข้าสู่กระบวนการประมวลผล

(4) หน้าแสดงผลการอ่านค่า



รูปภาพที่ 51 หน้าจอแสดงผลการอ่านค่ามิเตอร์น้ำหลังจากการประมวลผลด้วยโมเดลปัญญาประดิษฐ์

(5) หน้ารายงานผล




รูปภาพที่ 52 หน้าจอรายงานผลการตรวจจบ แสดงรายละเอียดค่าตัวเลขดิจิทัลและค่าทศนิยมจากหน้าปัดมิเตอร์น้ำ

(6) หน้าแจ้งเตือน



รูปภาพที่ 53 หน้าจอการแจ้งเตือน แสดงเหตุการณ์ที่ระบบตรวจพบค่าการใช้น้ำที่ผิดปกติ

(7) หน้าการตั้งค่า



รูปภาพที่ 54 หน้าจอการตั้งค่าและจัดการข้อมูลผู้ใช้งานของระบบ AquaRead

จากรายละเอียดที่นำเสนอในบทนี้ โครงการได้ดำเนินการออกแบบและพัฒนาระบบอ่านคำมีเตอร์น้ำอัตโนมัติ AquaRead อย่างครบถ้วน ตั้งแต่สถาปัตยกรรมของระบบ การประมวลผลภาพด้วยเทคนิค Image Processing และปัญญาประดิษฐ์ การเชื่อมต่อระหว่าง Web Application และ Backend Server ไปจนถึงการออกแบบส่วนติดต่อผู้ใช้ที่รองรับการใช้งานผ่าน Mobile WebView บนอุปกรณ์พกพา โดยรูปแบบหน้าจอที่นำเสนอแสดงให้เห็นถึงลำดับการใช้งานจริงของระบบ ตั้งแต่การบันทึกและอัปโหลดภาพ การแสดงผลการอ่านค่า การสรุปข้อมูล การแจ้งเตือน ไปจนถึงการตั้งค่าระบบ ซึ่งสะท้อนถึงความพร้อมของระบบในระดับต้นแบบสำหรับการใช้งานภาคสนาม

ทั้งนี้ ผลการทดสอบและประเมินประสิทธิภาพของโมดูลต่าง ๆ รวมถึงผลการทำงานของระบบโดยรวม จะนำเสนอและวิเคราะห์ในบทถัดไป

บทที่ 4

ผลการดำเนินงาน

4.1 ผลการทำงานของระบบ (System Results)

ผู้วิจัยได้พัฒนาและทดสอบระบบ “AquaRead” ครอบคลุมตามแผนที่กำหนด โดยครอบคลุมตั้งแต่การตรวจจับวัตถุ การจำแนกตัวเลข การประมาณค่ามุมเข็ม ไปจนถึงการพัฒนาเว็บแอปพลิเคชันสำหรับใช้งานจริง ระบบสามารถทำงานได้แบบครบวงจรตั้งแต่รับภาพ ประมวลผล ไปจนถึงแสดงผลและบันทึกข้อมูลอัตโนมัติ

ในส่วนของการตรวจจับวัตถุ ได้ฝึกโมเดล YOLOv8 สำหรับตรวจจับช่องตัวเลขดิจิทัลและหน้าปัดเข็ม แบบหลายคลาส ซึ่งสามารถระบุตำแหน่งวัตถุได้อย่างแม่นยำและเสถียรภายใต้สภาพแสงที่แตกต่างกัน สำหรับการจำแนกตัวเลข โมเดล CNN ให้ค่าความแม่นยำประมาณ 94.7% และโมเดลช่วงเปลี่ยนเลขมีความแม่นยำประมาณ 94.65% ส่วนการประมาณมุมเข็มด้วย Regression Model มีค่าความคลาดเคลื่อนเฉลี่ยประมาณ ± 3 องศา

นอกจากนี้ Web Application สามารถรองรับกระบวนการอัปโหลดภาพ ตรวจจับ ประมวลผล บันทึกข้อมูล และส่งออกไฟล์ CSV ได้อย่างสมบูรณ์ ภายใต้สถาปัตยกรรมแบบ Thin Client โดยรวม ระบบสามารถทำงานได้ตามวัตถุประสงค์ที่กำหนด และมีประสิทธิภาพเพียงพอสำหรับการประยุกต์ใช้งานจริง

4.2 ผลการดำเนินงานของโมดูลปัญญาประดิษฐ์ (AI Module Results)

4.2.1 การตรวจจับหน้าปัดเข็ม (Pointer Detection Model / YOLOv8-multi class)

โมเดล YOLOv8 ถูกฝึกเพื่อการตรวจจับหน้าปัดเข็มของมิเตอร์น้ำในแต่ละช่อง (Class 1 – 3) โดยไม่รวม Class 0 เพื่อให้สอดคล้องกับการใช้งานจริง กระบวนการฝึกใช้ภาพจริงที่ผ่านการครอบและจัดฉากอย่างถูกต้องจำนวนหลายพันภาพ ผลการฝึกตลอด 200 รอบ แสดงพฤติกรรมการลดลงของค่าการสูญเสีย (Box Loss, Cls Loss, DFL Loss) และแนวโน้มของ Precision, Recall และ mAP ที่เพิ่มขึ้นอย่างต่อเนื่อง

4.2.1.1 การวิเคราะห์กราฟผลการฝึกโมเดล


กราฟผลการฝึกของโมเดล YOLOv8 สามารถแบ่งการวิเคราะห์ออกเป็น 3 กลุ่มหลัก ได้แก่ กลุ่มค่าความสูญเสียของชุดฝึก (Training Loss) กลุ่มค่าความสูญเสียของชุดตรวจสอบ (Validation Loss) และกลุ่มตัวชี้วัดประสิทธิภาพของโมเดล (Performance Metrics)

1) กลุ่ม Training Loss ประกอบด้วย ค่า train/box_loss, train/cls_loss และ train/dfloss ซึ่งใช้สำหรับประเมินพฤติกรรมการเรียนรู้ของโมเดลระหว่างกระบวนการฝึก

ค่า train/box_loss แสดงค่าความคลาดเคลื่อนในการทำนายตำแหน่ง Bounding Box ของวัตถุ โดยค่าที่ลดลงอย่างต่อเนื่องแสดงให้เห็นว่าโมเดลสามารถระบุตำแหน่งของหน้าปัดเข็มได้แม่นยำมากขึ้นตามจำนวนรอบการฝึก


ค่า train/cls_loss แสดงค่าความคลาดเคลื่อนในการจำแนกประเภทของวัตถุในแต่ละคลาส การลดลงของค่า cls_loss บ่งชี้ว่าโมเดลสามารถเรียนรู้และจำแนกหน้าปัดเข็มในแต่ละคลาสได้ถูกต้องมากขึ้น

ค่า train/df_loss เป็นค่า Distribution Focal Loss ซึ่งถูกใช้ใน YOLOv8 เพื่อเพิ่มความแม่นยำในการทำนายตำแหน่ง Bounding Box การลดลงของค่า df_loss แสดงให้เห็นว่าโมเดลสามารถประมาณตำแหน่งของวัตถุได้แม่นยำขึ้น



รูปภาพที่ 55 กราฟ Training Loss ของโมเดลYOLOv8 แสดงแนวโน้มการลดลงของค่า loss ระหว่างการฝึก

2) กลุ่ม Validation Loss ประกอบด้วยค่า val/box_loss , val/cls_loss และ val/df_loss ซึ่งใช้สำหรับประเมินประสิทธิภาพของโมเดลกับชุดข้อมูลที่ไม่เคยใช้ในการฝึก จากผลการทดลองพบว่าค่า Loss ของชุด Validation มีแนวโน้มลดลงในทิศทางเดียวกับชุด Training แสดงให้เห็นว่าโมเดลสามารถเรียนรู้รูปแบบของข้อมูลได้อย่างเหมาะสม และไม่เกิดปัญหา Overfitting อย่างมีนัยสำคัญ



รูปภาพที่ 56 กราฟค่า Validation Loss ของโมเดล YOLOv8 แสดงการลดลงของค่า loss ของชุดตรวจสอบ


3) กลุ่ม Performance Metrics ประกอบด้วยค่า Precision, Recall, mAP@0.5 และ mAP@0.5-0.95 ซึ่งใช้สำหรับประเมินความแม่นยำของโมเดลในการตรวจจับวัตถุ

ค่า Precision แสดงสัดส่วนของการตรวจจับที่ถูกต้องต่อจำนวนการตรวจจับทั้งหมด ค่า Precision ที่เข้าใกล้ 1 แสดงว่าโมเดลมีอัตราความผิดพลาดจาก False Positive ต่ำ

ค่า Recall แสดงสัดส่วนของวัตถุที่ถูกตรวจพบต่อจำนวนวัตถุทั้งหมดในภาพ ค่า Recall ที่สูงบ่งชี้ว่าโมเดลสามารถตรวจจับวัตถุได้ครบถ้วน

ค่า $mAP@0.5$ เป็นค่าเฉลี่ยของ Average Precision ที่คำนวณภายใต้เงื่อนไข Intersection over Union (IoU) ตั้งแต่ 0.5 ขึ้นไป ซึ่งใช้เป็นตัวชี้วัดหลักของโมเดล Object Detection

ส่วนค่า $mAP@0.5-0.95$ เป็นค่าเฉลี่ยของ mAP ที่คำนวณในหลายระดับของ IoU ตั้งแต่ 0.5 ถึง 0.95 จึงเป็นตัวชี้วัดที่มีความเข้มงวดมากกว่า และสะท้อนความสามารถของโมเดลในการตรวจจับวัตถุได้อย่างละเอียดมากขึ้น




รูปภาพที่ 57 กราฟ Precision, Recall และ mAP แสดงประสิทธิภาพของโมเดลในการตรวจจับวัตถุ

สรุปจากกราฟผลการฝึกพบว่าค่า Loss ของทั้งชุด Train และ Validation ลดลงต่อเนื่องจนเข้าสู่ค่าคงที่หลังประมาณ 150 รอบ ในขณะที่ค่า Precision และ Recall เพิ่มขึ้นเกือบแตะ 1.00 ตั้งแต่รอบที่ 100 เป็นต้นไป ค่า $mAP@0.5$ มีค่าเฉลี่ยประมาณ 0.99 และ $mAP@0.5-0.95$ ประมาณ 0.89 ซึ่งแสดงให้เห็นว่าโมเดลสามารถตรวจจับหน้าปัดเข็มได้อย่างถูกต้องและเสถียรในทุกคลาสโมเดลสามารถตรวจจับหน้าปัดเข็มได้อย่างถูกต้องและเสถียรในทุกคลาส

นอกจากนี้ เพื่อแสดงให้เห็นถึงผลลัพธ์การตรวจจับจริงของโมเดล YOLOv8 แบบหลายคลาส (Multi-Class Detection) ผู้วิจัยได้ทดสอบโมเดลบนภาพมิเตอร์น้ำจริงในสถานะแสงและมุมมองที่แตกต่างกัน ผลลัพธ์ดังรูปที่ 57 และ 58 แสดงให้เห็นว่าโมเดลสามารถตรวจจับได้ครบทั้งบริเวณช่องตัวเลขดิจิทัล (digital_x) และหน้าปัดเข็มในตำแหน่งทศนิยมที่ 2 ถึง 4 (x00001, x0001, x001) ได้อย่างถูกต้องและเสถียรในทุกตัวอย่าง



รูปภาพที่ 58 ตัวอย่างผลการตรวจจับภาพมิเตอร์น้ำจากชุดข้อมูลฝึก (Training Batch) แสดงกรอบ Bounding Box ของคลาส digital_x, x00001, x0001 และ x001 ซึ่งโมเดลสามารถจำแนกและครอบตำแหน่งได้ถูกต้องครบทุกคลาส




รูปภาพที่ 59 ตัวอย่างผลการตรวจจับภาพมิเตอร์น้ำจากชุดข้อมูลตรวจสอบ (Validation Batch) โดยโมเดล สามารถตรวจจับหน้าปัดเข็มและช่องตัวเลขได้ครบถ้วนในสถานะแสงที่หลากหลาย

4.2.2 การตรวจจับช่องตัวเลขดิจิทัล (Digital Detection Model / YOLOv8-single class)

โมเดล YOLOv8 สำหรับการตรวจจับช่องตัวเลขดิจิทัล (คลาสเดียวชื่อ *digital*) ถูกพัฒนาเพื่อแยกบริเวณตัวเลขดิจิทัลออกจากฉากหลังของมิเตอร์น้ำ โดยชุดข้อมูลฝึกถูกแบ่งเป็น Training และ Validation Set อย่างเหมาะสม การฝึกดำเนินทั้งหมด 100 รอบ (Epochs) ผลลัพธ์ที่ได้แสดงว่าค่า Loss ลดลงต่อเนื่อง และโมเดลสามารถตรวจจับช่องตัวเลขได้ถูกต้องเกือบทุกภาพ


4.2.2.1 การวิเคราะห์กราฟผลการฝึกโมเดล

1) **Training Loss** กราฟค่า train/box_loss, train/cls_loss และ train/dfl_loss แสดงพฤติกรรมการเรียนรู้ของโมเดลระหว่างการฝึก โดยค่าความสูญเสียมีแนวโน้มลดลงอย่างต่อเนื่อง แสดงว่าโมเดลสามารถเรียนรู้การระบุตำแหน่ง Bounding Box และการแยกแยะบริเวณช่องตัวเลขจากพื้นหลังได้ดีขึ้นตามจำนวนรอบการฝึก




รูปภาพที่ 60 กราฟ Training Loss ของโมเดล YOLOv8 สำหรับการตรวจจับช่องตัวเลขดิจิทัล

2) **Validation Loss** ค่า val/box_loss, val/cls_loss และ val/dfl_loss ของชุด Validation ลดลงในทิศทางเดียวกับชุด Training แสดงว่าโมเดลสามารถเรียนรู้รูปแบบของข้อมูลได้อย่างเหมาะสมและไม่เกิดปัญหา Overfitting อย่างมีนัยสำคัญ



รูปภาพที่ 61 กราฟ Validation Loss ของโมเดล YOLOv8 สำหรับการตรวจจับช่องตัวเลขดิจิทัล

3) Performance Metrics ค่า Precision และ Recall เพิ่มขึ้นอย่างรวดเร็วในช่วงต้นของการฝึกและเข้าสู่ค่าคงที่ใกล้ 1.00 แสดงว่าโมเดลสามารถตรวจจับช่องตัวเลขได้อย่างถูกต้อง ขณะที่ค่า mAP@0.5 เท่ากับ 1.00 และ mAP@0.5–0.95 ประมาณ 0.87 แสดงถึงประสิทธิภาพการตรวจจับวัตถุในระดับที่ดี




รูปภาพที่ 62 กราฟ Performance Metrics ของโมเดล YOLOv8 สำหรับการตรวจจับช่องตัวเลขดิจิทัล


สรุปจากกราฟผลการฝึก YOLOv8-single class แสดงให้เห็นว่าค่า Box Loss, Cls Loss และ DFL Loss ของชุด Train และ Validation ลดลงต่อเนื่องจนถึงช่วงท้ายของการฝึก ขณะที่ค่า Precision และ Recall เพิ่มขึ้นจนแตะระดับคงที่ที่ใกล้เคียง 1.00 ค่า mAP@0.5 เท่ากับ 1.00 และค่า mAP@0.5–0.95 อยู่ที่ประมาณ 0.87 แสดงว่าโมเดลสามารถตรวจจับกรอบช่องตัวเลขได้อย่างมีประสิทธิภาพสูงและมีความเสถียรในทุกภาพทดสอบ

นอกจากการประเมินเชิงตัวเลขด้วยค่า Precision, Recall, และ mAP แล้ว ผู้วิจัยยังได้แสดงผล ลัทธิเชิงภาพ (Qualitative Results) เพื่อให้เห็นประสิทธิภาพของโมเดล YOLOv8 ในการตรวจจับช่องตัวเลข ดิจิทัลจากภาพมิเตอร์น้ำจริงที่มีลักษณะแสง เงา และมุมมองที่แตกต่างกัน

ผลลัพธ์ในรูปที่ 62 และ 63 แสดงให้เห็นว่าโมเดลสามารถระบุตำแหน่งช่องตัวเลขได้อย่างถูกต้อง ครอบคลุมทุกตัวอย่าง และสามารถทำงานได้อย่างเสถียรทั้งในสภาวะแสงจ้า เงา มีด หรือภาพที่มีพื้นหลัง ซับซ้อน ซึ่งยืนยันถึงความสามารถของโมเดลในการตรวจจับวัตถุได้อย่างแม่นยำในสภาพแวดล้อมจริง



รูปภาพที่ 63 ตัวอย่างผลการตรวจจับช่องตัวเลขดิจิทัลจากชุดข้อมูลฝึก โดยโมเดล YOLOv8 สามารถระบุ ตำแหน่งช่องตัวเลขได้ครบและถูกต้อง



รูปภาพที่ 64 ตัวอย่างผลการตรวจจับช่องตัวเลขดิจิทัลจากชุดข้อมูลตรวจสอบ แสดงให้เห็นว่าโมเดลสามารถ ตรวจจับได้แม่นยำในสภาพแสงและมุมมองที่แตกต่างกัน

4.2.3 โมเดลทำนายมุมเข็ม (Pointer Regression Model / Result of Pointer Regression Model)

โมเดล Pointer Regression ถูกพัฒนาเพื่อใช้ทำนายค่ามุมของเข็มในหน้าปัดมาตรวัดน้ำจากภาพอินพุตจริง โดยเป็นขั้นตอนสำคัญสำหรับการคำนวณค่าปริมาณน้ำจากหน้าปัดอนาล็อก ผลการฝึกโมเดลในส่วนนี้มุ่งเน้นประสิทธิภาพในการเรียนรู้เชิงมุมและความถูกต้องของการทำนาย


โมเดลถูกฝึกด้วยชุดข้อมูลภาพหน้าปัดเข็มจำนวนมากกว่า 1,000 ภาพ โดยแต่ละภาพถูกกำหนดค่า Ground Truth ในรูปของฟังก์ชันตรีโกณมิติ ($\sin\theta$, $\cos\theta$) เพื่อช่วยให้การเรียนรู้ของโมเดลมีความต่อเนื่องของมุมและลดปัญหาความไม่ต่อเนื่องของค่าเชิงมุมบริเวณจุดเปลี่ยนรอบระหว่าง 0° และ 360° การฝึกโมเดลดำเนินการเป็นจำนวน 100 Epochs โดยใช้ฟังก์ชันสูญเสียแบบ Mean Squared Error (MSE) และใช้อัลกอริทึมปรับค่าน้ำหนัก Adam Optimizer

ผลการทดสอบเพิ่มเติมด้วยชุดข้อมูลภาพทดสอบจำนวน 56 ภาพ และประเมินพบว่าโมเดลมีค่า Mean Absolute Error (MAE) เท่ากับ 2.94 องศา และมีความแม่นยำภายในช่วงความคลาดเคลื่อน $\pm 3^\circ$ เท่ากับ 57.14%, ภายในช่วง $\pm 5^\circ$ เท่ากับ 80.36% และภายในช่วง $\pm 10^\circ$ เท่ากับ 98.21% ซึ่งแสดงให้เห็นว่าโมเดลสามารถทำนายตำแหน่งของเข็มได้อย่างแม่นยำในภาพส่วนใหญ่

7.6_zeiger4_2019-06-05T223009.jpg -> Value: 7.60	GT angle: 273.60° Pred: 278.92°	Error: 5.32°
7.7_zeiger3_2019-06-02T200009.jpg -> Value: 7.70	GT angle: 277.20° Pred: 281.82°	Error: 4.62°
7.8_zeiger4_2019-06-04T065009.jpg -> Value: 7.80	GT angle: 280.80° Pred: 281.31°	Error: 0.51°
7.9_zeiger2_2019-06-02T090009.jpg -> Value: 7.90	GT angle: 284.40° Pred: 284.07°	Error: 0.33°
8.0_zeiger3_2019-06-04T160009.jpg -> Value: 8.00	GT angle: 288.00° Pred: 284.25°	Error: 3.75°
8.1_zeiger3_2019-06-04T192009.jpg -> Value: 8.10	GT angle: 291.60° Pred: 291.55°	Error: 0.05°
8.2_zeiger4_2019-06-05T045009.jpg -> Value: 8.20	GT angle: 295.20° Pred: 295.88°	Error: 0.68°
8.3_zeiger3_2019-11-19_07-02-03.jpg -> Value: 8.30	GT angle: 298.80° Pred: 284.74°	Error: 14.06°
8.4_zeiger3_2019-06-03T225009.jpg -> Value: 8.40	GT angle: 302.40° Pred: 302.88°	Error: 0.48°
8.6_zeiger2_2019-06-01T202014.jpg -> Value: 8.60	GT angle: 309.60° Pred: 301.79°	Error: 7.81°
8.7_zeiger2_2019-06-06T050009.jpg -> Value: 8.70	GT angle: 313.20° Pred: 307.19°	Error: 6.01°
8.8_zeiger3_2019-11-19_07-37-03.jpg -> Value: 8.80	GT angle: 316.80° Pred: 315.25°	Error: 1.55°
8.9_zeiger1_2019-06-02T235009.jpg -> Value: 8.90	GT angle: 320.40° Pred: 317.93°	Error: 2.47°
9.0_zeiger2_2019-06-04T235009.jpg -> Value: 9.00	GT angle: 324.00° Pred: 327.39°	Error: 3.39°
9.1_zeiger2_2019-11-19_09-17-03.jpg -> Value: 9.10	GT angle: 327.60° Pred: 334.48°	Error: 6.88°
9.2_zeiger4_2019-09-15_05-30-13.jpg -> Value: 9.20	GT angle: 331.20° Pred: 332.28°	Error: 1.08°
9.3_zeiger1_2019-06-03T143009.jpg -> Value: 9.30	GT angle: 334.80° Pred: 335.65°	Error: 0.85°
9.4_zeiger3_2019-11-19_01-42-03.jpg -> Value: 9.40	GT angle: 338.40° Pred: 336.80°	Error: 1.60°
9.5_zeiger4_2019-06-02T080009.jpg -> Value: 9.50	GT angle: 342.00° Pred: 347.44°	Error: 5.44°
9.7_zeiger2_2019-11-19_10-47-03.jpg -> Value: 9.70	GT angle: 349.20° Pred: 349.10°	Error: 0.10°
9.8_zeiger2_2019-11-19_00-47-03.jpg -> Value: 9.80	GT angle: 352.80° Pred: 357.42°	Error: 4.62°
9.9_zeiger4_2019-06-04T231009.jpg -> Value: 9.90	GT angle: 356.40° Pred: 358.16°	Error: 1.76°

```
===== SUMMARY =====
จำนวนภาพประเมินได้: 56
MAE: 2.94°
Accuracy within ±3° : 57.14%
Accuracy within ±5° : 80.36%
Accuracy within ±10° : 98.21%
```


รูปภาพที่ 65 ผลลัพธ์การประเมินโมเดล Pointer Regression จากชุดข้อมูลทดสอบจำนวน 56 ภาพ โดยแสดงค่ามุมจริง ค่ามุมที่โมเดลทำนาย และค่าความคลาดเคลื่อน พร้อมสรุปค่า Mean Absolute Error และ Accuracy ของโมเดล



รูปภาพที่ 66 กราฟเปรียบเทียบค่ามุมจริงของเข็ม (Ground Truth Angle) และค่ามุมที่โมเดลทำนายได้ (Predicted Angle) จากชุดข้อมูลทดสอบ

จากกราฟใน **รูปที่ 65** ซึ่งแสดงการเปรียบเทียบระหว่างค่ามุมจริงของเข็ม (Ground Truth Angle) และค่ามุมที่โมเดลทำนายได้ (Predicted Angle) พบว่าแนวโน้มของค่าทั้งสองมีความสอดคล้องกันเกือบตลอดช่วงข้อมูล โดยเส้นกราฟทั้งสองมีลักษณะใกล้เคียงกัน แสดงให้เห็นว่าโมเดลสามารถเรียนรู้ความสัมพันธ์ระหว่างภาพอินพุตและตำแหน่งเชิงมุมของเข็มได้อย่างมีประสิทธิภาพ

นอกจากนี้ จากการวิเคราะห์การกระจายตัวของค่าความคลาดเคลื่อนเชิงมุม พบว่าค่าความคลาดเคลื่อนส่วนใหญ่กระจุกตัวอยู่ในช่วง 0–5 องศา และมีเพียงส่วนน้อยที่มีค่าความคลาดเคลื่อนสูงกว่า 8 องศา ซึ่งสะท้อนว่าโมเดลมีความเสถียรและสามารถนำไปประยุกต์ใช้ในระบบอ่านค่ามาตรวัดน้ำอัตโนมัติได้อย่างเหมาะสม **รูปภาพที่ 66** การกระจายตัวของค่าความคลาดเคลื่อนเชิงมุม (Angular Error) ของโมเดล Pointer Regression จากชุดข้อมูลทดสอบ




รูปภาพที่ 67 การกระจายตัวของค่าความคลาดเคลื่อนเชิงมุม (Angular Error) ของโมเดล Pointer Regression

4.2.4 ผลการฝึกโมเดล CNN จำแนกตัวเลข (Digit Model / Result of Digit CNN Model)

โมเดล Convolutional Neural Network (CNN) สำหรับจำแนกตัวเลข 0–9 และคลาส NaN ได้รับการฝึกด้วยชุดข้อมูลภาพตัวเลขที่ผ่านกระบวนการเตรียมข้อมูลแล้ว โดยใช้ภาพขนาด 32×20 พิกเซล และใช้ชุดข้อมูลฝึกจำนวนมากว่า 1,110 ภาพ ในการฝึกโมเดลได้ใช้ฟังก์ชันสูญเสียแบบ Categorical Cross-Entropy และตัวปรับค่าน้ำหนักแบบ Adadelta โดยกำหนดค่า Batch size = 4 และ Epochs = 80 เพื่อให้โมเดลสามารถเรียนรู้ลักษณะของตัวเลขแต่ละประเภทได้อย่างเหมาะสม

จากผลการฝึกโมเดลพบว่า ค่า Accuracy ของชุดข้อมูลฝึก (Training Accuracy) และ ชุดข้อมูลตรวจสอบ (Validation Accuracy) เพิ่มขึ้นอย่างรวดเร็วในช่วงต้นของการฝึก และมีแนวโน้มคงที่ในช่วงท้ายของการฝึก โดยค่าความแม่นยำของโมเดลอยู่ที่ประมาณ **94.7%** ซึ่งแสดงให้เห็นว่าโมเดลสามารถเรียนรู้รูปแบบของตัวเลขจากภาพได้อย่างมีประสิทธิภาพ

ในส่วนของค่า Loss พบว่าค่า Loss ของชุดข้อมูลฝึกมีแนวโน้มลดลงอย่างต่อเนื่องตลอดกระบวนการฝึก ขณะที่ค่า Loss ของชุดข้อมูลตรวจสอบมีลักษณะการแกว่งตัวเล็กน้อยในช่วงของการฝึก ซึ่งเป็นลักษณะที่พบได้ทั่วไปในกระบวนการเรียนรู้ของโมเดลเชิงลึก แต่โดยรวมยังคงมีแนวโน้มลดลงและอยู่ในระดับที่ต่ำ แสดงให้เห็นว่าโมเดลสามารถปรับค่าพารามิเตอร์เพื่อเพิ่มประสิทธิภาพในการจำแนกตัวเลขได้อย่างเหมาะสม



(ก)



(ข)


รูปภาพที่ 68

(ก) กราฟแสดงค่าความแม่นยำ (Accuracy) ของชุดข้อมูลฝึกและชุดข้อมูลตรวจสอบระหว่างการฝึกโมเดล CNN

(ข) กราฟแสดงค่าความสูญเสีย (Loss) ของชุดข้อมูลฝึกและชุดข้อมูลตรวจสอบระหว่างการฝึกโมเดล CNN

เมื่อพิจารณาผลการประเมินโมเดลด้วย Confusion Matrix พบว่าโมเดลสามารถจำแนกตัวเลขในแต่ละคลาสได้อย่างถูกต้องในเกือบทุกกรณี โดยค่าที่ปรากฏในเมทริกซ์ส่วนใหญ่อยู่บนเส้นทแยงมุมของตาราง ซึ่งหมายความว่าค่าที่โมเดลทำนายตรงกับค่าจริงของข้อมูลในแต่ละคลาส ทั้งตัวเลข 0-9 และคลาส NaN แสดงให้เห็นว่าโมเดลมีความสามารถในการจำแนกตัวเลขได้อย่างมีประสิทธิภาพ

อย่างไรก็ตาม ยังพบความคลาดเคลื่อนเล็กน้อยในบางคลาส ซึ่งอาจเกิดจากลักษณะของตัวเลขที่มีรูปทรงคล้ายกัน หรือคุณภาพของภาพที่ทำให้รายละเอียดของตัวเลขไม่ชัดเจน ส่งผลให้โมเดลทำนายผิดพลาดในบางกรณี



รูปภาพที่ 69 ตาราง Confusion Matrix แสดงผลการจำแนกตัวเลขของโมเดล CNN ในชุดข้อมูลทดสอบ

จากการทดสอบเพิ่มเติมด้วยชุดข้อมูลภาพทดสอบจำนวน 82 ภาพ พบว่าโมเดลสามารถทำนายได้ถูกต้อง 81 ภาพ และเกิดความผิดพลาดเพียง 1 ภาพ คิดเป็นความแม่นยำประมาณ 98.78% โดยกรณีที่เกิดความผิดพลาดเกิดจากภาพตัวเลข 8 ที่ถูกทำนายเป็นตัวเลข 3 ซึ่งอาจเกิดจากลักษณะรูปทรงของตัวเลขที่มีความคล้ายคลึงกัน หรือคุณภาพของภาพที่ทำให้รายละเอียดของเส้นโค้งไม่ชัดเจน

พบรูปทดสอบ 82 ภาพ

```
0_10.jpg -> GT:0 | Predict:0 | ✓
0_11.jpg -> GT:0 | Predict:0 | ✓
0_7.jpg -> GT:0 | Predict:0 | ✓
0_8.jpg -> GT:0 | Predict:0 | ✓
0_9.jpg -> GT:0 | Predict:0 | ✓
4_4.jpg -> GT:4 | Predict:4 | ✓
4_5.jpg -> GT:4 | Predict:4 | ✓
4_6.jpg -> GT:4 | Predict:4 | ✓
5_2.jpg -> GT:5 | Predict:5 | ✓
5_3.jpg -> GT:5 | Predict:5 | ✓
5_4.jpg -> GT:5 | Predict:5 | ✓
5_5.jpg -> GT:5 | Predict:5 | ✓
8_1.jpg -> GT:8 | Predict:8 | ✓
8_2.jpg -> GT:8 | Predict:8 | ✓
8_3.jpg -> GT:8 | Predict:8 | ✓
8_4.jpg -> GT:8 | Predict:8 | ✓
8_5.jpg -> GT:8 | Predict:8 | ✓
8_6.jpg -> GT:8 | Predict:8 | ✓
8_7.jpg -> GT:8 | Predict:3 | ✗
0_1.png -> GT:0 | Predict:0 | ✓
0_2.png -> GT:0 | Predict:0 | ✓
0_3.png -> GT:0 | Predict:0 | ✓
0_4.png -> GT:0 | Predict:0 | ✓
```

```
7_2.png -> GT:7 | Predict:7 | ✓
7_3.png -> GT:7 | Predict:7 | ✓
8_1.png -> GT:8 | Predict:8 | ✓
8_2.png -> GT:8 | Predict:8 | ✓
8__1.png -> GT:8 | Predict:8 | ✓
9_1.png -> GT:9 | Predict:9 | ✓
9_2.png -> GT:9 | Predict:9 | ✓
NaN1.png -> GT:NaN | Predict:NaN | ✓
NaN10.png -> GT:NaN | Predict:NaN | ✓
NaN1_2.png -> GT:NaN | Predict:NaN | ✓
NaN2.png -> GT:NaN | Predict:NaN | ✓
NaN3.png -> GT:NaN | Predict:NaN | ✓
NaN4.png -> GT:NaN | Predict:NaN | ✓
NaN5.png -> GT:NaN | Predict:NaN | ✓
NaN6.png -> GT:NaN | Predict:NaN | ✓
NaN6_7.png -> GT:NaN | Predict:NaN | ✓
NaN7.png -> GT:NaN | Predict:NaN | ✓
NaN8.png -> GT:NaN | Predict:NaN | ✓
NaN9.png -> GT:NaN | Predict:NaN | ✓
```

```
===== SUMMARY =====
จำนวนภาพที่ประเมินได้: 82
ทำนายถูก: 81
ทำนายผิด: 1
Accuracy: 98.78%

ตัวอย่างภาพที่ทำนายผิด:
8_7.jpg -> GT:8 Predict:3
```


รูปภาพที่ 70 ผลการทดสอบโมเดลอ่านค่าตัวเลขดิจิทัล โดยแสดงค่าจริงของตัวเลข ค่าที่โมเดลทำนาย และสรุปผลความแม่นยำของโมเดลจากชุดข้อมูลทดสอบ

โดยสรุป โมเดล CNN ที่พัฒนาขึ้นสามารถเรียนรู้รูปแบบของตัวเลขจากภาพได้อย่างมีประสิทธิภาพ และมีศักยภาพในการนำไปประยุกต์ใช้ในระบบอ่านค่ามิเตอร์อัตโนมัติ อย่างไรก็ตาม เพื่อเพิ่มความสามารถในการใช้งานจริง จำเป็นจะต้องเพิ่มจำนวนและความหลากหลายของข้อมูลฝึก เช่น ความแตกต่างของสภาพแสง มุมกล้อง และคุณภาพของภาพ เพื่อช่วยให้โมเดลสามารถจำแนกตัวเลขได้แม่นยำยิ่งขึ้นในสถานการณ์จริง

4.2.5 ผลการฝึกโมเดล Transition (Pair Model / Result of Transition CNN Model)

โมเดล Transition CNN Model หรือ Pair Model ถูกพัฒนาขึ้นเพื่อใช้ตรวจสอบความต่อเนื่องของค่าตัวเลขที่ได้จากโมเดลจำแนกตัวเลข (Digit CNN Model) โดยมีวัตถุประสงค์เพื่อจัดการกับสถานการณ์ที่ตัวเลขของมิเตอร์เกิดการเปลี่ยนผ่าน (Transition) เช่น $0 \rightarrow 1$, $1 \rightarrow 2$, ..., $8 \rightarrow 9$ และ $9 \rightarrow 0$ ซึ่งเป็นลักษณะการทำงานปกติของมิเตอร์น้ำในระบบจริง

ในการฝึกโมเดล Transition CNN ใช้ชุดข้อมูลภาพที่สร้างจากคู่ตัวเลขที่มีการเปลี่ยนผ่านประมาณ 3000 ภาพ ครอบคลุมการเปลี่ยนแปลงของตัวเลขทั้ง 10 คลาส ($0 \rightarrow 1$ ถึง $9 \rightarrow 0$) โดยใช้สถาปัตยกรรม Convolutional Neural Network (CNN) สำหรับการจำแนกการเปลี่ยนผ่านของตัวเลข เพื่อให้โมเดลสามารถเรียนรู้รูปแบบของการเปลี่ยนผ่านของตัวเลขได้อย่างมีประสิทธิภาพ



รูปภาพที่ 71


- (ก) กราฟแสดงค่าความแม่นยำ (Accuracy) ของโมเดล Transition CNN ระหว่างการฝึกและการตรวจสอบ
- (ข) กราฟแสดงค่าความสูญเสีย (Loss) ของโมเดล Transition CNN ระหว่างการฝึกและการตรวจสอบ

จากผลการฝึกโมเดลพบว่า โมเดลมีค่า Training Accuracy เท่ากับประมาณ 100% ขณะที่ Validation Accuracy มีค่าอยู่ที่ประมาณ 94.65% โดยโมเดลมีค่า Validation Loss ต่ำที่สุดประมาณ 0.423 ซึ่งเกิดขึ้นในช่วง epoch ที่ 25 ของการฝึก นอกจากนี้จากผลการประเมินยังพบว่าโมเดลมีความสามารถในการจำแนกการเปลี่ยนผ่านของตัวเลขได้อย่างถูกต้องในระดับสูง โดยสามารถเรียนรู้ลักษณะของข้อมูลภาพได้อย่างมีประสิทธิภาพ

จากกราฟผลการฝึกใน **รูปภาพที่ 70 (ก)** พบว่าค่าความแม่นยำของโมเดลเพิ่มขึ้นอย่างรวดเร็วในช่วงต้นของการฝึก และมีแนวโน้มคงที่ในช่วงท้ายของการฝึก โดยค่า Training Accuracy มีค่าใกล้เคียง 100% ในขณะที่ Validation Accuracy มีค่าอยู่ในช่วงประมาณ 93–95% ซึ่งแสดงให้เห็นว่าโมเดลสามารถเรียนรู้รูปแบบของข้อมูลได้อย่างมีประสิทธิภาพ

ในส่วนของกราฟ Loss **รูปภาพที่ 70** (ข) พบว่าค่า Training Loss มีแนวโน้มลดลงอย่างต่อเนื่องตลอดกระบวนการฝึกโมเดล ขณะที่ Validation Loss ลดลงอย่างรวดเร็วในช่วงต้นของการฝึก และมีค่าต่ำสุดที่ประมาณ 0.423 ก่อนที่จะมีการแกว่งตัวเล็กน้อยในช่วงท้ายของการฝึก ทั้งนี้ระบบได้ใช้กลไก Early Stopping เพื่อหยุดการฝึกเมื่อประสิทธิภาพของโมเดลไม่ดีขึ้นเพิ่มเติม และเลือกใช้โมเดลจาก epoch ที่ให้ค่า Validation Loss ต่ำที่สุด

ผลการทดลองดังกล่าวแสดงให้เห็นว่าโมเดล CNN ที่พัฒนาขึ้นสามารถเรียนรู้รูปแบบของการเปลี่ยนผ่านของตัวเลขได้อย่างมีประสิทธิภาพ และสามารถนำไปใช้ในการจำแนกการเปลี่ยนผ่านของตัวเลขในระบบอ่านค่ามิเตอร์อัตโนมัติได้อย่างเหมาะสม แม้ว่าจะยังพบความคลาดเคลื่อนเล็กน้อยในบางคลาส แต่โดยรวมแล้วโมเดลมีประสิทธิภาพอยู่ในระดับที่น่าพอใจ



รูปภาพที่ 72 Confusion Matrix ของโมเดล Transition CNN ในชุดข้อมูลตรวจสอบ แสดงผลการจำแนกการเปลี่ยนผ่านของตัวเลขตั้งแต่ 0→1 ถึง 9→0

ผลการประเมินโมเดลด้วย Confusion Matrix ในชุดข้อมูลตรวจสอบดังแสดงใน **รูปภาพที่ 71** พบว่าค่าการทำนายส่วนใหญ่อยู่บนเส้นทแยงมุมของเมทริกซ์ แสดงว่าโมเดลสามารถจำแนกการเปลี่ยนผ่านของตัวเลขในแต่ละคลาสได้อย่างถูกต้องในเกือบทุกกรณี โดยมีการสับสนระหว่างคลาสเพียงเล็กน้อย ซึ่งสะท้อนถึงประสิทธิภาพของโมเดลในการเรียนรู้รูปแบบของการเปลี่ยนผ่านของตัวเลข

จากการทดสอบเพิ่มเติมด้วยชุดข้อมูลภาพทดสอบจำนวน 28 ภาพ ซึ่งเป็นภาพตัวเลขในช่วงการเปลี่ยนผ่านของมิเตอร์น้ำ โมเดล Transition CNN สามารถจำแนกตัวเลขได้อย่างถูกต้องในทุกภาพทดสอบ ผลการทดสอบแสดงค่าจริงของตัวเลข (Ground Truth) ค่าที่โมเดลทำนายได้ (Prediction) และค่าความมั่นใจของโมเดล (Confidence) สำหรับแต่ละภาพ

พบภาพทั้งหมด 28 ภาพ

0_1_1.png -> GT:0 Pred:0 conf:1.000 ✓	5_6_1.png -> GT:5 Pred:5 conf:1.000 ✓
0_1_2.png -> GT:0 Pred:0 conf:1.000 ✓	5_6_1.png -> GT:5 Pred:5 conf:1.000 ✓
0_1_3.png -> GT:0 Pred:0 conf:1.000 ✓	5_6_2.png -> GT:5 Pred:5 conf:1.000 ✓
0_1_4.png -> GT:0 Pred:0 conf:1.000 ✓	5_6_2.png -> GT:5 Pred:5 conf:1.000 ✓
1_2_0.png -> GT:1 Pred:1 conf:1.000 ✓	5_6_3.png -> GT:5 Pred:5 conf:1.000 ✓
2_3_1.png -> GT:2 Pred:2 conf:1.000 ✓	5_6_4.png -> GT:5 Pred:5 conf:1.000 ✓
2_3_2.png -> GT:2 Pred:2 conf:1.000 ✓	6_7_1.png -> GT:6 Pred:6 conf:1.000 ✓
2_3_3.png -> GT:2 Pred:2 conf:1.000 ✓	6_7_1.png -> GT:6 Pred:6 conf:1.000 ✓
3_4_1.png -> GT:3 Pred:3 conf:1.000 ✓	6_7_2.png -> GT:6 Pred:6 conf:0.886 ✓
3_4_2.png -> GT:3 Pred:3 conf:1.000 ✓	6_7_2.png -> GT:6 Pred:6 conf:0.886 ✓
3_4_3.png -> GT:3 Pred:3 conf:1.000 ✓	7_8_1.png -> GT:7 Pred:7 conf:1.000 ✓
4_5_1.png -> GT:4 Pred:4 conf:1.000 ✓	7_8_2.png -> GT:7 Pred:7 conf:1.000 ✓
4_5_2.png -> GT:4 Pred:4 conf:1.000 ✓	7_8_1.png -> GT:7 Pred:7 conf:1.000 ✓
4_5_3.png -> GT:4 Pred:4 conf:1.000 ✓	7_8_2.png -> GT:7 Pred:7 conf:1.000 ✓
5_6_1.png -> GT:5 Pred:5 conf:1.000 ✓	7_8_3.png -> GT:7 Pred:7 conf:1.000 ✓
5_6_2.png -> GT:5 Pred:5 conf:1.000 ✓	7_8_3.png -> GT:7 Pred:7 conf:1.000 ✓
5_6_3.png -> GT:5 Pred:5 conf:1.000 ✓	7_8_4.png -> GT:7 Pred:7 conf:1.000 ✓
5_6_4.png -> GT:5 Pred:5 conf:1.000 ✓	7_8_4.png -> GT:7 Pred:7 conf:1.000 ✓
6_7_1.png -> GT:6 Pred:6 conf:1.000 ✓	9_0_1.png -> GT:9 Pred:9 conf:1.000 ✓
6_7_2.png -> GT:6 Pred:6 conf:0.886 ✓	9_0_2.png -> GT:9 Pred:9 conf:1.000 ✓
7_8_1.png -> GT:7 Pred:7 conf:1.000 ✓	9_0_4.png -> GT:9 Pred:9 conf:1.000 ✓
7_8_2.png -> GT:7 Pred:7 conf:1.000 ✓	9_0_5.png -> GT:9 Pred:9 conf:1.000 ✓
4_5_1.png -> GT:4 Pred:4 conf:1.000 ✓	
4_5_2.png -> GT:4 Pred:4 conf:1.000 ✓	
4_5_3.png -> GT:4 Pred:4 conf:1.000 ✓	

```
===== SUMMARY =====
จำนวนภาพที่ประเมินได้: 28
ทำนายถูก: 28
ทำนายผิด: 0
Accuracy: 100.00%
```


รูปภาพที่ 73 ผลการทดสอบโมเดล Transition CNN (Pair Model) กับชุดข้อมูลภาพทดสอบ

นอกจากการประเมินประสิทธิภาพของโมเดลแล้ว งานวิจัยนี้ยังนำโมเดล Transition CNN มาใช้ร่วมกับกระบวนการ Transition-State Handling เพื่อแก้ไขปัญหาความไม่ต่อเนื่องของค่าตัวเลขที่ได้จากโมเดลจำแนกตัวเลข โดยเฉพาะในกรณีที่ตัวเลขของมิเตอร์อยู่ในช่วงการเปลี่ยนผ่าน (digit transition) เช่น $0 \rightarrow 1$, $1 \rightarrow 2$ หรือในกรณีที่เกิดการ rollover ของตัวเลข เช่น $9 \rightarrow 0$ ซึ่งเป็นลักษณะการทำงานปกติของมิเตอร์น้ำแบบเชิงกล

ในการอ่านค่ามิเตอร์เชิงกล เมื่อภาพตัวเลขอยู่ในช่วงการเปลี่ยนผ่าน ตัวเลขที่ปรากฏในช่องหน้าต่างของมิเตอร์จะมีลักษณะก้ำกึ่งระหว่างตัวเลขสองค่า เช่น ในช่วงที่ตัวเลขกำลังเปลี่ยนจาก 5 ไปเป็น 6 ภาพที่ปรากฏอาจแสดงทั้งส่วนของตัวเลข 5 และ 6 พร้อมกัน ในกรณีดังกล่าว ระบบอ่านมิเตอร์โดยทั่วไปจะใช้หลักการ เลือกค่าตัวเลขที่น้อยกว่าเป็นค่าที่ถูกต้อง (Lower Digit Rule) เนื่องจากค่าที่ปรากฏในช่วงการเปลี่ยนผ่านยังถือเป็นค่าของตัวเลขก่อนหน้า ดังนั้นหากตรวจพบภาพ transition เช่น $5 \rightarrow 6$ ระบบจะเลือกค่าตัวเลข 5 เป็นผลลัพธ์ของการอ่านค่า เพื่อให้ค่าที่ได้สอดคล้องกับพฤติกรรมการทำงานจริงของมิเตอร์น้ำ

อย่างไรก็ตาม เมื่อใช้โมเดล CNN ในการจำแนกตัวเลขจากภาพแต่ละเฟรม โมเดลอาจเกิดความคลาดเคลื่อนในการทำนายค่าตัวเลขในบางช่วง โดยเฉพาะในช่วงที่ตัวเลขกำลังเปลี่ยนผ่าน ทำให้เกิดปรากฏการณ์ที่เรียกว่า value jump ซึ่งหมายถึงการที่ค่าที่โมเดลทำนายมีการกระโดดของค่าอย่างไม่ต่อเนื่อง ตัวอย่างเช่น ค่าที่ได้จากโมเดลอาจเป็น $4 \rightarrow 4 \rightarrow 5 \rightarrow 5 \rightarrow 7$ ซึ่งไม่สอดคล้องกับลำดับการเปลี่ยนแปลงของตัวเลขจริงของมิเตอร์


ผลการทดลองก่อนการใช้กระบวนการ Transition-State Handling แสดงใน **รูปภาพที่ 73** ซึ่งเปรียบเทียบค่าจริงของตัวเลข (Ground Truth) กับค่าที่ได้จากโมเดล CNN ก่อนการปรับแก้ จะเห็นได้ว่าค่าที่โมเดลทำนายอาจเกิดการกระโดดของค่าในบางช่วง ส่งผลให้ลำดับของค่าที่ได้ไม่สอดคล้องกับพฤติกรรมการเปลี่ยนแปลงของตัวเลขจริงของมิเตอร์



รูปภาพที่ 74 การทำนายค่าตัวเลขก่อนการใช้ Transition-State Handling (Digit Prediction Before Transition Handling)

เพื่อแก้ไขปัญหาดังกล่าว งานวิจัยนี้ได้ใช้กระบวนการ Transition-State Handling ในการตรวจสอบความต่อเนื่องของค่าตัวเลขที่ได้จากโมเดล โดยอาศัยหลักการเปลี่ยนผ่านของตัวเลขในมิเตอร์ร่วมกับผลการจำแนกจากโมเดล Transition CNN (Pair Model) ในการปรับค่าที่เกิดความคลาดเคลื่อนให้กลับมาอยู่ในลำดับที่ถูกต้อง

ผลลัพธ์หลังจากนำกระบวนการ Transition-State Handling มาใช้แสดงใน **รูปภาพที่ 74** โดยพบว่าค่าตัวเลขที่ได้มีความต่อเนื่องมากขึ้นและสอดคล้องกับลำดับการเปลี่ยนแปลงของตัวเลขจริงของมิเตอร์ เช่น จากเดิมที่ค่าที่โมเดลทำนายอาจเกิดการกระโดดของค่า ระบบสามารถปรับค่าดังกล่าวให้เป็นลำดับที่ถูกต้อง เช่น $4 \rightarrow 4 \rightarrow 5 \rightarrow 6 \rightarrow 7$ ซึ่งสอดคล้องกับพฤติกรรมการทำงานของมิเตอร์น้ำจริง




รูปภาพที่ 75 ความต่อเนื่องของค่าตัวเลขก่อนและหลังการใช้ Transition-State Handling (Digit Value Continuity Before and After Transition Handling)

จากผลการทดลองดังกล่าวสามารถสรุปได้ว่า การใช้โมเดล Transition CNN Model ร่วมกับกระบวนการ Transition-State Handling สามารถช่วยเพิ่มความเสถียรของค่าตัวเลขที่อ่านได้จากระบบอ่านมิเตอร์อัตโนมัติ และช่วยลดความผิดพลาดที่เกิดขึ้นในช่วงการเปลี่ยนผ่านของตัวเลขได้อย่างมีประสิทธิภาพ ส่งผลให้ค่าที่อ่านได้มีความต่อเนื่องและสอดคล้องกับพฤติกรรมการทำงานจริงของมิเตอร์น้ำ ซึ่งช่วยเพิ่มความน่าเชื่อถือของระบบสำหรับการนำไปใช้งานจริง

4.3 ผลการดำเนินงานของ Web Application และ Mobile WebView

ระบบ AquaRead ได้รับการพัฒนาเป็น Web Application ที่สามารถใช้งานผ่าน Mobile WebView บนอุปกรณ์พกพา เพื่อรองรับการใช้งานจริงในภาคสนามของเจ้าหน้าที่ โดยในส่วนนี้นำเสนอผลการแสดงผลของระบบในหน้าจอหลักที่เกี่ยวข้องกับกระบวนการใช้งาน ตั้งแต่การเข้าสู่ระบบ การจัดการงานอ่านคำมิตเตอร์ การแสดงผลการตรวจจับ ไปจนถึงการแจ้งเตือนและการตั้งค่าผู้ใช้งาน

4.3.1 หน้าจอเริ่มต้นและการเข้าสู่ระบบ



รูปภาพที่ 76 หน้าจอเริ่มต้น (Splash Screen) และหน้าจอเข้าสู่ระบบของแอป AquaRead แสดงโลโก้ระบบและแบบฟอร์มสำหรับยืนยันตัวตนผู้ใช้งานก่อนเข้าสู่การใช้งานระบบ

4.3.2 หน้าหลักและแดชบอร์ดสรุปสถานะ



รูปภาพที่ 77 หน้าหลักของระบบ AquaRead แสดงสรุปสถานะรอบบิลปกติ ห้องที่อ่านแล้ว และรายการที่มีความผิดปกติ ช่วยให้ผู้ใช้งานสามารถติดตามภาพรวมของการใช้น้ำได้อย่างรวดเร็ว

4.3.3 เมนูบริการและการเลือกงานอ่านค่า




รูปภาพที่ 78 หน้าจอเมนูบริการของระบบ AquaRead แสดงทางเลือกสำหรับการบันทึกค่าน้ำ ห้องที่ยังไม่ได้อ่าน และรายการค่าผิดปกติ เพื่อรองรับการทำงานภาคสนาม

4.3.4 การอัปโหลดภาพและประมวลผลมิเตอร์



รูปภาพที่ 79 หน้าจอการอัปโหลดหรือถ่ายภาพมิเตอร์น้ำเพื่อเข้าสู่กระบวนการตรวจนับและประมวลผล ผู้ใช้งานสามารถเลือกภาพถ่ายเดี่ยว ไฟล์จากไฟล์เตอร์ หรือกล้อง (Webcam) เพื่อส่งข้อมูลเข้าสู่ระบบ

4.3.5 การแสดงผลการอ่านค่าและรายละเอียด



รูปภาพที่ 80 หน้าจอแสดงผลการตรวจนับมิเตอร์น้ำและผลการคำนวณปริมาณการใช้น้ำ แสดงค่าที่อ่านได้จากตัวเลขดิจิทัลและหน้าปัดเข็ม พร้อมสรุปปริมาณการใช้น้ำรวม (m³)

เมื่อผู้ใช้งานกดปุ่ม “แสดงรายละเอียด” ระบบจะแสดงข้อมูลเชิงลึกของกระบวนการอ่านค่า ซึ่งประกอบด้วยภาพต้นฉบับที่ผ่านการตรวจจับ กรอบการตรวจจับของตัวเลขดิจิทัลและหน้าปัดเข็ม ค่าที่ได้จากการจำแนกในแต่ละหลัก รวมถึงผลลัพธ์ก่อนและหลังการปรับแก้ด้วยกลไก Transition-State Handling ดังแสดงในรูปที่ 62

หน้าจอดังกล่าวช่วยให้ผู้ใช้งานสามารถตรวจสอบความถูกต้องของผลลัพธ์ในแต่ละขั้นตอน ตั้งแต่ระดับภาพ (Image Crop) ไปจนถึงระดับการตัดสินใจสุดท้าย (Final Decision) ซึ่งเพิ่มความโปร่งใสและความน่าเชื่อถือของระบบ AquaRead ในการใช้งานจริง

รายงานผลการตรวจจับ

1000011592



สรุปค่าที่อ่านได้

ตำแหน่ง	ค่า
Digital	0003
x01	1
x001	5
x0001	4
x00001	8
รวม	0003.1548 m³



การตัดสินใจแต่ละหลัก

ตำแหน่ง	Prev	Raw	Final
Digital	-	0003	0003
x01	1	1	1
x001	5	5	5
x0001	4	4	4
x00001	8	8	8

Image Digital Crop

Img	Val.	Img	Val.	Img	Val.	Img	Val.	Img	Val.
	0		0		0		3		1

Image Analog Crop

Img	Val.	Img	Val.	Img	Val.
	5		4		8




รูปภาพที่ 81 หน้าจอแสดงผลรายละเอียดการอ่านค่ามิเตอร์น้ำ ระบบจะแสดงภาพต้นฉบับของมิเตอร์น้ำ ควบคู่กับผลการคำนวณค่าใช้น้ำ โดยแสดงค่าที่อ่านได้จากตัวเลขดิจิทัล ค่าทศนิยมจากหน้าปัดเข็ม และ ปริมาณการใช้น้ำรวม (m³) พร้อมข้อมูลเวลาและไฟล์ที่ใช้ในการประมวลผล

4.3.6 การแจ้งเตือน



รูปภาพที่ 82 หน้าจอประวัติการอ่านค่าและการแจ้งเตือนล่าสุด แสดงรายการห้องที่มีการใช้น้ำผิดปกติ ห้องที่ยังไม่ได้อ่านค่า และเหตุการณ์ที่ต้องตรวจสอบเพิ่มเติม

4.3.7 โปรไฟล์ผู้ใช้งานและการตั้งค่า



รูปภาพที่ 83 หน้าจอโปรไฟล์และการตั้งค่าของผู้ใช้งาน รองรับการแสดงข้อมูลบัญชีผู้ใช้ การตั้งค่าการแจ้งเตือน และโหมดการแสดงผลแบบกลางคืน (Dark Mode)

4.4 สรุปผลการดำเนินงานและข้อสังเกตจากการทดสอบ

โดยสรุป การดำเนินงานพัฒนาระบบ AquaRead ในระยะนี้ประสบความสำเร็จในการพัฒนาโมดูลหลักของระบบครบถ้วน ทั้งในด้านการตรวจจับตำแหน่ง (Detection) และการจำแนกค่า (Recognition) โดยระบบสามารถประมวลผลภาพมิเตอร์น้ำแบบอนาล็อกเพื่อแปลงเป็นข้อมูลดิจิทัลได้โดยอัตโนมัติผ่านการประยุกต์ใช้เทคนิค Image Processing และ Artificial Intelligence (AI)

จากผลการทดลองในหัวข้อ 4.3 พบว่าโมดูลตรวจจับตำแหน่งที่พัฒนาด้วย YOLOv8 สามารถทำงานได้อย่างมีประสิทธิภาพ โดยให้ค่า mAP@0.5 เท่ากับ 1.00 สำหรับการตรวจจับแถบตัวเลขดิจิทัล และ 0.99 สำหรับการตรวจจับตำแหน่งเข็มมิเตอร์ แสดงให้เห็นถึงความสามารถในการตรวจจับวัตถุที่มีความแม่นยำสูง

ในส่วนของการจำแนกค่าตัวเลข โมเดล Digit CNN สามารถจำแนกตัวเลข 0–9 และคลาส NaN ได้ด้วยค่า Validation Accuracy ประมาณ 94.7% และมีค่า F1-score มากกว่า 0.90 นอกจากนี้เมื่อทดสอบกับชุดข้อมูลภาพทดสอบจำนวน 82 ภาพ พบว่าโมเดลสามารถทำนายได้ถูกต้อง 81 ภาพ คิดเป็นความแม่นยำประมาณ 98.78%

เพื่อแก้ไขปัญหาค่าที่เกินขึ้นบริเวณรอยต่อของตัวเลข ผู้วิจัยได้พัฒนา Transition (Pair) Model เพื่อช่วยตรวจสอบลักษณะการเปลี่ยนผ่านของตัวเลข โดยผลการทดลองพบว่าโมเดลมีค่า Training Accuracy เท่ากับ 100% และ Validation Accuracy ประมาณ 94.65% ซึ่งช่วยเพิ่มความถูกต้องของการอ่านค่าตัวเลขในกรณีที่ตัวเลขอยู่ในช่วงการเปลี่ยนผ่าน

สำหรับการอ่านค่าทศนิยมจากตำแหน่งเข็มมิเตอร์ ระบบใช้โมเดล Pointer Regression ซึ่งสามารถทำนายมุมของเข็มได้ด้วยค่าความคลาดเคลื่อนเฉลี่ยประมาณ ± 3 องศา และมีความแม่นยำประมาณ 96% ภายในช่วงความคลาดเคลื่อน ± 5 องศา

เมื่อพิจารณาการทำงานของระบบแบบครบกระบวนการ (End-to-End System) พบว่าระบบสามารถอ่านค่ามิเตอร์ได้สำเร็จมากกว่า 82% ของจำนวนภาพทดสอบทั้งหมด และมีเวลาเฉลี่ยในการประมวลผลประมาณ 1.8 วินาทีต่อภาพ แสดงให้เห็นว่าระบบสามารถทำงานได้ในระดับที่ใกล้เคียงกับการใช้งานจริง

เพื่อสรุปประสิทธิภาพของระบบในภาพรวม ตารางที่ 2 แสดงผลการประเมินประสิทธิภาพของแต่ละโมดูลและผลการทำงานของระบบแบบครบกระบวนการ

โมดูล / ส่วนการทำงาน	ตัวชี้วัดประสิทธิภาพ	ค่า / ผลลัพธ์
YOLOv8 – Digital Detection (Single-Class)	mAP@0.5	1.00
YOLOv8 – Pointer Detection (Multi-Class)	mAP@0.5	0.99
Digit CNN Model	Accuracy	~94.7%
	F1-score	> 0.90

Transition (Pair) Model	Train Accuracy	100%
	Validation Accuracy	~94.65%
Pointer Regression Model	MAE (Error)	$\pm 3^\circ$
	Accuracy ($\pm 5^\circ$)	96%
ระบบรวม End-to-End	1) ความสำเร็จในการตรวจจับครบถ้วน 2) เวลาเฉลี่ยประมวลผลต่อภาพ 3) ความสอดคล้อง Digital + Analog	> 82% ≈ 1.8 วินาที ถูกต้องตาม ค่าความ จริง(Ground Truth)

ตารางที่ 2 สรุปประสิทธิภาพรวมของระบบ AquaRead (Overall Performance Summary)

อย่างไรก็ตาม จากการทดลองยังพบข้อจำกัดบางประการที่ส่งผลกระทบต่อความแม่นยำของระบบ เช่น สภาวะแสงที่ไม่สม่ำเสมอ แสงย้อน หรือเงามืดที่เกิดขึ้นบนหน้าปัดมิเตอร์ รวมถึงลักษณะของตัวเลขที่อยู่ในช่วงการเปลี่ยนผ่าน ซึ่งอาจทำให้เกิดความคลาดเคลื่อนในการอ่านค่าได้ในบางกรณี ผู้วิจัยจึงได้ประยุกต์ใช้เทคนิค CLAHE (Contrast Limited Adaptive Histogram Equalization) เพื่อช่วยปรับสมดุลแสงของภาพ และใช้โมเดล Transition Model เพื่อช่วยตรวจสอบความถูกต้องของตัวเลขในช่วงรอยต่อ

ทั้งนี้ ข้อจำกัดที่พบจากการทดลอง รวมถึงแนวทางการพัฒนาระบบให้มีความสมบูรณ์และมีความเสถียรมากยิ่งขึ้นสำหรับการใช้งานจริงในภาคสนาม จะถูกนำไปกล่าวถึงโดยละเอียดในบทถัดไป

บทที่ 5

บทสรุปและข้อเสนอแนะ

5.1 บทสรุป

โครงการพัฒนาระบบอ่านค่ามิเตอร์น้ำอัตโนมัติ AquaRead มีวัตถุประสงค์เพื่อแก้ไขปัญหาความคลาดเคลื่อนจากการอ่านค่าด้วยมนุษย์ (Human Error) โดยประยุกต์ใช้เทคนิคการประมวลผลภาพ (Image Processing) และปัญญาประดิษฐ์ (Artificial Intelligence) ร่วมกับการออกแบบระบบสารสนเทศที่สามารถใช้งานได้จริงในภาคสนาม ผลการดำเนินงานสามารถสรุปสาระสำคัญได้ดังนี้

1) **ด้านการพัฒนาโมเดลปัญญาประดิษฐ์** ระบบประกอบด้วยโมดูลหลัก 3 ส่วน ได้แก่ โมเดลตรวจจับวัตถุด้วย YOLOv8 โมเดลจำแนกตัวเลขดิจิทัลด้วย CNN และโมเดลทำนายมุมเข็มแบบ Regression ซึ่งผลการทดสอบแสดงให้เห็นว่าโมเดลทั้งหมดสามารถทำงานร่วมกันได้อย่างมีประสิทธิภาพและให้ผลลัพธ์ที่สอดคล้องกับค่าจริง

2) **ด้านความแม่นยำของการอ่านค่า** ระบบสามารถทำนายมุมเข็มของหน้าปัดอนาล็อกได้โดยมีความคลาดเคลื่อนเฉลี่ยประมาณ $\pm 3^\circ$ และสามารถจำแนกตัวเลขดิจิทัลได้อย่างแม่นยำในระดับที่น่าพึงพอใจ โดยเฉพาะเมื่อมีการประยุกต์ใช้ Transition Model เพื่อแก้ไขปัญหาความไม่ต่อเนื่อง ของตัวเลขในช่วงเปลี่ยนหลัก

3) **ด้านระบบประมวลผลและการให้บริการผ่านเครือข่าย** Web Application ของระบบ AquaRead สามารถรับภาพจากผู้ใช้งาน ประมวลผล และแสดงผลลัพธ์ได้แบบอัตโนมัติภายในเวลาเฉลี่ยประมาณ 1.8 วินาทีต่อภาพ พร้อมทั้งรองรับการจัดเก็บข้อมูลและการส่งออกรายงานในรูปแบบไฟล์ CSV ซึ่งเหมาะสมกับการบริหารจัดการข้อมูลการใช้น้ำในเชิงระบบ

4) **ด้านการออกแบบ Mobile Application ผ่าน WebView** ระบบได้ถูกออกแบบให้สามารถใช้งานผ่านอุปกรณ์พกพาโดยอาศัยแนวคิด Mobile WebView ซึ่งนำ Web Application เดียวกันมาแสดงผลภายใน Mobile Application โดยไม่จำเป็นต้องพัฒนาแอปพลิเคชันแบบ Native แยกต่างหาก แนวทางนี้ช่วยลดความซับซ้อนในการพัฒนา รองรับการใช้งานภาคสนาม และทำให้ผู้ใช้งานสามารถถ่ายภาพ ตรวจสอบผลการอ่านค่า และติดตามข้อมูลผ่านอุปกรณ์เคลื่อนที่ได้อย่างสะดวก

5) **ด้านแนวคิดและความคุ้มค่าในการนำไปใช้งานจริง** ระบบ AquaRead ยึดแนวคิด “ติดตั้งทั้ของเดิม ไม่ต้องเปลี่ยนมิเตอร์” ซึ่งช่วยลดต้นทุนในการติดตั้งและสามารถนำไปประยุกต์ใช้งานกับระบบมิเตอร์น้ำเดิมได้ทันที เหมาะสมกับการพัฒนาในระดับต้นแบบและมีศักยภาพในการต่อยอดสู่การใช้งานจริงในอนาคต

5.2 ข้อจำกัดของโครงการ

แม้ว่าระบบ AquaRead จะสามารถอ่านค่ามิเตอร์น้ำแบบอนาล็อกได้อย่างอัตโนมัติและให้ผลลัพธ์ที่น่าพึงพอใจ แต่เนื่องจากข้อจำกัดด้านขอบเขตของโครงการและทรัพยากรที่ใช้ในการพัฒนา ระบบยังมีข้อจำกัดบางประการดังนี้

1) **ด้านคุณภาพของภาพอินพุต** ความแม่นยำของระบบยังขึ้นอยู่กับคุณภาพของภาพถ่าย เช่น สภาพแสง เงาสะท้อน คราบสกปรก หรือความเบลอลงของภาพ ซึ่งอาจส่งผลให้การตรวจจับและการอ่านค่ามิเตอร์เกิดความคลาดเคลื่อนได้

แม้ว่าระบบจะถูกฝึกด้วยชุดข้อมูลจากมิเตอร์น้ำในลักษณะเดียวกันกับภาพทดสอบ แต่คุณภาพของภาพยังคงมีผลต่อความแม่นยำของการอ่านค่า ในบางกรณีอาจเกิดสิ่งรบกวนบนหน้าปัดมิเตอร์ เช่น ฝุ่น คราบสกปรก หรือแสงสะท้อน ซึ่งอาจบดบังตำแหน่งของเข็มบางส่วน ทำให้โมเดลไม่สามารถระบุตำแหน่งปลายเข็มได้อย่างถูกต้อง

ดังตัวอย่างในรูปที่ 83 แม้ว่ามิเตอร์ดังกล่าวจะเป็นรูปแบบเดียวกับที่ใช้ในการฝึกโมเดล แต่มีฝุ่นบดบังบริเวณปลายเข็มของหน้าปัดย่อย ส่งผลให้ระบบอ่านค่าตำแหน่งเข็มคลาดเคลื่อน จากค่าที่ควรอ่านได้ประมาณ 3 กลายเป็น 6 ซึ่งทำให้ค่าการใช้น้ำที่คำนวณได้เกิดความคลาดเคลื่อนจากค่าจริง




รูปภาพที่ 84 ตัวอย่างกรณีที่คุณภาพของภาพส่งผลต่อความแม่นยำของระบบ โดยมีฝุ่นบดบังบริเวณปลายเข็มของหน้าปัดย่อย ทำให้ระบบอ่านค่าตำแหน่งเข็มคลาดเคลื่อนจากค่าจริง

2) ด้านการรองรับรูปแบบมิเตอร์น้ำ ระบบ AquaRead ถูกพัฒนาและทดสอบจากชุดข้อมูลมิเตอร์น้ำที่มีลักษณะหน้าปัดเฉพาะบางรูปแบบ จึงอาจยังไม่สามารถรองรับมิเตอร์น้ำทุกยี่ห้อหรือทุกรูปแบบได้อย่างสมบูรณ์ เมื่อทดสอบกับมิเตอร์น้ำที่มีโครงสร้างหน้าปัดแตกต่างจากชุดข้อมูลฝึก เช่น ตำแหน่งเข็ม รูปร่างหน้าปัด หรือรูปแบบสเกลที่ไม่สอดคล้องกัน พบว่าโมเดลตรวจจับอาจครอบคลุมตำแหน่งหน้าปัดเข็มหรือกล่องตัวเลขไม่ถูกต้อง ส่งผลให้การคำนวณค่ามูมเข็มและการอ่านค่ามิเตอร์น้ำเกิดความคลาดเคลื่อน ดังแสดงในตัวอย่างการตรวจจับมิเตอร์น้ำรูปแบบอื่น ซึ่งสะท้อนถึงข้อจำกัดของโมเดลเมื่อใช้งานกับข้อมูลที่อยู่นอกขอบเขตการฝึก



(ก)



(ข)

รูปภาพที่ 85 ผลการตรวจจับมิเตอร์น้ำที่มีโครงสร้างหน้าปัดแตกต่างจากข้อมูลที่ใช้ฝึกโมเดล ได้แก่ (ก) มิเตอร์ที่มีจำนวนหน้าปัดเข็มมากกว่าหนึ่งวง และ (ข) มิเตอร์ที่มีช่องตัวเลขเลื่อนมากกว่า 5 ตำแหน่งและมีหน้าปัดเข็มเพียงหนึ่งวง ซึ่งพบว่าการครอบตำแหน่งหน้าปัดเข็มและกล่องตัวเลขเกิดความคลาดเคลื่อน ส่งผลให้การคำนวณค่ามูมเข็มและการอ่านค่ามิเตอร์น้ำไม่สอดคล้องกับค่าจริง สอดคล้องกับข้อจำกัดที่กล่าวไว้ในหัวข้อ 5.2(2)

นอกจากนี้ จากการทดสอบกับมิเตอร์น้ำที่มีโครงสร้างแตกต่างจากชุดข้อมูลฝึก เช่น มิเตอร์ที่มีช่องตัวเลขเลื่อนมากกว่า 5 ตำแหน่ง และมีหน้าปัดเข็มเพียง 1 วง พบว่าระบบยังไม่สามารถตีความโครงสร้างหน้าปัดได้อย่างถูกต้อง ส่งผลให้การแบ่งหลักตัวเลขและการประเมินค่าจากเข็มไม่สอดคล้องกับค่าจริง ซึ่งแสดงให้เห็นว่าระบบยังมีข้อจำกัดในการรองรับมิเตอร์ที่มีโครงสร้างแตกต่างจากสมมติฐานที่ใช้ในการฝึกโมเดล

3) ด้านการทดสอบภาคสนาม ระบบยังอยู่ในระดับต้นแบบ (Prototype) และการทดสอบส่วนใหญ่ดำเนินการในสภาพแวดล้อมที่ควบคุมได้ จึงยังขาดการทดสอบระยะยาวในสภาพแวดล้อมภาคสนามจริง

5.3 ข้อเสนอแนะและแนวทางการพัฒนาต่อยอด

เพื่อให้ระบบอ่านค่ามาตรน้ำอัตโนมัติ AquaRead มีประสิทธิภาพและความเสถียรเพิ่มขึ้นสำหรับการนำไปประยุกต์ใช้งานในภาคสนาม ผู้วิจัยมีข้อเสนอแนะสำหรับการพัฒนาต่อยอดดังนี้

1) ด้านการเพิ่มความแม่นยำของโมเดล (Model Enhancement) ควรเพิ่มปริมาณและความหลากหลายของชุดข้อมูล (Data Augmentation) โดยเฉพาะภาพถ่ายในสภาวะที่ยากลำบาก เช่น ภาพที่มีความสว่างน้อย (Low Light) หรือภาพที่มีความเบลอจากการสั่นไหว เพื่อลดค่าความคลาดเคลื่อนในการตรวจจับ เช่น พัฒนาอัลกอริทึมการปรับแสงและสี (Image Enhancement) ให้มีความซับซ้อนขึ้น เพื่อแก้ปัญหาการเกิดเงาสะท้อนบนกระบอกมาตรน้ำซึ่งเป็นอุปสรรคสำคัญในการทำนายมุมซึม

2) ด้านการขยายขีดความสามารถของระบบ (System Expansion) พัฒนาแอปพลิเคชันบนอุปกรณ์เคลื่อนที่ (Mobile Application) เพื่ออำนวยความสะดวกให้เจ้าหน้าที่สามารถถ่ายภาพและอัปโหลดข้อมูลได้โดยตรงจากหน้างาน เช่น เพิ่มระบบบริหารจัดการข้อมูลประวัติการอ่านค่ารายเดือน (Monthly Log) เพื่อให้สามารถวิเคราะห์แนวโน้มการใช้น้ำและแจ้งเตือนกรณีพบการใช้น้ำที่ผิดปกติได้อย่างทันท่วงที

3) ด้านการรองรับอุปกรณ์ (Device Support) ปรับปรุงสถาปัตยกรรมของซอฟต์แวร์ให้รองรับเมตอร์น้ำยี่ห้อและรุ่นอื่น ๆ ที่มีความแตกต่างของหน้าปัด เพื่อเพิ่มความยืดหยุ่นในการนำไปใช้งานในพื้นที่ที่หลากหลาย

บรรณานุกรม

- [1] การประปาส่วนภูมิภาค, “คู่มือการอ่านและบันทึกค่าน้ำ,” เอกสารเผยแพร่ภายใน, 2020.
- [2] R. Gonzalez and R. Woods, *Digital Image Processing*, 4th ed., Pearson, 2018.
- [3] A. Krizhevsky, I. Sutskever, and G. E. Hinton, “ImageNet Classification with Deep Convolutional Neural Networks,” *Communications of the ACM*, vol. 60, no. 6, pp. 84–90, 2017.
- [4] J. Redmon and A. Farhadi, “YOLOv3: An Incremental Improvement,” 2018. [Online]. Available: <https://pjreddie.com/darknet/yolo/>
- [5] Jomjol, “AI-on-the-edge-device Project: ESP32-based Smart Meter Reader,” *GitHub Repository*, 2021. [Online]. Available: <https://github.com/jomjol/AI-on-the-edge-device>
- [6] S. Dasgupta, N. Kundu, and A. Singh, “Automatic Meter Reading using YOLOv2 and CNN Regression,” *Proceedings of the International Conference on Computer Vision Applications*, pp. 102–108, 2019.
- [7] M. Imran, H. Ali, and A. Khan, “Automatic Recognition of Digital and Analog Electric Meters using YOLOv3,” *IEEE Sensors Journal*, vol. 23, no. 9, pp. 11145–11153, 2023.
- [8] P. Li, X. Zhang, and Y. Chen, “Smart Pressure Gauge Reading via Multi-Step Edge Detection and Adaptive Thresholding,” *Measurement*, vol. 181, pp. 109653–109660, 2021.
- [9] P. Li, Z. Lu, and H. Zhang, “YOLOX-DC and PM-SwinUnet for Robust Pointer Meter Reading Recognition,” *Sensors*, vol. 25, no. 4, pp. 2456–2470, 2025.
- [10] W. Wu, Y. Chen, and C. Li, “A High-Precision Automatic Pointer Meter Reading System in Low-Light Environment,” *IEEE Access*, vol. 9, pp. 116972–116984, 2021.

ภาคผนวก

ภาคผนวก ก ตัวอย่างผลการตรวจจับมิเตอร์น้ำจากระบบ AquaRead



รูป ก-1 ตัวอย่างผลการตรวจจับตำแหน่งหน้ากลองตัวเลขและหน้าปัดเข็ม



รูป ก-2 ตัวอย่างผลการตรวจจับตัวเลขเลื่อนแยกแต่ละหลักจากแถบตัวเลขดิจิทัล

รายงานผลการตรวจนับ img73

ภาพที่ตรวจนับแล้ว



แสดงรายละเอียด ->

ผลการตรวจนับ

TOTAL USAGE

0002.0255 m³

Digital: 0002 x01: 0 x001: 2 x0001: 5 x00001: 5

ตำแหน่ง	ค่าอ่าน
Digital	0002
x01	0
x001	2
x0001	5
x00001	5
Total	0002.0255 m³



สรุปค่าที่อ่านได้

ตำแหน่ง	ค่า
Digital	0002
x01	0
x001	2
x0001	5
x00001	5
รวม	0002.0255 m³

การตัดสินใจแต่ละหลัก

ตำแหน่ง	Prev	Raw	Final
Digital	-	0002	0002
x01	2	0	0
x001	0	2	2
x0001	8	5	5
x00001	5	5	5

Image Digital Crop

Img	Val.	Img	Val.	Img	Val.	Img	Val.	Img	Val.
	0		0		0		2		0

Image Analog Crop

Img	Val.	Img	Val.	Img	Val.
	2		5		5

รายงานผลการตรวจนับ 468a942f-564b-48f1-affa-83169bbcb1b1

ภาพที่ตรวจนับแล้ว



แสดงรายละเอียด

ผลการตรวจนับ

TOTAL USAGE

0000.2085 m³

Digital: 0000 x01: 2 x001: 0 x0001: 8 x00001: 5

ตำแหน่ง ค่าอ่าน

Digital 0000

x01 2

x001 0

x0001 8

x00001 5

Total 0000.2085 m³



สรุปค่าที่อ่านได้

ตำแหน่ง	ค่า
Digital	0000
x01	2
x001	0
x0001	8
x00001	5
รวม	0000.2085 m ³

การตัดสินใจแต่ละหลัก

ตำแหน่ง	Prev	Raw	Final
Digital	-	0	0000
x01	6	2	2
x001	3	0	0
x0001	2	8	8
x00001	2	5	5

Image Digital Crop

Img	Val.	Img	Val.	Img	Val.	Img	Val.	Img	Val.
	0		0		0		0		2

Image Analog Crop

Img	Val.	Img	Val.	Img	Val.
	0		8		5

รูป ก-3 ตัวอย่างผลลัพธ์การทำงานของระบบ AquaRead แบบครบกระบวนการ (End-to-End)

แสดงผลลัพธ์จากระบบ AquaRead จำนวน 2 กรณี ซึ่งมีขั้นตอนการประมวลผลเหมือนกัน ได้แก่ การตรวจจับตำแหน่งบนหน้าปัดมิเตอร์ การตัดภาพย่อย การประเมินค่าตัวเลข และการสรุปค่าการใช้น้ำรวม โดยรายละเอียดของขั้นตอนแสดงตามรายการ (ก)–(ง)

- (ก) ภาพผลการตรวจจับตำแหน่งบนหน้าปัดมิเตอร์
- (ข) ตารางสรุปค่าที่อ่านได้จาก Digital และ Analog
- (ค) ตารางตรวจสอบค่า Prev (ค่าก่อนหน้า), Raw (ค่าดิบ) และ Final (ค่าหลังการปรับแก้)
- (ง) ภาพตัวอย่าง Digital Crop และ Analog Crop ที่ใช้ในการประมวลผล

ภาคผนวก ข โค้ดใช้งานระบบ (Deployment / Application)

ซอร์สโค้ดฉบับสมบูรณ์ของระบบ AquaRead ซึ่งประกอบด้วยโมดูลการประมวลผลภาพ การตรวจจับวัตถุ การอ่านค่าตัวเลขดิจิทัล การประมาณค่าเข็มมาตรวัด และระบบเว็บแอปพลิเคชันสำหรับการใช้งานจริง ได้จัดเก็บไว้ในรูปแบบ Repository บนแพลตฟอร์ม GitHub โดยสามารถเข้าถึงได้จากลิงก์ดังต่อไปนี้ https://github.com/ppippp1517-wq/AquaRead_meter

ทั้งนี้ Repository ดังกล่าวประกอบด้วยไฟล์โปรแกรม โครงสร้างระบบ เอกสารคำอธิบาย (README) และแผนภาพสถาปัตยกรรมของระบบอย่างครบถ้วน

The screenshot displays the GitHub interface for the repository `ppippp1517-wq / AquaRead_meter`. The repository is public and has 8 commits. The commit history shows files like `water_meter_alignment`, `watermeter_project`, `.gitignore`, `New Text Document.txt`, `README.md`, `requirements.txt`, and `system_architecture.png` being added. The README section is titled "AquaRead: Automatic Analog Water Meter Reading System". Below the README, there is a "System Architecture Diagram" which illustrates the workflow from input to output, involving image processing, digit recognition, and model inference. A language usage bar at the bottom indicates the repository contains 59.2% HTML, 40.7% Python, and 0.1% JavaScript.

ประวัติผู้เขียน

ชื่อ-สกุล :นางสาว ปิยะพร แสงพรหมขารี

วันเดือนปีเกิด : 18 ตุลาคม 2545

ประวัติการศึกษา :

- พ.ศ. 2561 สำเร็จการศึกษาระดับมัธยมศึกษาตอนต้น
จากโรงเรียนปิยะมหาราชาลัย จังหวัดนครพนม
- พ.ศ. 2564 สำเร็จการศึกษาระดับมัธยมศึกษาตอนปลาย
จากโรงเรียนธรรมศาสตร์คลองหลวงวิทยาคม จังหวัดปทุมธานี

ผลงานหรือความสนใจด้านวิชาการ :

มีความสนใจด้านปัญญาประดิษฐ์ (Artificial Intelligence) การประมวลผลภาพ (Computer Vision) และ การพัฒนาระบบ Internet of Things (IoT) โดยได้พัฒนาโครงงานเรื่อง “AquaRead: ระบบอ่านค่ามาตรวัดน้ำอัตโนมัติด้วยเทคนิค Deep Learning” ซึ่งเป็นการประยุกต์ใช้โมเดล YOLOv8 และ Convolutional Neural Network สำหรับตรวจจับและอ่านค่ามิเตอร์น้ำแบบอนาล็อกจากภาพถ่าย